Investigação e Implementação de Modelos Neurais em Tópicos Avançados de Inteligência Artificial

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Recife - PE, Brasil
jose.alberico@ufrpe.br

Abstract. Este trabalho apresenta o estudo, projeto e implementação de arquiteturas neurais avançadas no âmbito da disciplina de Tópicos Avançados em Inteligência Artificial. Através de uma abordagem baseada em grafo explícito e experimentação empírica, investigam-se os impactos de hiperparâmetros, dinâmicas de treinamento e convergência de gradientes. Os resultados obtidos demonstram a consistência dos métodos propostos, validando a integração entre o ambiente de experimentação prática e a análise técnica formal.

Keywords: Inteligência Artificial · Redes Neurais · Multi-Layer Perceptron · Grafo Explícito · Aprendizado Profundo.

1 Introdução

O avanço contínuo das técnicas de Inteligência Artificial (IA) e Aprendizado Profundo (*Deep Learning*) tem impulsionado transformações significativas em diversas áreas do conhecimento [2]. No entanto, a compreensão detalhada das dinâmicas internas de treinamento, fluxos de propagação direta (*forward propagation*) e retropropagação de gradientes (*backpropagation*) permanece fundamental para o desenvolvimento e depuração de novos modelos.

Este artigo propõe e avalia a implementação de modelos neurais sob a perspectiva de grafos explícitos, permitindo a inspeção detalhada de estados internos e a visualização dinâmica da arquitetura. O objetivo central é fornecer uma base empírica e analítica sólida para as atividades desenvolvidas na disciplina de Tópicos Avançados em Inteligência Artificial.

2 Trabalhos Relacionados

Os fundamentos do treinamento de redes neurais multicamadas através da descida de gradiente e retropropagação foram consolidados no trabalho seminal de Rumelhart et al. [5] e sistematizados de forma abrangente por Goodfellow et al. [2]. Desde então, diversos arcabouços computacionais e arquiteturas modernas,

incluindo modelos baseados em mecanismos de autoatenção [6], foram propostos para escalar o cálculo automático de gradientes e a construção de topologias profundas.

Na literatura contemporânea, o aprendizado de representações e a inferência estruturada demonstram ampla versatilidade em domínios complexos, abrangendo desde a inferência em grafos sobre rastros de rede [4] até a classificação textual com redes neurais e aprendizado de máquina automatizado [3] e a construção de corpora anotados para detecção de padrões em mídias sociais [1]. Tais avanços reforçam a importância de compreender com rigor analítico e experimental os mecanismos internos de propagação direta e reversa de gradientes investigados neste estudo.

3 Metodologia

A metodologia adotada divide-se em duas frentes complementares: formulação teórica do modelo neural e implementação em código modular.

3.1 Modelo Matemático

Dado um vetor de entrada $\mathbf{x} \in \mathbb{R}^d$, a saída de um neurônio j em uma camada l é expressa por:

$$z_j^{(l)} = \sum_i w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)} \tag{1}$$

$$a_j^{(l)} = \sigma\left(z_j^{(l)}\right) \tag{2}$$

onde $w_{ij}^{(l)}$ denota o peso sináptico da conexão, $b_j^{(l)}$ representa o termo de viés (*bias*) e $\sigma(\cdot)$ é a função de ativação não linear aplicada elemento a elemento.

3.2 Arquitetura em Grafo Explícito

Diferentemente de implementações baseadas exclusivamente em operações matriciais opacas, a arquitetura foi concebida como um grafo direcionado $G = (V, E)$, onde os vértices V correspondem aos neurônios individuais e as arestas E armazenam os pesos sinápticos e os respectivos gradientes acumulados em cada passo de otimização.

4 Resultados e Discussão

Esta seção detalha os experimentos empíricos conduzidos com a arquitetura proposta, avaliando convergência de função de perda, taxa de acerto (*accuracy*) e estabilidade numérica.

Table 1. Resumo dos hiperparâmetros utilizados nos ensaios experimentais.

Parâmetro	**Valor Adotado**
Taxa de Aprendizado (η)	0.01 – 0.1
Otimizador	Descida do Gradiente Estocástico (SGD)
Função de Custo	Erro Quadrático Médio (MSE) / Entropia Cruzada
Épocas de Treinamento	500

4.1 Ambiente Experimental

Os experimentos foram executados utilizando o ambiente integrado em Python, com dados normalizados e divisão entre conjuntos de treino e validação.

Os resultados preliminares evidenciam a convergência monótona da perda e a consistência dos gradientes calculados através da estrutura em grafo.

5 Conclusão e Trabalhos Futuros

Este trabalho apresentou uma abordagem integrada para o estudo e implementação de modelos neurais em inteligência artificial. A representação explícita como grafo facilitou a depuração algorítmica e a inspeção dos gradientes durante a etapa de treinamento.

Como trabalhos futuros, planeja-se a extensão para arquiteturas baseadas em mecanismos de atenção [6], bem como a automatização da exportação de métricas experimentais diretamente para o relatório acadêmico.

References

1. Álvarez-Ojeda, P., Cantero-Romero, M.V., Semikozova, A., Montejo-Ráez, A.: The precom-sm corpus: Gambling in spanish social media. In: Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025). pp. 15–28 (2025), https://aclanthology.org/2025.coling-main.2/
2. Goodfellow, I., Bengio, Y., Courville, A.: Deep Learning. MIT Press (2016), https://www.deeplearningbook.org
3. Muzakir, A., Syaputra, H., Fathoni, Kusnadi: Text-based detection of online gambling advertisements on social media using automl and cnn. In: 2025 2nd International Conference on Information System and Information Technology (ICISIT). IEEE (2025). https://doi.org/10.1109/ICISIT.2025.10842131
4. Nabeel, M., Khalil, I.M., Guan, B., Yu, T.: Following passive dns traces to detect stealthy malicious domains via graph inference. ACM Transactions on Privacy and Security (TOPS) **23**(4), 1–36 (2020). https://doi.org/10.1145/3401897
5. Rumelhart, D.E., Hinton, G.E., Williams, R.J.: Learning representations by back-propagating errors. Nature **323**(6088), 533–536 (1986). https://doi.org/10.1038/323533a0
6. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. Advances in Neural Information Processing Systems **30** (2017)