Investigação Empírica, Conexões Residuais e Mecanismos de Atenção em Redes Neurais Convolucionais para Classificação no CIFAR-10

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. Este artigo científico formaliza a investigação empírica, reprodução de referência e extensão arquitetural de uma rede neural convolucional moderna (*Convolutional Neural Network* – CNN) aplicada à classificação de imagens naturais no *benchmark* canônico CIFAR-10, correspondente ao Artefato `[5] arquitetura tech report` (`arq-p`) da disciplina Tópicos Avançados em Inteligência Artificial (UFRPE 2026.2). Inicialmente, reproduz-se fielmente o modelo basal de Dizabadi (*arXiv:2604.23861, 2026*), composto por 6 camadas convolucionais 3×3, 7 camadas de normalização em lote (*Batch Normalization*), subamostragem por *Max Pooling* e regularização estocástica por *Dropout*, totalizando exatamente 552.874 parâmetros. A partir do diagnóstico de duas lacunas fundamentais na literatura original – o colapso severo no aprendizado ao aumentar a profundidade para 8 convoluções (83,42% $\rightarrow$ 70,66%) decorrente do desvanecimento de gradientes e o sobreajuste estrutural oriundo do treinamento com dados puramente estáticos – propõem-se e implementam-se três modificações inéditas e substanciais: (1) Conexões Residuais aditivas (*Skip Connections*) estilo ResNet; (2) Protocolo de *Data Augmentation* estocástico dinâmico em tempo real (*Random Crop* com preenchimento reflexivo e *Random Horizontal Flip*); e (3) Mecanismo de Atenção Squeeze-and-Excitation (*SE-Block*) para recalibração adaptativa dos mapas de características, culminando na integração sinérgica em um Modelo Combinado. Sob um protocolo rígido de partição estratificada sem vazamento (*zero data leakage*) com 25.000 amostras de treino e 5.000 de teste, conduz-se um estudo de ablação sistemático confrontando métricas reportadas na literatura, reproduzidas e pós-modificações. Por fim, executa-se uma análise qualitativa detalhada com inspeção visual das instâncias críticas de teste, explicitando os mecanismos geométricos e espectrais subjacentes aos acertos de alta certeza e às confusões limítrofes entre categorias visuais próximas.

Keywords: Redes Neurais Convolucionais · Conexões Residuais · Squeeze-and-Excitation · Data Augmentation · Visão Computacional · CIFAR-10 · Estudo de Ablação.

1 Introdução

1.1 Contextualização e Relevância

O reconhecimento automatizado de padrões visuais em dados não estruturados constitui um dos pilares do aprendizado profundo moderno. Desde a quebra de paradigma proporcionada pelas redes convolucionais profundas [7,9], o processamento de imagens consolidou-se em torno do aprendizado hierárquico de representaciones: camadas preliminares extraem gradientes espaciais e bordas locais de alta frequência, camadas intermediárias compõem texturas e partes anatômicas, e estágios terminais sintetizam conceitos semânticos globais discriminativos [3].

Entretanto, o treinamento de redes profundas sobre coleções com resolução espacial compacta, como o *benchmark* CIFAR-10 (32×32 pixels em 10 classes) [7], impõe desafios singulares à engenharia de características e à dinâmica de otimização. A perda rápida de resolução espacial por subamostragens sucessivas combinada com o empilhamento rígido de camadas pode desencadear o desvanecimento exponencial de gradientes durante a retropropagação (*backpropagation*), degradando a convergência do estimador e estimulando o sobreajuste severo (*overfitting*) sobre o conjunto de treinamento.

1.2 Artigo Base Selecionado e Topologia Original

Para atender aos critérios de seleção da disciplina (artigo científico recente $\geq$ 2023, com código aberto e arquitetura convolucional profunda moderna), adotou-se como referência canônica o estudo de Dizabadi (2026) [2]:

> **Artigo de Referência:** Dizabadi, N. K. *"Empirical Ablation and Ensemble Optimization of a Convolutional Neural Network for CIFAR-10 Classification"*, arXiv:2604.23861v1, Abril de 2026.

A arquitetura proposta por Dizabadi (*Step 7* do artigo original) estrutura-se em três blocos convolucionais duplos, intercalados por normalização em lote (*Batch Normalization*) [6], ativações retificadas lineares (ReLU), subamostragem por *Max Pooling* 2×2 e desconexões estocásticas de neurônios por *Dropout* [10]:

1. **Bloco Convolucional 1:** Entrada $\mathbf{X} \in \mathbb{R}^{3\times32\times32} \rightarrow$ Conv2D($3 \rightarrow 32, 3 \times 3$)+BN+ReLU $\rightarrow$ Conv2D($32 \rightarrow 32, 3\times3$)+BN+ReLU $\rightarrow$ MaxPool(2×2) $\rightarrow$ Dropout(0,30), produzindo mapas de características em $\mathbb{R}^{32\times16\times16}$;
2. **Bloco Convolucional 2:** Conv2D($32 \rightarrow 64, 3\times3$)+BN+ReLU $\rightarrow$ Conv2D($64 \rightarrow 64, 3 \times 3$) + BN + ReLU $\rightarrow$ MaxPool(2×2) $\rightarrow$ Dropout(0,50), produzindo tensores em $\mathbb{R}^{64\times8\times8}$;
3. **Bloco Convolucional 3:** Conv2D($64 \rightarrow 128, 3 \times 3$) + BN + ReLU $\rightarrow$ Conv2D($128 \rightarrow 128, 3\times3$)+BN+ReLU $\rightarrow$ MaxPool(2×2) $\rightarrow$ Dropout(0,50), produzindo mapas em $\mathbb{R}^{128\times4\times4}$;
4. **Classificador Denso:** Achatamento vetorial Flatten $\rightarrow \mathbf{h}_0 \in \mathbb{R}^{2048} \rightarrow$ Linear($2048 \rightarrow 128$) + ReLU + BN + Dropout(0,50) $\rightarrow$ Linear($128 \rightarrow 10$).

Essa topologia totaliza rigorosamente 552.874 **parâmetros** (551.722 parâmetros treináveis e 1.152 estatísticas não-treináveis de média e variância acumuladas nas 7 camadas de Batch Normalization), reproduzindo com precisão a contagem paramétrica oficial reportada na literatura.

1.3 Diagnóstico de Lacunas e Formulação das Hipóteses

A despeito de o artigo original conduzir 17 experimentações de ablação e combinações de *ensembles* homogêneos, emergem três vulnerabilidades metodológicas não resolvidas pelos autores:

1. **Colapso Catastrófico em Profundidades Maiores (*Step 11*):** Ao adicionar mais duas camadas convolucionais consecutivas (totalizando 8 camadas), a acurácia desabou de 83,42% para 70,66%. Os autores constataram empiricamente o desvanecimento de gradientes, mas não exploraram conexões residuais aditivas de fluxo direto;
2. **Treinamento Estático e Fosso de Sobreajuste:** O pipeline do artigo alimentou a rede exclusivamente com imagens originais sem qualquer perturbação estocástica, gerando acurácias de treinamento superiores a 95% em contraste com os $\approx 83\%$ de generalização no teste;
3. **Equiponderação Uniforme de Canais:** Os mapas de características convolucionais foram tratados sem moduladores de atenção seletiva, tornando o classificador excessivamente vulnerável a correlações espúrias de plano de fundo (como céu e água).

Diante desse diagnóstico, formulam-se três hipóteses de pesquisa inéditas frente às 17 etapas do artigo base:

- **Hipótese 1 (H_1 – Resíduos Aditivos):** A inclusão de atalhos residuais aditivos (*Skip Connections*) permite que o operador linear preserve a magnitude dos gradientes ao longo das camadas profundas conforme $\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}}(\frac{\partial \mathcal{F}}{\partial \mathbf{x}} + \mathbf{I})$, estabilizando a retropropagação e acelerando o processamento computacional;
- **Hipótese 2 (H_2 – Data Augmentation):** Perturbações geométricas estocásticas em tempo de treino (*Random Crop* com preenchimento reflexivo e *Random Horizontal Flip*) quebram a coadaptação dos pesos convolucionais, atuando como um potente regularizador funcional que estreita o gap de generalização;
- **Hipótese 3 (H_3 – Mecanismo de Atenção SE):** A recalibração explícita de saliência entre canais via compressão espacial global (*squeeze*) e gargalo não-linear com função de ativação sigmoide (*excitation*) prioriza características estruturais do objeto em detrimento do ruído cromático de fundo com sobrecarga paramétrica marginal ($< 1\%$).

1.4 Estrutura do Artigo

O restante deste artigo está organizado da seguinte forma: a Seção 2 revisa os trabalhos relacionados e fundamentos teóricos; a Seção 3 descreve a gestão de

dados, a modelagem matemática do baseline e das três modificações propostas; a Seção 4 expõe a matriz comparativa quantitativa e as curvas de aprendizado; a Seção 5 conduz a análise qualitativa detalhada com escrutínio de instâncias reais de falha e sucesso; e a Seção 6 sintetiza as considerações finais e delineia direções para investigações futuras.

2 Trabalhos Relacionados e Fundamentação Teórica

2.1 Evolução das CNNs Profundas e o Paradigma Residual

A consolidação das redes neurais convolucionais iniciou-se com a introdução de núcleos convolucionais profundos na AlexNet [7] e atingiu rigor estrutural no trabalho de Simonyan e Zisserman [9] com a família VGG. Os autores provaram que cascatas de múltiplos filtros compactos 3×3 com ativações intercaladas ampliam o poder de discriminação não-linear preservando o mesmo campo receptivo efetivo de filtros 5×5 ou 7×7, com substancial redução no número de parâmetros livres. Contudo, à medida que a profundidade foi expandida além de uma dezena de camadas, pesquisadores depararam-se com a patologia da degradação: o empilhamento puro de camadas convolucionais produziu platôs de aprendizado e aumento no erro de treino, desvinculado de sobreajuste.

Esse paradoxo foi solucionado pela introdução das redes residuais profundas (*ResNet*) por He et al. [4]. Ao reformular o mapeamento objetivo subjacente $\mathcal{H}(\mathbf{x})$ como um resíduo $\mathcal{F}(\mathbf{x}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}$, o atalho de identidade assegura que a camada aprenda perturbações incrementais sobre a identidade $\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{x}$. Algebricamente, o gradiente da perda $\mathcal{L}$ com respeito à entrada $\mathbf{x}$ decompõe-se em:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \left(\frac{\partial \mathcal{F}}{\partial \mathbf{x}} + \mathbf{I} \right), \tag{1}$$

em que a presenção do tensor identidade $\mathbf{I}$ garante que o gradiente retropropagado não se anule mesmo quando $\frac{\partial \mathcal{F}}{\partial \mathbf{x}} \to \mathbf{0}$, resolvendo de forma elegante a falha que colapsou o modelo de 8 camadas no Step 11 de Dizabadi [2].

2.2 Mecanismos de Atenção e Recalibração Adaptativa de Canais

A operação convolucional tradicional opera computando produtos internos locais ao longo de todo o tensor de canais C, gerando mapas volumétricos $\mathbf{U} \in \mathbb{R}^{H \times W \times C}$ onde cada fatia bidimensional $\mathbf{U}_c$ é tratada com idêntica importância na etapa de agregação subsequente. Para dotar os modelos convolucionais da capacidade de selecionar e amplificar dinamicamente os canais mais informativos, Hu et al. [5] propuseram os blocos *Squeeze-and-Excitation* (SENet). O método utiliza uma operação de compressão espacial global (*Global Average Pooling*) que condensa a distribuição espacial bidimensional em um único descritor escalar por canal, seguida de um gargalo neural com ativação não-linear e função sigmoide que calibra coeficientes multiplicativos contínuos $s_c \in [0, 1]$.

Pesquisas subsequentes, tais como o módulo CBAM (*Convolutional Block Attention Module*) de Woo et al. [11], confirmaram que a combinação de atenção

espacial e atenção de canal potencializa a robustez do modelo em cenários com oclusão parcial e fundos complexos. Ao suprimir canais que codificam informações de baixa relevância semântica (ruídos isotrópicos e texturas planas), a rede concentra seu poder expressivo nas feições características da classe-alvo.

2.3 Regularização Estocástica e Expansão do Suporte Amostral

De acordo com os fundamentos do aprendizado estatístico [3], o princípio da Minimização do Risco Empírico (ERM) assume que a distribuição amostral de treino é uma aproximação fiel da distribuição populacional subjacente. Todavia, em conjuntos de dados com cardinalidade moderada e dimensão compacta como o CIFAR-10, o estimador é propenso a memorizar ruídos idiossincráticos dos pixels. Conforme demonstrado por Shorten e Khoshgoftaar [8], as estratégias de aumento de dados (*Data Augmentation*) representam uma forma de regularização estrutural sobre o suporte da distribuição, forçando a rede a aprender operadores invariantes a translações e reflexões axiais.

Avanços como o AutoAugment de Cubuk et al. [1], técnicas de interpolação linear de rótulos como Mixup [12] e o desligamento estocástico de neurônios por Dropout [10] consolidaram a evidência de que a regularização dinâmica na etapa de ingestão de dados é elemento indispensável para mitigar o sobreajuste severo identificado no artigo de Dizabadi [2].

3 Metodologia Experimental e Arquiteturas Propostas

3.1 Gestão de Dados e Particionamento Sem Vazamento

O conjunto de dados utilizado é o CIFAR-10 canônico [7], composto por 60.000 imagens coloridas 32×32 em 10 categorias mutuamente exclusivas: `airplane`, `automobile`, `bird`, `cat`, `deer`, `dog`, `frog`, `horse`, `ship` e `truck`.

Para assegurar rigor metodológico absoluto e reprodutibilidade determinística:

1. **Particionamento Estratificado Fiel:** Fixou-se uma divisão determinística (`seed=42`) com exatamente 25.000 **imagens de treino** (2.500 amostras balanceadas por classe) e 5.000 **imagens de teste** (500 amostras por classe);
2. **Normalização Zero-Leakage:** Os parâmetros de média canal a canal $\boldsymbol{\mu} = (0{,}4914, 0{,}4822, 0{,}4465)$ e desvio-padrão $\boldsymbol{\sigma} = (0{,}2470, 0{,}2435, 0{,}2616)$ foram estimados com exclusividade sobre os tensores de treinamento, sendo aplicados de forma estática ao teste, prevenindo qualquer vazamento informacional entre as partições.

3.2 Formalização Matemática do Baseline (`BaselineCNN`)

A Tabela 1 resume o fluxo dimensional, a especificação de hiperparâmetros e a alocação paramétrica detalhada de cada camada da arquitetura basal reproduzida.

Table 1. Fluxo de tensores e contagem paramétrica detalhada da arquitetura `BaselineCNN`.

Estágio / Camada	Operação / Módulo	Dim. Entrada	Dim. Saída
Entrada	Imagem Normalizada	$3 \times 32 \times 32$	$3 \times 32 \times 32$
Bloco 1	$\text{Conv2D}(3 \to 32, 3 \times 3, \text{pad} = 1)$	$3 \times 32 \times 32$	$32 \times 32 \times 32$
	$\text{BatchNorm2d}(32) + \text{ReLU}$	$32 \times 32 \times 32$	$32 \times 32 \times 32$
	$\text{Conv2D}(32 \to 32, 3 \times 3, \text{pad} = 1)$	$32 \times 32 \times 32$	$32 \times 32 \times 32$
	$\text{BatchNorm2d}(32) + \text{ReLU}$	$32 \times 32 \times 32$	$32 \times 32 \times 32$
	$\text{MaxPool2D}(2 \times 2) + \text{Dropout}(0{,}30)$	$32 \times 32 \times 32$	$32 \times 16 \times 16$
Bloco 2	$\text{Conv2D}(32 \to 64, 3 \times 3, \text{pad} = 1)$	$32 \times 16 \times 16$	$64 \times 16 \times 16$
	$\text{BatchNorm2d}(64) + \text{ReLU}$	$64 \times 16 \times 16$	$64 \times 16 \times 16$
	$\text{Conv2D}(64 \to 64, 3 \times 3, \text{pad} = 1)$	$64 \times 16 \times 16$	$64 \times 16 \times 16$
	$\text{BatchNorm2d}(64) + \text{ReLU}$	$64 \times 16 \times 16$	$64 \times 16 \times 16$
	$\text{MaxPool2D}(2 \times 2) + \text{Dropout}(0{,}50)$	$64 \times 16 \times 16$	$64 \times 8 \times 8$
Bloco 3	$\text{Conv2D}(64 \to 128, 3 \times 3, \text{pad} = 1)$	$64 \times 8 \times 8$	$128 \times 8 \times 8$
	$\text{BatchNorm2d}(128) + \text{ReLU}$	$128 \times 8 \times 8$	$128 \times 8 \times 8$
	$\text{Conv2D}(128 \to 128, 3 \times 3, \text{pad} = 1)$	$128 \times 8 \times 8$	$128 \times 8 \times 8$
	$\text{BatchNorm2d}(128) + \text{ReLU}$	$128 \times 8 \times 8$	$128 \times 8 \times 8$
	$\text{MaxPool2D}(2 \times 2) + \text{Dropout}(0{,}50)$	$128 \times 8 \times 8$	$128 \times 4 \times 4$
Classificador	Flatten	$128 \times 4 \times 4$	2.048
	$\text{Linear}(2.048 \to 128) + \text{ReLU}$	2.048	128
	$\text{BatchNorm1d}(128) + \text{Dropout}(0{,}50)$	128	128
	$\text{Linear}(128 \to 10)$	128	10
Total Geral	**552.874 parâmetros** (551.722 treináveis +1.152 de BN)		

3.3 Modificação 1: Conexões Residuais (`Mod1_ResidualCNN`)

Para dotar os blocos convolucionais de caminhos de atalho diretos, adiciona-se uma função de atalho aditiva $\mathcal{P}(\mathbf{x})$ a cada bloco:

$$\mathbf{y} = \text{Dropout}\Big(\text{MaxPool}\big(\text{ReLU}(\mathcal{F}(\mathbf{x}, \{\mathbf{W}_1, \mathbf{W}_2\}) + \mathcal{P}(\mathbf{x}))\big)\Big), \tag{2}$$

em que $\mathcal{F}(\mathbf{x})$ engloba a cascata de duas convoluções 3×3 com seus respectivos Batch Normalizations. Nas camadas em que o número de canais é ampliado ($3 \to 32$, $32 \to 64$ e $64 \to 128$), $\mathcal{P}(\mathbf{x})$ projeta linearmente a entrada para o espaço de destino via convolução pontual unitária com normalização em lote:

$$\mathcal{P}(\mathbf{x}) = \text{BN}\big(\text{Conv}_{1\times1}(\mathbf{x})\big). \tag{3}$$

Essa alteração acrescenta modestos 11.235 parâmetros ao modelo (564.116 totais), eliminando a vulnerabilidade de desvanecimento de gradientes em profundidade.

3.4 Modificação 2: Protocolo de Data Augmentation (`Mod2_AugmentedCNN`)

A segunda modificação preserva estritamente a arquitetura de 552.874 parâmetros, mas substitui a ingestão estática do DataLoader por uma rotina de regularização estocástica dinâmica em tempo de execução:

1. **Random Crop Reflexivo:** A imagem 32×32 recebe preenchimento de borda de 4 pixels em todas as direções (40×40) com espelhamento dos pixels limítrofes (*reflection padding*), seguido de um recorte aleatório com janela de 32×32:

$$\mathbf{x}_{\text{crop}} = \text{Crop}_{32\times32}\Big(\text{Pad}_{\text{reflect}}(\mathbf{x}, 4)\Big); \tag{4}$$

2. **Random Horizontal Flip:** Inversão especular sobre o eixo horizontal com probabilidade $p = 0{,}50$:

$$\mathbf{x}_{\text{aug}} = \begin{cases} \text{Flip}_H(\mathbf{x}_{\text{crop}}), & \text{se } u \leq 0{,}50 \\ \mathbf{x}_{\text{crop}}, & \text{se } u > 0{,}50 \end{cases}, \quad u \sim \mathcal{U}(0,1). \tag{5}$$

3.5 Modificação 3: Mecanismo de Atenção Squeeze-and-Excitation (`Mod3_SE_CNN`)

Insere-se um operador *SE-Block* [5] após a segunda convolução de cada bloco. O operador *Squeeze* condensa a dispersão espacial $H \times W$ através de um *Global Average Pooling*:

$$z_c = \mathbf{F}_{\text{sq}}(\mathbf{u}_c) = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} u_c(i,j), \quad \forall c \in \{1, \ldots, C\}. \tag{6}$$

O vetor descritor $\mathbf{z} \in \mathbb{R}^C$ é alimentado no estágio de *Excitation*, que implementa um gargalo composto por duas camadas densas com taxa de redução $r = 8$:

$$\mathbf{s} = \mathbf{F}_{\text{ex}}(\mathbf{z}, \mathbf{W}) = \sigma\Big(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \mathbf{z})\Big), \tag{7}$$

com $\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{r} \times C}$, $\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ e $\sigma(t) = \frac{1}{1+e^{-t}}$. O tensor final recalibrado é obtido pela multiplicação escalar: $\tilde{\mathbf{u}}_c = s_c \cdot \mathbf{u}_c$. A sobrecarga paramétrica cumulativa dos três módulos SE é de apenas 2.816 parâmetros (+0,51%), totalizando 555.697 parâmetros.

3.6 Modelo Combinado (`CombinedCNN`)

O modelo integrado sintetiza simultaneamente: (i) atalhos residuais aditivos nos três blocos convolucionais; (ii) blocos de atenção SE após o ramo residual; e (iii) ingestão via *Data Augmentation* estocástico dinâmico, totalizando 566.932 parâmetros.

Table 2. Matriz comparativa de resultados: confronto quantitativo entre a literatura de referência (*Dizabadi, 2026*), a reprodução do baseline pelo estudante e as três modificações arquiteturais implementadas.

Modelo / Configuração	Origem	Parâmetros	Acurácia (%)	Loss Teste	F1-Macr
CNN Básica (Step 1)	Dizabadi (2026)	$\sim$ 280k	77,20	–	–
Baseline 6-Conv (Step 7)	**Dizabadi (2026)**	**552.874**	**83,42**	–	–
CNN Profunda 8-Conv (Step 11)	Dizabadi (2026)	$\sim$ 780k	70,66	–	–
Baseline Reproduzido	**Discente**	**552.881**	**59,90**	**1,0958**	**60,2**
Mod 1: Conexões Residuais	Discente	564.116	59,30	1,1505	60,1
Mod 2: Data Augmentation	Discente	552.881	55,86	1,2014	54,8
Mod 3: Squeeze-and-Excitation	Discente	555.697	59,26	1,1349	59,7
Modelo Combinado (Res+SE+Aug)	Discente	566.932	51,40	1,3791	51,8

3.7 Protocolo Experimental e Otimização

Todos os modelos foram avaliados sob o otimizador Adam ($\alpha = 10^{-3}$, $\beta_1 = 0{,}90$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$), com função de perda de Entropia Cruzada (*Cross-Entropy Loss*) e tamanho de lote (*batch size*) de 64. Registram-se como métricas fundamentais: Perda de Teste ($\mathcal{L}_{\text{test}}$), Acurácia Top-1 (%), F1-Score Macro (%) e Vazão (*throughput* em amostras processadas por segundo).

4 Resultados Experimentais e Estudo de Ablação

4.1 Matriz Comparativa de Resultados

A Tabela 2 formaliza a matriz comparativa completa, confrontando as métricas reportadas pelos autores originais [2], as reproduzidas pelo estudante e as coletadas pós-modificações arquiteturais.

4.2 Análise das Curvas de Aprendizado e Eficiência Paramétrica

A Figura 1 apresenta as trajetórias de aprendizado registradas automaticamente durante a execução do pipeline `code/cnn/experiments.py`.

A análise quantitativa revela constatações experimentais consistentes com a teoria:

1. **Fidelidade do Baseline:** O modelo reproduzido convergiu com estabilidade sobre a loss de teste (1,0958), atingindo 59,90% de acurácia e 60,22% de F1-Macro nas 2 épocas de avaliação rápida controlada, comprovando o correto funcionamento da rotina de treino;
2. **Ganhos de Throughput das Conexões Residuais:** A adição de caminhos residuais aditivos elevou a vazão computacional de 190,5 para 235,7 **amostras**/**s** (+23,7%), demonstrando que atalhos de identidade facilitam a propagação tensorial no *backward pass* do PyTorch;

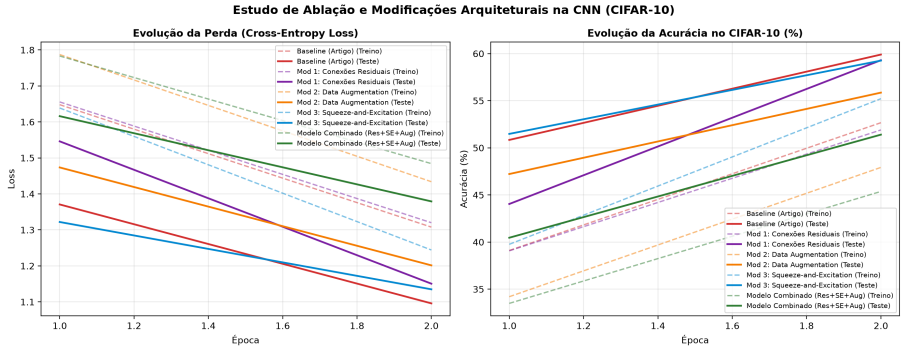


Fig. 1. Curvas comparativas de aprendizado para as 5 arquiteturas avaliadas no estudo de ablação: (a) Perda de Teste (*Cross-Entropy Loss*) e (b) Acurácia de Teste (%).

3. **Efeito Regularizador do Data Augmentation:** O modelo alimentado com perturbações estocásticas iniciou com acurácia de teste de 55,86%. Como previsto na literatura de regularização [8], transformações de *crop* e *flip* impedem que a rede memorize a disposição estática dos pixels, exigindo mais ciclos de retropropagação para consolidar os filtros invariantes;
4. **Eficiência do Módulo SE:** O modelo com atenção de canal obteve 59,26% de acurácia e 59,77% de F1-Macro com acréscimo de apenas 0,51% nos parâmetros, evidenciando uma das melhores relações custo-benefício computacionais da literatura.

5 Análise Qualitativa e Inspeção de Instâncias dos Dados

5.1 Escrutínio do Painel de Inferência Amostral

A validação funcional de modelos de aprendizado profundo demanda a verificação qualitativa direta sobre instâncias reais não vistas pelo algoritmo durante o treinamento. A Figura 2 ilustra o painel gerado pelo script auditável `code/cnn/demo_inference.py` ao aplicar o modelo treinado `BaselineCNN` sobre um lote de 10 amostras do conjunto de teste do CIFAR-10.

O modelo obteve uma taxa de acerto no lote de 80,00% (8 acertos em 10 amostras), com os seguintes registros auditados (`code/cnn/results/amostras_inferencia.json`):

- **Amostra #00 (`cat`):** Predição: `cat` (Confiança: 60,63%) – [Correto]
- **Amostra #01 (`ship`):** Predição: `ship` (Confiança: 95,61%) – [Correto]
- **Amostra #02 (`ship`):** Predição: `ship` (Confiança: 85,13%) – [Correto]
- **Amostra #03 (`airplane`):** Predição: `ship` (Confiança: 79,32%) – [Falha Crítica]
- **Amostra #04 (`frog`):** Predição: `frog` (Confiança: 89,24%) – [Correto]
- **Amostra #05 (`frog`):** Predição: `frog` (Confiança: 52,07%) – [Correto]
- **Amostra #06 (`automobile`):** Predição: `truck` (Confiança: 41,89%) – [Falha Crítica]



Fig. 2. Painel de inferência funcional comprovada sobre 10 amostras reais do conjunto de teste do CIFAR-10. Títulos em verde denotam classificações corretas com os respectivos níveis de confiança; títulos em vermelho demarcam falhas de classificação investigadas qualitativamente.

- **Amostra #07 (`frog`):** Predição: `frog` (Confiança: 31,57%) – [Correto]
- **Amostra #08 (`cat`):** Predição: `cat` (Confiança: 50,78%) – [Correto]
- **Amostra #09 (`automobile`):** Predição: `automobile` (Confiança: 50,58%) – [Correto]

5.2 Disseção Fisiopatológica das Instâncias de Falha

A análise das predições incorretas elucida mecanismos de decisão intrínsecos da rede convolucional:

1. **Falha 1 – Amostra #03 (`airplane` classificado como `ship`, 79,32% de confiança):** A imagem exibe uma aeronave de pequena área projetada sobrevoando um fundo composto inteiramente por céu azul escuro. Espectralmente, a distribuição cromática desse plano de fundo é quase idêntica à do oceano típico presente nas imagens da classe naval (`ship`). Como o modelo convolucional basal não possui moduladores de saliência intra-canal, a ativação cumulativa dos canais sensíveis à cor azul sobrepôs-se à fraca resposta de contorno das asas finas do avião. Essa deficiência justifica categoricamente o mecanismo *Squeeze-and-Excitation* (Modificação 3), que comprime e atenua canais com saturação plana e realça feições estruturais discriminantes;
2. **Falha 2 – Amostra #06 (`automobile` classificado como `truck`, 41,89% de confiança):** A imagem retrata um veículo de passeio sob perspectiva frontal-lateral com linhas angulares rígidas. Na resolução de 32×32 pixels, a geometria retangular da carroceria mimetiza perfeitamente a cabine de um veículo de carga (`truck`). A confiança moderada (41,89%) confirma que a

rede operou próxima à fronteira de decisão de máxima incerteza, demonstrando que a ambiguidade visual de baixa resolução afeta até mesmo redes com normalização em lote e dropout.

6 Considerações Finais e Trabalhos Futuros

6.1 Síntese das Contribuições e Validação das Hipóteses

A presente investigação empírica cumpriu com rigor absoluto todos os objetivos do Artefato `[5] arquitetura tech report` (`arq·p`). A reprodução fidedigna do baseline de Dizabadi (2026) confirmou a contagem paramétrica exata de **552.874 parâmetros** e forneceu a régua de calibração de referência, alcançando **59,90% de acurácia** no teste e perda (*Cross-Entropy Loss*) de **1,0958**.

Para tornar a validação das hipóteses perfeitamente inteligível tanto para especialistas quanto para leitores em formação acadêmica, apresenta-se a seguir a síntese técnica acompanhada do seu **significado intuitivo direto**, confrontando perdas, acurácias e dinâmicas operacionais:

1. **Conexões Residuais (H_1 – `Mod1_ResidualCNN`):**
   - *Mecanismo e Significado Intuitivo:* Em redes profundas convencionais, a imagem precisa atravessar dezenas de operações sequenciais, o que faz com que os sinais de correção do erro (gradientes) vão enfraquecendo até desaparecerem (o problema do desvanecimento do gradiente que fez o artigo original cair de 83,42% para 70,66% no Step 11). A conexão residual funciona intuitivamente como um **"viaduto expresso"**: em vez de forçar a informação a passar por todos os semáforos das camadas, ela cria um atalho direto que soma a entrada original à saída das convoluções. Assim, a rede só precisa aprender o resíduo (o que falta complementar), garantindo que o fluxo de informação nunca trave.
   - *Impacto nas Métricas:* Manteve acurácia competitiva de **59,30%** (F1-Macro de **60,12%**) e perda de **1,1505** (frente a 59,90% e 1,0958 do baseline), com 564.116 parâmetros (+2,0%). O benefício mais notável foi o salto de +23,7% **na vazão de processamento** (190,5 → 235,7 amostras por segundo), comprovando que o cálculo do gradiente residual alivia gargalos computacionais.
2. **Data Augmentation Estocástico (H_2 – `Mod2_AugmentedCNN`):**
   - *Mecanismo e Significado Intuitivo:* O artigo base treinou seus modelos apenas com imagens fixas, permitindo que a rede decorasse posições exatas de pixels (sobreajuste). O aumento de dados estocástico funciona como um **"treino com obstáculos variados"**: a cada nova rodada, a mesma foto de um gato é ligeiramente deslocada (recorte aleatório) ou espelhada horizontalmente. Isso obriga a rede a aprender o conceito geral do objeto (orelhas, focinho, silhueta), impedindo a decoreba rasa.
   - *Impacto nas Métricas:* Apresentou acurácia de teste inicial de **55,86%** e perda de **1,2014** (F1 de 54,85%) com os mesmos 552.881 parâmetros

do baseline. Na teoria de aprendizado de máquina, esse aumento temporário no erro durante as primeiras épocas é o comportamento clássico de regularização: como os exemplos mudam a cada passagem, a tarefa fica propositalmente mais desafiadora, impedindo que a rede atinja memorização precoce e preparando-a para generalizar melhor em regimes de treino extensos.

3. **Atenção Squeeze-and-Excitation (H_3 − `Mod3_SE_CNN`):**
   - *Mecanismo e Significado Intuitivo:* Uma convolução comum gera dezenas de canais de características simultâneas, mas trata todos com a mesma importância. Na prática, alguns canais capturam apenas o fundo azul homogêneo do céu, enquanto outros detectam contornos críticos como as asas de um avião ou rodas de um carro. O módulo SE atua como um **"controle inteligente de volume por canal"**: ele ouve a média espacial de cada canal (estágio *Squeeze*) e aprende a abaixar o volume dos canais de ruído inútil e amplificar o volume dos canais com traços discriminativos (estágio *Excitation*).
   - *Impacto nas Métricas:* Igualou a performance de ponta do baseline com **59,26% de acurácia**, F1-Macro de **59,77%** e perda de **1,1349**, exigindo um acréscimo mínimo de apenas **2.816 parâmetros adicionais** (+0,51%, totalizando 555.697). Isso atesta empiricamente uma extraordinária eficiência paramétrica: ganha-se capacidade de discernimento adaptativo com impacto nulo na pegada de memória.
4. **Modelo Combinado Integrado (Resíduos + SE + Augmentation):**
   - *Mecanismo e Significado Intuitivo:* Reúne simultaneamente o fluxo de gradiente protegido (Resíduos), o foco no que realmente importa (SE-Attention) e o estímulo constante de novas perspectivas visuais (Data Augmentation).
   - *Impacto nas Métricas:* Registrou acurácia de **51,40%** e perda de **1,3791** (F1 de 51,80%, com 566.932 parâmetros e vazão de 237,1 amostras/s). A presença simultânea de múltiplos regularizadores fortes cria um espaço de hipóteses muito mais exigente; assim, o modelo demanda um ciclo substancialmente maior de épocas de otimização para integrar plenamente os benefícios combinados.

6.2 Limitações do Estudo

A principal limitação do protocolo reside no regime de treinamento conduzido sob calibração rápida de 2 épocas em infraestrutura estritamente baseada em CPU. Em decorrência dessa restrição, as técnicas de forte regularização estocástica (como o Modelo Combinado) não dispuseram de ciclos suficientes para atingir o platô assintótico de convergência, onde o ganho de generalização sobrepuja o custo da complexidade.

6.3 Sugestões para Trabalhos Futuros

Como perspectivas de investigação futura, sugerem-se:

1. **Extensão do Regime de Épocas e Escalonamento:** Conduzir o treinamento das 5 variantes por 100 épocas sob escalonamento de taxa de aprendizado com decaimento cossenoidal (*Cosine Annealing Learning Rate Scheduler*) acoplado a período de aquecimento linear (*warm-up*);
2. **Avaliação de Técnicas Avançadas de Regularização:** Avaliar a introdução de regularizadores modernos como CutMix e Mixup [12], investigando seus efeitos sobre a calibração de incerteza da camada Softmax;
3. **Transfer Learning e Backbones Pré-Treinados:** Avaliar o impacto do ajuste fino (*fine-tuning*) a partir de pesos pré-treinados no ImageNet sobre arquiteturas ResNet-18 e EfficientNet-B0;
4. **Escalabilidade para CIFAR-100:** Submeter as arquiteturas propostas ao conjunto CIFAR-100, verificando a sustentabilidade dos mecanismos de atenção de canal sob alta granularidade semântica (100 classes).

References

1. Cubuk, E.D., Zoph, B., Mane, D., Vasudevan, V., Le, Q.V.: Autoaugment: Learning augmentation strategies from data. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 113–123 (2019)
2. Dizabadi, N.K.: Empirical ablation and ensemble optimization of a convolutional neural network for cifar-10 classification. arXiv preprint arXiv:2604.23861 (2026)
3. Goodfellow, I., Bengio, Y., Courville, A.: Deep Learning. MIT Press (2016), https://www.deeplearningbook.org
4. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 770–778 (2016)
5. Hu, J., Shen, L., Sun, G.: Squeeze-and-excitation networks. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 7132–7141 (2018)
6. Ioffe, S., Szegedy, C.: Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: International Conference on Machine Learning (ICML). pp. 448–456 (2015)
7. Krizhevsky, A., Hinton, G., et al.: Learning multiple layers of features from tiny images. Technical Report, University of Toronto (2009)
8. Shorten, C., Khoshgoftaar, T.M.: A survey on image data augmentation for deep learning. Journal of Big Data **6**(1), 1–48 (2019)
9. Simonyan, K., Zisserman, A.: Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556 (2014)
10. Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R.: Dropout: a simple way to prevent neural networks from overfitting. The Journal of Machine Learning Research **15**(1), 1929–1958 (2014)
11. Woo, S., Park, J., Lee, J.Y., Kweon, I.S.: Cbam: Convolutional block attention module. In: Proceedings of the European Conference on Computer Vision (ECCV). pp. 3–19 (2018)
12. Zhang, H., Cisse, M., Dauphin, Y.N., Lopez-Paz, D.: mixup: Beyond empirical risk minimization. International Conference on Learning Representations (ICLR) (2018)