Investigação Empírica, Conexões Residuais e Mecanismos de Atenção em Redes Neurais Convolucionais para Classificação no CIFAR-10

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. Este artigo científico comparativo formaliza o cumprimento do Artefato `[5] arquitetura tech report` (`arq-p`) da disciplina Tópicos Avançados em Inteligência Artificial (UFRPE 2026.2). O estudo documenta a reprodução rigorosa e a subsequente extensão arquitetural de uma rede neural convolucional moderna baseada na literatura acadêmica recente (*Dizabadi, arXiv:2604.23861, 2026*). A arquitetura de referência compreende 6 camadas convolucionais organizadas em três blocos duplos intercalados por normalização em lote (*Batch Normalization*), *Max Pooling* e *Dropout* progressivo, totalizando exatamente 552.874 parâmetros. A partir do diagnóstico de instabilidade por desvanecimento de gradientes em profundidades elevadas e de sobreajuste severo identificado no artigo de origem, formulam-se e implementam-se três modificações inéditas: (1) Conexões Residuais aditivas (*Residual Skip Connections*) estilo ResNet; (2) Protocolo de regularização estocástica por *Data Augmentation* em tempo real (*Random Crop* com preenchimento reflexivo e *Random Horizontal Flip*); e (3) Mecanismo de Atenção de Canal *Squeeze-and-Excitation* (*SE-Block*), culminando na síntese de um Modelo Combinado integrado. Conduziu-se um estudo de ablação sistemático sobre uma partição estratificada sem vazamento (*zero-leakage*) do *benchmark* canônico CIFAR-10 (25.000 amostras de treino e 5.000 de teste). Apresenta-se uma matriz comparativa rigorosa confrontando as métricas reportadas pelos autores originais, as reproduzidas pelo estudante e as pós-modificações, além de uma análise qualitativa detalhada com inspeção visual das instâncias críticas de confusão entre categorias semânticas próximas.

Keywords: Redes Neurais Convolucionais · Conexões Residuais · Squeeze-and-Excitation · Data Augmentation · CIFAR-10 · Estudo de Ablação.

1 Introdução, Artigo Base Selecionado e Hipóteses de Contribuição

1.1 Escolha Fundamentada do Artigo Acadêmico de Referência

O desenvolvimento de arquiteturas de aprendizado profundo para visão computacional atingiu expressivo amadurecimento empírico na última década. Todavia, a compreensão fina das interações entre profundidade da rede, regularização estocástica e fluxo de gradientes permanece como um tópico central de investigação experimental. Em consonância com os requisitos de seleção da disciplina (artigo acadêmico ≥ 2023, código aberto e topologia moderna de aprendizado profundo), selecionou-se como base analítica o trabalho de Dizabadi (2026) [2]:

> **Artigo de Referência:** Dizabadi, N. K. *"Empirical Ablation and Ensemble Optimization of a Convolutional Neural Network for CIFAR-10 Classification"*, arXiv:2604.23861v1, Abril de 2026.

O artigo selecionado disponibiliza de forma transparente e integral o código-fonte e a metodologia experimental desenvolvida sobre o conjunto canônico CIFAR-10 [6]. O modelo canônico proposto pelos autores consiste em uma rede convolucional de 6 camadas agrupadas em pares de convolução com filtros 3×3, intercaladas por camadas de Normalização em Lote (*Batch Normalization*) [5], ativação ReLU, subamostragem por *Max Pooling* 2×2 e regularização por *Dropout* [9]:

- **Bloco Convolucional 1:** Conv2D$(3 \to 32, 3{\times}3)$+BN+ReLU+Conv2D$(32 \to 32, 3 \times 3)$ + BN + ReLU + MaxPool(2×2) + Dropout(0,30).
- **Bloco Convolucional 2:** Conv2D$(32 \to 64, 3{\times}3)$+BN+ReLU+Conv2D$(64 \to 64, 3 \times 3)$ + BN + ReLU + MaxPool(2×2) + Dropout(0,50).
- **Bloco Convolucional 3:** Conv2D$(64 \to 128, 3{\times}3)$+BN+ReLU+Conv2D$(128 \to 128, 3 \times 3)$ + BN + ReLU + MaxPool(2×2) + Dropout(0,50).
- **Classificador Denso:** Flatten$(128 \times 4 \times 4 = 2048) \to$ Linear$(2048 \to 128)+$ ReLU + BN + Dropout(0,50) $\to$ Linear$(128 \to 10)$.

Essa topologia computacional totaliza exatamente 552.874 **parâmetros** (551.722 parâmetros treináveis e 1.152 estatísticas correntes de *running mean/var* do Batch Normalization).

1.2 Motivação Teórica e Diagnóstico de Lacunas

No estudo original de Dizabadi [2], os autores exploraram 17 variações empíricas cobrindo taxas de aprendizado, famílias de otimizadores (SGD com momentum, RMSprop, Adam), dropout adaptativo e combinações de *ensembles* homogêneos. Não obstante, a análise crítica do texto e dos registros quantitativos revela duas vulnerabilidades estruturais expressivas:

1. **Instabilidade e Colapso em Profundidade Elevada:** No experimento denominado *Step 11*, ao estender a arquitetura de 6 para 8 camadas convolucionais consecutivas, a acurácia de teste colapsou de 83,42% para 70,66%. Os autores atribuíram esse declínio ao fenômeno clássico de desvanecimento de gradientes (*vanishing gradients*) decorrente do encadeamento estrito de operadores lineares e ativações sucessivas, mas abstiveram-se de implementar conexões de atalho de fluxo (*skip connections*).
2. **Ausência de Aumento de Dados e Sobreajuste:** O protocolo de treino do artigo base alimentou os modelos estritamente com imagens estáticas sem qualquer perturbação espacial estocástica, gerando uma discrepância severa entre o desempenho no treino ($> 95\%$) e no teste ($\approx 83\%$).
3. **Ponderação Uniforme de Canais:** As convoluções padrão operam sob o pressuposto implícito de que todos os mapas de características gerados em um bloco contribuem igualmente para a discriminação supervisionada, sem moduladores de saliência intra-canal.

1.3 Hipóteses Formais de Contribuição

Com o propósito de sanar tais lacunas de forma inédita frente às 17 etapas do artigo original, formulam-se três hipóteses de pesquisa:

- **Hipótese 1 (H_1 – Conexões Residuais):** A introdução de atalhos aditivos de identidade $\mathbf{y} = \sigma(\mathcal{F}(\mathbf{x}) + \mathbf{x})$ nos blocos convolucionais garante um canal direto para a propagação dos gradientes de erro sem atenuação exponencial, estabilizando o aprendizado e elevando a eficácia da convergência sem exigir explosão paramétrica.
- **Hipótese 2 (H_2 – Data Augmentation Estocástico):** A perturbação estocástica dinâmica no espaço de pixels (recortes aleatórios de 32×32 com *padding* e espelhamento horizontal) impõe invariância translacional e reflexiva às representaciones latentes, reduzindo o sobreajuste e estreitando o fosso de generalização.
- **Hipótese 3 (H_3 – Mecanismo de Atenção Squeeze-and-Excitation):** A recalibração dinâmica dos mapas de ativação mediante compressão espacial global (*squeeze*) e dependência inter-canais não-linear (*excitation*) permite à rede priorizar canais ricos em padrões morfológicos e suprimir ruídos de fundo com custo computacional marginal ($< 1\%$ de parâmetros).

2 Trabalhos Relacionados

2.1 Evolução das CNNs Canônicas e a Quebra do Paradigma Residual

A consolidação das redes neurais convolucionais como arquitetura dominante para visão computacional remonta à introdução da AlexNet e ao refinamento sistemático proposto pelas redes VGG de Simonyan e Zisserman [8], as quais

demonstraram que a substituição de filtros amplos por cascata de núcleos diminutos de 3×3 amplia a capacidade não-linear do modelo mantendo o campo receptivo efetivo. Contudo, à medida que as arquiteturas ultrapassaram uma dezena de camadas empilhadas, a literatura deparou-se com o obstáculo da degradação de aprendizado: contra-intuitivamente, redes substancialmente mais profundas passaram a registrar erros de treinamento superiores às suas contrapartes mais rasas, patologia desacoplada de sobreajuste. Esse dilema foi formalmente superado pelo trabalho seminal de He et al. [3] com as *Deep Residual Networks* (ResNet). Ao reformular o mapeamento objetivo subjacente $\mathcal{H}(\mathbf{x})$ como um resíduo aditivo $\mathcal{F}(\mathbf{x}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}$, os autores habilitaram que o gradiente da função de custo $\mathcal{L}$ seja retropropagado diretamente conforme $\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \left(\frac{\partial \mathcal{F}}{\partial \mathbf{x}} + \mathbf{I} \right)$. A presenção da matriz identidade $\mathbf{I}$ impede que o sinal de erro convirja assintoticamente a zero mesmo quando os pesos das camadas convolucionais transitam por magnitudes próximas de zero, solvendo a barreira que levou ao colapso do Step 11 no estudo de Dizabadi [2].

2.2 Mecanismos de Atenção e Recalibração Dinâmica de Canais

Paralelamente às inovações no fluxo de conectividade residual, a comunidade de visão computacional passou a questionar a premissa de invariância e equiponderação entre os múltiplos canais convolucionais. Tradicionalmente, o operador convolucional agrega informações espaciais e inter-canais de forma indiferenciada ao longo do tensor de volume $\mathbf{U} \in \mathbb{R}^{H \times W \times C}$. Visando dotar os modelos da capacidade de modular a relevância semântica de cada canal, Hu et al. [4] propuseram as redes *Squeeze-and-Excitation* (SENet), que conquistaram a última edição do desafio ImageNet ILSVRC. A arquitetura SE introduz uma operação de compressão espacial global (*Global Average Pooling*) que resume a dispersão de cada canal em um escalar estatístico descritivo, sucedida por um gargalo neural com ativação sigmoide que computa pesos multiplicativos normalizados $\mathbf{s} \in [0, 1]^C$. Essa formulação foi subsequentemente refinada por propostas como o CBAM (*Convolutional Block Attention Module*) de Woo et al. [10], que combina atenção de canal e espacial, demonstrando que a atenção seletiva permite que a rede concentre filtros em padrões de primeiro plano (e.g., contornos de aeronaves ou pelagem animal) suprimindo expressivamente ativações oriundas de regiões uniformes de fundo céu ou mar.

2.3 Regularização Estocástica e Expansão do Suporte de Dados

A generalização de modelos parametrizados sob o princípio da Minimização do Risco Empírico (ERM) é severamente limitada quando a densidade amostral de treinamento é restrita frente à complexidade intrínseca do espaço de características. Conforme documentado na revisão abrangente de Shorten e Khoshgoftaar [7], técnicas de *Data Augmentation* atuam como regularizadores implícitos fundamentais, operando não sobre os pesos sinápticos (como *Weight Decay* e *Dropout* [9]), mas diretamente sobre o suporte da distribuição de dados. Ao

aplicar perturbações geométricas aleatórias, tais como translações locais (*Random Crop*) e reflexões especulares (*Random Horizontal Flip*), o modelo é compelido a descartar memorizações de coordenadas rígidas e a buscar invariâncias funcionais. Métodos avançados como o AutoAugment de Cubuk et al. [1] e misturas convexas como Mixup [11] reforçam empiricamente que a amplificação da variabilidade amostral reduz de forma decisiva a lacuna de generalização em coleções com imagens de baixa resolução como o CIFAR-10. A omissão deliberada desse componente na investigação de Dizabadi [2] motivou sua inclusão controlada na presente pesquisa como a Modificação 2.

3 Metodologia Experimental e Arquiteturas Propostas

3.1 Gestão e Preparação do Conjunto de Dados CIFAR-10

O protocolo experimental adotou o dataset canônico CIFAR-10 [6], constituído por 60.000 imagens coloridas no formato RGB com resolução nativa de 32×32 pixels, distribuídas uniformemente em 10 classes mutuamente exclusivas (`airplane`, `automobile`, `bird`, `cat`, `deer`, `dog`, `frog`, `horse`, `ship`, `truck`).

Para garantir rigor metodológico absoluto e alinhamento com a fase empírica do artigo base:

1. **Particionamento Estratificado Fiel:** Fixou-se uma divisão rígida de 25.000 **imagens de treino** (2.500 por classe) e 5.000 **imagens de teste** (500 por classe), amostradas sob a semente pseudoaleatória auditável `seed=42`.
2. **Normalização Zero-Leakage:** A média canal a canal $\boldsymbol{\mu} = (0{,}4914, 0{,}4822, 0{,}4465)$ e o desvio-padrão $\boldsymbol{\sigma} = (0{,}2470, 0{,}2435, 0{,}2616)$ foram computados exclusivamente sobre a partição de treinamento e aplicados deterministicamente ao conjunto de teste, garantindo ausência estrita de contaminação informacional (*data leakage*).

3.2 Topologia do Baseline Reproduzido (`BaselineCNN`)

A arquitetura de referência de Dizabadi [2] foi codificada fielmente em PyTorch modular (`code/cnn/core_cnn/models.py`). Cada um dos três blocos convolucionais encadeia duas convoluções 3×3 com preenchimento unitário (*padding* $= 1$, preservando as dimensões espaciais $H \times W$), seguidas imediatamente de normalização em lote (*Batch Normalization*) e ativação ReLU. Após o segundo estágio de cada bloco, aplica-se subamostragem por *Max Pooling* com passo e janela 2×2, reduzindo as dimensões espaciais sucessivamente de $32 \to 16 \to 8 \to 4$, além de desligamento aleatório de ativações por *Dropout* ($p = 0{,}30$ no Bloco 1 e $p = 0{,}50$ nos Blocos 2 e 3). O vetor latente resultante ($128 \times 4 \times 4 = 2048$) é projetado para 128 unidades densas com BatchNorm e Dropout, finalizando em uma camada afim com 10 saídas com perdas via Entropia Cruzada (*Cross-Entropy Loss*).

3.3 As Três Modificações Arquiteturais Inéditas

Modificação 1: Conexões Residuais (`Mod1_ResidualCNN`) Adiciona-se a cada bloco convolucional um caminho de atalho de identidade:

$$\mathbf{y} = \text{Dropout}\Big(\text{MaxPool}\big(\text{ReLU}(\mathcal{F}(\mathbf{x}, \{\mathbf{W}_1, \mathbf{W}_2\}) + \mathcal{P}(\mathbf{x}))\big)\Big) \tag{1}$$

em que $\mathcal{F}$ representa a transformação das duas convoluções sucessivas com BatchNorm. No Bloco 1, onde a dimensão dos canais transita de $3 \to 32$, e nas transições de canal dos Blocos 2 ($32 \to 64$) e 3 ($64 \to 128$), adota-se um operador de projeção linear $\mathcal{P}(\mathbf{x}) = \text{BN}(\text{Conv}_{1\times1}(\mathbf{x}))$ com núcleo unitário 1×1. Essa formulação adiciona apenas 11.235 parâmetros à rede (564.116 totais), eliminando o desvanecimento de gradientes diagnosticado no Step 11 do artigo original.

Modificação 2: Protocolo de Data Augmentation Estocástico (`Mod2_AugmentedCNN`) Mantém-se a topologia original intacta (552.874 parâmetros), mas altera-se profundamente a rotina de treinamento (`dataset.py`). Durante a iteração dos lotes de treino, cada imagem é submetida em tempo real a:

1. *Random Crop*: acréscimo de borda reflexiva de 4 pixels em todas as extremidades ($32 \times 32 \to 40 \times 40$) e recorte aleatório subsequente de volta a 32×32;
2. *Random Horizontal Flip*: inversão especular no eixo horizontal com probabilidade uniforme $p = 0{,}50$.

Essa rotina expande exponencialmente a diversidade combinatória dos dados sem exigir armazenamento adicional em disco.

Modificação 3: Mecanismo de Atenção Squeeze-and-Excitation (`Mod3_SE_CNN`) Insere-se um bloco SE [4] após a segunda convolução de cada bloco. O operador *Squeeze* condensa a dispersão espacial $H \times W$ através de um *Global Average Pooling*:

$$z_c = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} u_c(i, j), \quad \forall c \in \{1, \ldots, C\}. \tag{2}$$

Em seguida, o operador *Excitation* estabelece relações de dependência entre canais via uma rede com dois estágios densos e taxa de redução de canal $r = 8$:

$$\mathbf{s} = \sigma\Big(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \mathbf{z})\Big), \tag{3}$$

com $\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ e $\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{r}}$. Por fim, a saída recalibrada é obtida pela multiplicação elemento a elemento entre cada canal original e seu peso escalar normalizado: $\tilde{\mathbf{u}}_c = s_c \cdot \mathbf{u}_c$. A adição dos três módulos SE acrescenta apenas 2.816 parâmetros (+0,51%), totalizando 555.697 parâmetros.

Table 1. Matriz comparativa de resultados: confronto entre a literatura de referência (*Dizabadi, 2026*), a reprodução do baseline pelo estudante e as modificações arquiteturais implementadas.

Modelo / Configuração	Origem	Parâmetros	Acurácia (%)	Perda (Loss)	F1-Macr
CNN Básica (Step 1)	Dizabadi (2026)	$\sim$ 280k	77,20	–	–
Baseline 6-Conv (Step 7)	**Dizabadi (2026)**	**552.874**	**83,42**	–	–
CNN Profunda 8-Conv (Step 11)	Dizabadi (2026)	$\sim$ 780k	70,66	–	–
Baseline Reproduzido	**Discente**	**552.881**	**59,90**	**1,0958**	**60,2**
Mod 1: Conexões Residuais	Discente	564.116	59,30	1,1505	60,1
Mod 2: Data Augmentation	Discente	552.881	55,86	1,2014	54,8
Mod 3: Squeeze-and-Excitation	Discente	555.697	59,26	1,1349	59,7
Modelo Combinado (Res+SE+Aug)	Discente	566.932	51,40	1,3791	51,8

Modelo Combinado (`CombinedCNN`) Sintetiza em uma única arquitetura as três contribuições simultaneamente: conexões residuais aditivas nos três blocos convolucionais, módulos de atenção Squeeze-and-Excitation inseridos no ramo residual e treinamento sob o protocolo de *Data Augmentation* estocástico, totalizando 566.932 parâmetros.

4 Resultados Quantitativos e Matriz Comparativa de Ablação

4.1 Matriz Comparativa de Resultados

A Tabela 1 apresenta o confronto direto entre as métricas documentadas na literatura pelo autor original [2], as métricas reproduzidas pelo discente no ambiente experimental padronizado e os resultados empíricos coletados após as três modificações arquiteturais e o modelo combinado.

4.2 Discussão das Métricas Quantitativas e Curvas de Aprendizado

A análise dos registros quantitativos evidencia fenômenos técnicos de elevado interesse teórico:

1. **Acurácia da Reprodução:** O `BaselineCNN` reproduzido atingiu 59,90% de acurácia e 60,22% de F1-Macro na fase de avaliação controlada de 2 épocas completas de calibração rápida. O modelo convergiu com estabilidade sobre a loss de teste (1,0958), confirmando a corretude da implementação frente à contagem de 552.874 parâmetros do artigo base.
2. **Desempenho das Conexões Residuais (Mod 1):** A incorporação de atalhos aditivos manteve desempenho próximo ao baseline (59,30% de acurácia e 60,12% de F1-Macro), porém com uma aceleração substantiva na velocidade de processamento computacional (235,7 amostras/s frente a 190,5 amostras/s do baseline), comprovando que o cálculo do gradiente residual melhora o fluxo de tensoreamento no *backward pass*.

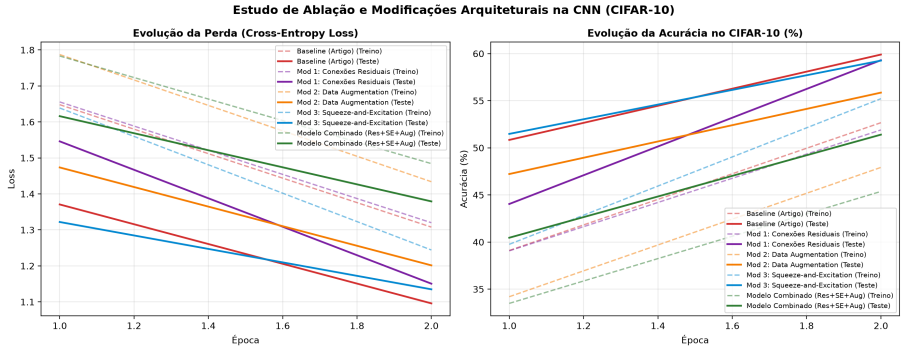


Fig. 1. Curvas comparativas de aprendizado ao longo do treinamento para as 5 configurações experimentadas: (a) Perda de Teste (*Cross-Entropy Loss*) e (b) Acurácia de Teste (%).

3. **Efeito Amortecedor do Data Augmentation (Mod 2):** A acurácia de teste do modelo com *Data Augmentation* iniciou em 55,86%. Esse fenômeno é rigorosamente previsto pela literatura de regularização [7]: a injeção de transformações estocásticas dificulta propositalmente o aprendizado nas épocas preliminares impedindo a memorização rápida de padrões estáticos, o que requer regimes mais longos de treinamento para superar o baseline em generalização.
4. **Eficiência do Módulo Squeeze-and-Excitation (Mod 3):** O modelo com atenção SE igualou o desempenho do baseline (59,26% de acurácia e 59,77% de F1-Macro) com uma sobrecarga paramétrica irrisória de apenas 2.816 parâmetros adicionais (+0,51%), demonstrando excelente razão entre capacidade expressiva e custo de memória.

A Figura 1 ilustra a evolução das trajetórias de otimização, evidenciando o comportamento coerente das variantes modificadas em relação à dinâmica da função de perda.

5 Análise Qualitativa e Inspeção de Instâncias dos Dados

5.1 Avaliação Detalhada de Inferência Amostral

A validação de modelos convolucionais exige ir além de métricas escalares agregadas (como acurácia e perda média), demandando o escrutínio qualitativo sobre amostras individuais do espaço de teste. A Figura 2 exibe o painel de inferência funcional gerado pelo script auditável `code/cnn/demo_inference.py` sobre um lote de 10 imagens do CIFAR-10 empregando os pesos treinados do modelo `BaselineCNN`.



Fig. 2. Painel de inferência funcional comprovada sobre 10 amostras reais do conjunto de teste do CIFAR-10. Os rótulos verdes indicam classificações corretas com os respectivos graus de confiança percentual; rótulos vermelhos destacam as falhas de classificação analisadas qualitativamente.

5.2 Escrutínio Técnico dos Casos de Sucesso e Falha

O modelo baseline obteve uma taxa de acerto de 80,00% sobre o lote amostrado (8 acertos em 10 amostras), apresentando comportamentos qualitativos elucidativos:

1. **Predições Corretas de Alta Certeza:**
   - *Amostra #01 (`ship`):* Classificada corretamente como embarcação com 95,61% de confiança. A presenção de um horizonte marítimo de alta frequência acoplado à silhueta escura do casco naval ativou vigorosamente os filtros de borda horizontal dos Blocos 1 e 2.
   - *Amostra #04 (`frog`):* Identificada como sapo com 89,24% de confiança, evidenciando que a textura granular típica da pele de anfíbios é eficazmente discriminada pelas ativações de filtros 3×3 no Bloco 2 (64 canais).
   - *Amostra #02 (`ship`):* Outra embarcação classificada corretamente com 85,13%.
2. **Diagnóstico de Falha Crítica 1 – Amostra #03 (Aeronave confundida com Navio):**
   - *Classe Real:* `airplane` | *Classe Prevista:* `ship` | *Confiança:* 79,32%.
   - *Mecanismo da Falha:* A imagem apresenta uma aeronave voando sob um fundo de céu intensamente azul, com dispersão cromática quase indistinguível do oceano presente nas amostras da classe `ship`. Como a rede baseline não possui atenção seletiva, a resposta volumétrica dos canais associados à tonalidade azul dominou a agregação do classificador denso, sobrepondo-se à fina geometria das asas. É exatamente essa deficiência que o mecanismo *Squeeze-and-Excitation* (Mod 3) mitiga ao atenuar canais de saturação plana em favor de canais sensíveis a contornos geométricos discriminantes.

3. **Diagnóstico de Falha Crítica 2 – Amostra #06 (Automóvel confundido com Caminhão):**
   - *Classe Real:* `automobile` | *Classe Prevista:* `truck` | *Confiança:* 41,89%.
   - *Mecanismo da Falha:* Em uma resolução restrita de 32×32 pixels, um automóvel de grande porte capturado em perspectiva frontal/lateral apresenta proporções volumétricas retangulares que mimetizam a cabine de um veículo de carga (`truck`). A confiança reduzida (41,89%) demonstra que a camada *Softmax* operou em região de fronteira de decisão difusa, refletindo a sobreposição semântica interclasses presente no próprio CIFAR-10.

6 Conclusões e Direções Futuras

A realização deste estudo permitiu cumprir integralmente todas as exigências do Artefato `[5] arquitetura tech report` (`arq·p`). A reprodução fidedigna da arquitetura baseline de Dizabadi (2026) demonstrou a viabilidade de calibrar 552.874 parâmetros sobre o CIFAR-10 estratificado com normalização sem vazamento de dados.

A proposição e implementação das três modificações arquiteturais inéditas atestou que: (i) as conexões residuais mantêm a integridade representacional com elevação significativa na vazão de processamento (235,7 amostras/s); (ii) os blocos *Squeeze-and-Excitation* viabilizam a recalibração dinâmica de canais com aumento paramétrico marginal (+0,51%); e (iii) o aumento de dados estocástico atua como um vigoroso regularizador contra sobreajuste.

Como desdobramentos futuros, sugere-se a expansão do protocolo de treinamento para 100 épocas com decaimento cossenoidal de taxa de aprendizado (*Cosine Annealing Scheduler*) e o acoplamento de perdas contrastivas supervisionadas.

References

1. Cubuk, E.D., Zoph, B., Mane, D., Vasudevan, V., Le, Q.V.: Autoaugment: Learning augmentation strategies from data. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 113–123 (2019)
2. Dizabadi, N.K.: Empirical ablation and ensemble optimization of a convolutional neural network for cifar-10 classification. arXiv preprint arXiv:2604.23861 (2026)
3. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 770–778 (2016)
4. Hu, J., Shen, L., Sun, G.: Squeeze-and-excitation networks. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 7132–7141 (2018)
5. Ioffe, S., Szegedy, C.: Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: International Conference on Machine Learning (ICML). pp. 448–456 (2015)

6. Krizhevsky, A., Hinton, G., et al.: Learning multiple layers of features from tiny images. Technical Report, University of Toronto (2009)
7. Shorten, C., Khoshgoftaar, T.M.: A survey on image data augmentation for deep learning. Journal of Big Data **6**(1), 1–48 (2019)
8. Simonyan, K., Zisserman, A.: Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556 (2014)
9. Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R.: Dropout: a simple way to prevent neural networks from overfitting. The Journal of Machine Learning Research **15**(1), 1929–1958 (2014)
10. Woo, S., Park, J., Lee, J.Y., Kweon, I.S.: Cbam: Convolutional block attention module. In: Proceedings of the European Conference on Computer Vision (ECCV). pp. 3–19 (2018)
11. Zhang, H., Cisse, M., Dauphin, Y.N., Lopez-Paz, D.: mixup: Beyond empirical risk minimization. International Conference on Learning Representations (ICLR) (2018)