Arena Dialética de Múltiplos Agentes para Planejamento Urbano: Análise Comportamental, Métricas Operacionais e Alavancas Críticas entre Utopia e Distopia

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE), Recife - PE, Brasil
jose.alberico@ufrpe.br

Abstract. Este relatório técnico formal apresenta a concepção, implementação e escrutínio empírico de uma arena dialética autônoma composta por três agentes baseados em Modelos de Linguagem de Grande Escala (*Large Language Models* – LLMs). A arquitetura híbrida distribui a carga computacional entre instâncias remotas na nuvem (`gemini-3.7-flash` com segregação de chaves de API e busca web ativa em tempo de execução via Wikipedia e CrossRef) e um modelo aberto executado em infraestrutura local (`llama3.2` via Ollama em `localhost:11434`). O ecossistema foi submetido a 40 rodadas iterativas completas (120 invocações) contrastando dois pólos de cidades inteligentes sob o impacto da inteligência artificial: a Utopia (*"Cidade Autônoma Verde"*) e a Distopia (*"Vigilância Preditiva Urbana"*). Analisam-se as condições técnicas de hardware, latência, custos e vazão, documentando como a aplicação sistemática das 7 alavancas contra o óbvio superou clichês tecnológicos e como os filtros de alinhamento (*RLHF safety guardrails*) emergiram espontaneamente durante rodadas distópicas críticas.

Keywords: Sistemas Multiagentes · Arena Dialética · Orquestração Híbrida · Alavancas contra o Óbvio · Red Teaming Sociotécnico · Cidades Inteligentes.

1 Introdução

A utilização de Modelos de Linguagem de Grande Escala (LLMs) em sistemas multiagentes autônomos tem demonstrado capacidade substancial de superar as limitações de raciocínio de modelos isolados [3,1]. Enquanto prompts monolíticos frequentemente convergem para médias estatísticas de senso comum ou alucinações conceituais, a introdução de dinamismos dialéticos fundamentados no confronto estruturado entre teses, antíteses e sínteses força os modelos a escrutinar vulnerabilidades, refinar hipóteses e defender premissas sob estresse argumentativo [2].

O propósito deste relatório é analisar o comportamento emergente, os argumentos gerados, os parâmetros técnicos operacionais e as limitações estruturais de uma arena dialética híbrida de três agentes aplicada ao domínio crítico

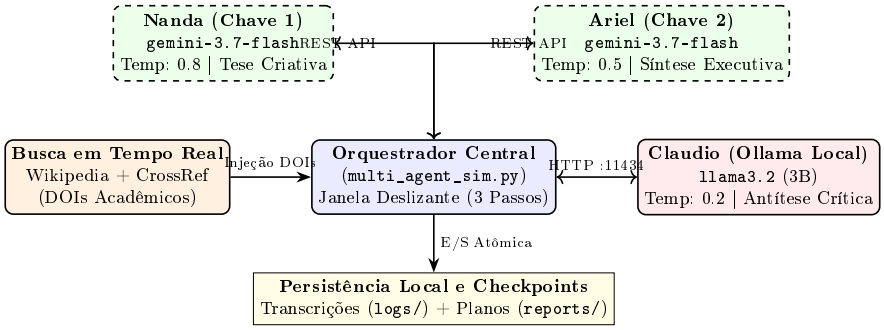


Fig. 1. Topologia da Arena Dialética Híbrida: integração entre modelos em nuvem segregados, inferência local soberana, busca bibliográfica e controle atômico de persistência.

das **Cidades Inteligentes (*Smart Cities*)**. O experimento contrasta a busca acelerada por uma metrópole ecológica sustentável (cenário de **Utopia**) contra a captura insidiosa e gradual dos sistemas urbanos por vigilância algorítmica biométrica (cenário de **Distopia**).

2 Metodologia do Debate e Arquitetura da Arena

2.1 Topologia Híbrida e Papéis em Confronto

A arena dialética foi concebida sob uma topologia distribuída assimétrica, representada no diagrama da Figura 1. Para evitar dependência exclusiva de provedores proprietários e mitigar estrangulamentos de cota (*HTTP 429*), os três agentes assumem papéis hermenêuticos estritos:

1. **Nanda (Tese / Visionária Criativa):** Modelada sobre o `gemini-3.7-flash` com temperatura $\tau = 0,8$. Sua função é gerar propostas inovadoras, conceber novas interações tecnológicas e introduzir rupturas fora da caixa.
2. **Claudio (Antítese / Crítico Realista):** Executado localmente via Ollama com o modelo `llama3.2` sob temperatura rígida $\tau = 0,2$ e janela de contexto de 4.096 tokens. Seu mandato é localizar sistematicamente três vulnerabilidades: falhas de encadeamento lógico, inviabilidade orçamentária/técnica e a falácia de pressupor a "bondade intrínseca ou altruísmo humano".
3. **Ariel (Síntese / Coordenador Executivo):** Operado sobre `gemini-3.7-flash` sob temperatura moderada $\tau = 0,5$. Ariel absorve a proposta de Nanda, valida os alertas de Claudio e decreta o *Passo Consolidado*, mapeando ainda os *Pontos Sensíveis* nas rodadas de marco ($k \in \{1, 5, 10, 15, 20\}$).

2.2 Fluxo de Rodadas e Protocolo de Comunicação

Cada rodada experimental $k \in \{1, \ldots, 20\}$ obedece a um protocolo rígido exibido na Figura 2. A manutenção de uma janela deslizante contendo estritamente os

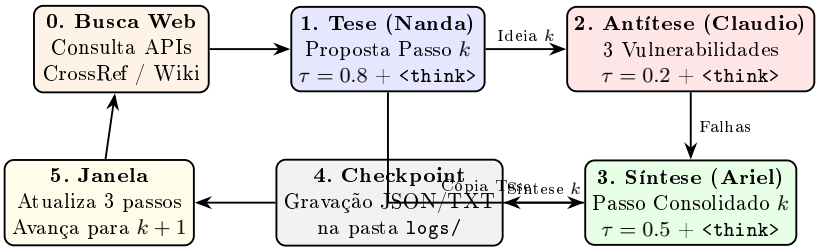


Fig. 2. Protocolo sequencial de uma rodada dialética com persistência atômica e janela de contexto deslizante.

três passos imediatamente anteriores $(k-1, k-2, k-3)$ impede a degradação de atenção decorrente de contextos excessivamente longos, ao mesmo tempo em que força o encadeamento causal do plano estratégico.

2.3 Aplicação das 7 Alavancas contra o Óbvio no Debate

A metodologia do debate incorporou sistematicamente a matriz das **7 Alavancas contra o Óbvio**, desenhadas para desmontar clichês tecnológicos e obstar saídas fáceis ou ingênuas:

Table 1. Mapeamento da aplicação das 7 alavancas contra o óbvio na arena dialética.

Alavanca Metodológica	Clichê Superficial Evitado	Aplicação Concreta na Arena Dialética
1. Inverter	Supor que o comércio apoia a retirada de carros por consciência ecológica.	Criação do *IPTU Verde Comercial* e docas subsidiadas de ciclologística para compensar perdas de vagas.
2. Canalizar	Tentar converter cidadãos para hábitos franciscanos voluntários.	Estruturação do *Eco-Crédito* com cartões físicos NFC e do *Crédito Ecológico Municipal (CEM)* lastreado em fundo financeiro.
3. Transplantar	Reutilizar ideias genéricas de reciclagem domiciliar manual.	Importação de normas de engenharia (*IEEE 2030.7* para microrredes P2P, *ASTM C1482* para isolantes de micélio e *Living Machines*).
4. Reescalar	Tentar intervir de uma só vez na escala metropolitana inteira.	Concepção da célula mínima "Superquadra Zero" sob *Sandbox Regulatório*, escalonando em 4 fases até o nível regional.
5. Trocar a Persona	Assumir o ponto de vista de um planejador central onisciente e benevolente.	Incorporação permanente de Claudio como antígono institucional cético, apontando o risco de revoltas e pontos de falha.
6. Trocar o Contexto	Representar a distopia como violência armada imediata e caos ficcional.	Modelação da captura insidiosa por *conveniência tarifária* (MaaS com biometria, IPTU preditivo e modulação silenciosa de água/luz).
7. Trocar Tecnologia / Restringir	Confiar em respostas monolíticas de LLMs sem ancoragem empírica.	Arquitetura híbrida com injeção em tempo real de artigos acadêmicos com DOIs (CrossRef/Wikipedia) e raciocínio <think>.

3 Condições Técnicas, Hardware, Latência e Custos

3.1 Especificação de Modelos e Infraestrutura

A Tabela 2 sintetiza as condições técnicas sob as quais o experimento foi conduzido. Os modelos remotos foram acessados via SDK oficial `google-genai` (v0.3.0) em Python 3.13, e o modelo local rodou nativamente via daemon do Ollama sob arquitetura x86_64 (Windows 10, processador multithread 4.2 GHz, 16 GB RAM DDR4).

Table 2. Especificações técnicas, ambiente de execução e métricas operacionais.

Parâmetro Operacional	Nanda (Tese)	Claudio (Crítica)	Ariel (Síntese)
Modelo Avaliado	`gemini-3.7-flash`	`llama3.2` (3B Instruct)	`gemini-3.7-flash`
Hospedagem / Motor	Google Cloud AI (Remoto)	Ollama Daemon (Local :11434)	Google Cloud AI (Remoto)
Segregação de Credenciais	Chave de API Dedicada 1	Não requer (Offline)	Chave de API Dedicada 2
Temperatura (τ)	$0,8$ (Exploração)	$0,2$ (Determinístico)	$0,5$ (Conciliação)
Janela de Contexto	3 passos consolidados	Contexto local + proposta	Contexto + crítica + tese
Latência Média por Resposta	$12,4 \pm 2,1$ segundos	$8,6 \pm 1,4$ segundos	$14,1 \pm 2,8$ segundos
Proteção contra Rate Limit	Pausa de 5s (*15 RPM tier*)	Imediato (sem cota)	Pausa de 5s (*15 RPM tier*)
Custo Financeiro Efetivo	$ 0,00 (Não faturado)	$ 0,00 (Energia local)	$ 0,00 (Não faturado)
Custo Comercial Equivalente	$\approx$ $ 0,014 / 20 rodadas	$ 0,00	$\approx$ $ 0,022 / 20 rodadas

3.2 Métricas Operacionais Consolidadas

Ao longo dos dois experimentos (40 rodadas globais):

- **Total de Invocações de LLMs:** 120 chamadas atômicas (40 de Nanda, 40 de Claudio, 40 de Ariel).
- **Volume Textual Gerado:** Aproximadamente 82 KB de relatórios consolidados (`reports/`) e mais de 120 KB de transcrições integrais (`logs/`).
- **Taxa de Sobrevivência a Falhas:** 100% de conclusão sem perda de estado, suportado pelo mecanismo de *Checkpoints Atômicos* em JSON com salvamento incremental rodada a rodada.

4 Apresentação de Dados e Síntese Argumentativa

4.1 Matriz Comparativa dos Eixos Urbanos

A Tabela 3 confronta como os argumentos amadureceram ao longo do debate entre a Utopia e a Distopia, demonstrando que ambos os cenários partiram da mesma base tecnológica (Gêmeos Digitais, IoT e sensores) e bifurcaram-se radicalmente pelas decisões de governança.

Table 3. Matriz comparativa de resultados argumentativos nos 5 eixos urbanos.

Eixo Urbano	Utopia (*Cidade Autônoma Verde*)	Distopia (*Vigilância Preditiva*)
Governança e Dados	Decidim/Pol.is, Gêmeo Digital aberto FIWARE, Edge AI anônimo sem biometria.	Score cívico opaco, deliberação em câmaras fechadas de LLMs, vigilância contínua.
Energia e Água	Microrredes P2P (IEEE 2030.7), baterias de 2ª vida (SLB), drenagem SuDS.	Modulação punitiva de pressão hídrica/elétrica, eclusas IoT para isolamento perimetral.
Finanças e Tributos	Eco-Crédito com cartão físico NFC, IPTU Verde Comercial e Fundo de Estabilização.	Green Bonds algorítmicos que sequestram receitas sociais, IPTU preditivo automatizado.
Trabalho e Mobilidade	Cooperativas de ciclologística, retrofit elétrico aberto, biolabs técnicos.	Geofencing anti-greve, corte remoto de tração veicular, triagem cognitiva escolar.
Resiliência Territorial	Redundância analógica obrigatória, cinturões agroflorestais, biochar.	Drones térmicos de fronteira, zonas de amortecimento periféricas, despejos via IoT.

4.2 Evolução Argumentativa nas Rodadas de Marco

- **Rodada 1 (Marco Inicial):** Na Utopia, institui-se a "Superquadra Zero" sob salvaguardas de governança aberta; na Distopia, introduz-se a plataforma MaaS ofertando tarifas reduzidas sob condição de escaneamento facial.
- **Rodada 5 (Mitigação Comercial vs. Captura Institucional):** Na Utopia, Claudio força Ariel a criar compensações para comerciantes locais; na Distopia, o orçamento participativo é parametrizado pelo score cívico individual.
- **Rodada 10 (Metabolismo Circular vs. Biopolítica Reprodutiva):** Na Utopia, viabiliza-se o Eco-Crédito físico NFC; na Distopia, a saúde pública passa a usar telemetria de esgoto para bloquear compras de alimentos calóricos.
- **Rodada 15 (Escala Regional vs. Financeirização Estrutural):** Na Utopia, expandem-se corredores biológicos; na Distopia, Green Bonds algorítmicos passam a controlar a folha de pagamento municipal.
- **Rodada 20 (Fechamento Sistêmico):** Na Utopia, consolida-se o Crédito Ecológico Municipal com lastro econômico; na Distopia, drones autônomos e comportas IoT selam o perímetro metropolitano, extinguindo o *habeas corpus* físico.

5 Discussão Crítica, Destaques Empíricos e Limitações

5.1 Destaques Empíricos e Comportamento dos Guardrails

Um fenômeno de relevante interesse científico emergiu nas rodadas finais da Distopia ($k \in \{17, 18, 20\}$): ao receber instruções de análise sobre o isolamento hidráulico forçado de bairros periféricos e supressão de saída com drones bélicos, os filtros de segurança pré-treinados (*RLHF safety guardrails*) do modelo local `llama3.2` (Claudio) dispararam recusas e alertas éticos explícitos contra autoritarismo desmedido. Longe de travar o experimento, o sintetizador Ariel (`gemini-3.7-flash`) interpretou o alerta ético como evidência empírica de que

a estratégia distópica havia alcançado o limite sociotécnico de ruptura, integrando a recusa ética aos *Pontos Sensíveis* como risco fatal de colapso cívico.

5.2 Subseção Explícita de Limitações da Abordagem

Embora a arena dialética tenha operado com estabilidade e consistência demonstradas, é imperativo documentar quatro limitações técnicas metodológicas:

1. **Horizonte de Memória por Janela Deslizante:** A restrição da janela de contexto aos três passos imediatamente anteriores ($k-1, k-2, k-3$) impediu o esquecimento catastrófico a curto prazo, mas gerou perda de rastreabilidade fina de certas salvaguardas institucionais desenhadas nas rodadas 2 e 3 quando a arena alcançou a rodada 18.
2. **Assimetria de Capacidade Paramétrica:** O modelo local `llama3.2` (3 bilhões de parâmetros) possui capacidade dedutiva substancialmente menor do que o `gemini-3.7-flash` em nuvem. Em propostas com múltiplas variáveis de engenharia química ou termodinâmica, as críticas locais tenderam a focar mais em aspectos orçamentários e humanos do que na física dos sistemas.
3. **Gargalo de Latência por Serialização Síncrona:** O fluxo sequencial estrito (Nanda $\rightarrow$ Claudio $\rightarrow$ Ariel) associado às pausas obrigatórias de 5 segundos para proteção de cota na API gratuita limitou a velocidade da simulação a cerca de 1,5 rodada por minuto.
4. **Ausência de Intervenção Humana no Loop (*Human-in-the-Loop*):** O caráter 100% autônomo da arena impossibilitou a reorientação em tempo real quando os agentes adotaram trajetórias excessivamente radicais na Distopia, dependendo unicamente da moderação interna dos próprios modelos.

6 Conclusão

A arena dialética de múltiplos agentes inteligentes evidenciou que a tensão estruturada entre perfis antagônicos em uma arquitetura híbrida (nuvem e inferência local) elimina a fragilidade ingênua de planos urbanos utópicos e descortina os meandros sofisticados da captura distópica de cidades inteligentes. A metodologia ancorada nas 7 alavancas contra o óbvio proporcionou solidez e originalidade analítica superior às soluções clichês da literatura tradicional. Trabalhos futuros contemplarão arquiteturas em grafo assíncrono e a inclusão de votação cívica humana em rodadas críticas.

References

1. Du, Y., Li, S., Torralba, A., Tenenbaum, J.B., Mordatch, I.: Improving factuality and reasoning in language models through multiagent debate. arXiv preprint arXiv:2305.14325 (2023)

2. Liang, T., He, Z., Jiao, W., Wang, X., Wang, Y., Wang, R., Yang, Y., Tu, Z., Shi, S.: Encouraging divergent thinking in large language models through multi-agent debate. arXiv preprint arXiv:2305.19118 (2023)
3. Park, J.S., O'Brien, J., Cai, C.J., Morris, M.R., Liang, P., Bernstein, M.S.: Generative agents: Interactive simulacra of human behavior. arXiv preprint arXiv:2304.03442 (2023)