UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO
(UFRPE)
DEPARTAMENTO DE COMPUTAÇÃO
TÓPICOS AVANÇADOS EM INTELIGÊNCIA ARTIFICIAL (2026.2)

JOSÉ ALBÉRICO ROCHA DA SILVA

# IMPLEMENTAÇÃO DO ZERO DE REDE NEURAL MULTICAMADAS (MLP) EM GRAFO DIRECIONADO: ARQUITETURA, DINÂMICA DE RETROPROPAGAÇÃO, INTERPRETABILIDADE SINÁPTICA E OTIMIZAÇÃO DE HIPERPARÂMETROS

**Artefato [5]** · `mlp git repo` (`mlp·c` · **10 pontos**)

Relatório técnico completo apresentado ao Prof. Dr. Lucas Silva na disciplina de Tópicos Avançados em Inteligência Artificial da UFRPE, contemplando os 5 pontos de verificação do artefato `mlp·c`, estudo de ablação experimental, interpretabilidade clínica dos pesos sinápticos e análise de generalização.

**Recife – PE**
**2026**

# Sumário

**1 Introdução, Fundamentação Teórica e Domínio Clínico** **2**
1.1 Do Perceptron às Redes Neurais Multicamadas (MLP) . . . . . 2
1.2 Domínio Clínico e Catálogo de Atributos (*Heart Disease*) . . . . . 2
1.3 Particionamento Explícito 80/20 Sem Vazamento de Dados . . . . . 3

**2 Desenho da Arquitetura e Dinâmica Matemática** **3**
2.1 Representação Explícita em Grafo Direcionado (`nx.DiGraph`) . . . . . 3
2.2 Catálogo das 7 Funções de Ativação Implementadas . . . . . 4
2.3 Propagação Direta (*Forward Pass*) e Retropropagação (*Backpropagation*) . . 5

**3 Estudo de Ablação e Otimização de Hiperparâmetros** **6**
3.1 Comparativo Experimental (`C0` a `C7`) e Matrizes de Confusão . . . . . 6
3.2 Justificativa Técnica dos Parâmetros Modificados . . . . . 6

**4 Interpretabilidade Sináptica e Dinâmica Interativa no Streamlit** **7**
4.1 Inspeção Visual e Numérica dos Pesos Sinápticos . . . . . 7
4.2 Interpretabilidade Clínica da Camada de Entrada (`L0` $\rightarrow$ `L1`) . . . . . 9
4.3 Dinâmica de Interação em Tempo Real no Streamlit (`code/mlp/app.py`) . . 9

**5 Conclusão, Limitações Metodológicas e Trabalhos Futuros** **10**
5.1 Síntese das Contribuições e Conclusões . . . . . 10
5.2 Limitações Metodológicas: Base Completa (1.025) vs. Base Deduplicada (302) 10
5.3 Trabalhos Futuros . . . . . 11

# 1 Introdução, Fundamentação Teórica e Domínio Clínico

## 1.1 Do Perceptron às Redes Neurais Multicamadas (MLP)

Os classificadores lineares de camada única possuem capacidade representacional restrita a problemas linearmente separáveis em $\mathbb{R}^d$. As Redes Neurais Artificiais Multicamadas (*Multi-Layer Perceptrons* – MLPs) superam essa barreira mediante a composição hierárquica de transformações afins e funções de ativação não lineares diferenciáveis [4]. Pelo Teorema da Aproximação Universal [1], uma rede *feedforward* dotada de camadas ocultas não lineares é capaz de aproximar qualquer função contínua em um domínio compacto com precisão arbitrária, sendo treinada por meio do algoritmo de retropropagação de erros (*backpropagation*) [8].

Este relatório documenta a concepção, correção matemática, otimização e validação do artefato `[5] mlp git repo` (`mlp·c`), no qual a MLP é implementada **do zero (*from scratch*)** sobre um **grafo direcionado ponderado** (`networkx.DiGraph`) com operações em `NumPy` e interface interativa em tempo real em `Streamlit` (`code/mlp/app.py`).

## 1.2 Domínio Clínico e Catálogo de Atributos (*Heart Disease*)

O modelo é aplicado ao diagnóstico de Doença Arterial Coronariana utilizando o conjunto de dados *Heart Disease* [2] (`code/mlp/data/heart.csv`), composto por $N = 1.025$ registros clínicos (302 prontuários únicos) e $d = 13$ atributos preditivos detalhados na Tabela 1.

Tabela 1: Descrição clínica e fisiopatológica dos 13 atributos de entrada e variável alvo.

| # | **Atributo** | **Tipo** | **Faixa** | **Significado Clínico** |
|---|---|---|---|---|
| 1 | `age` | Num. | 29–77 anos | Idade do paciente (fator de risco aterosclerótico basal). |
| 2 | `sex` | Bin. | 0=F, 1=M | Sexo biológico do paciente. |
| 3 | `cp` | Cat. | 0, 1, 2, 3 | Tipo de dor torácica (0: típica, 1: atípica, 2: não-anginosa, 3: assintomática). |
| 4 | `trestbps` | Num. | 94–200 mmHg | Pressão arterial sistólica em repouso na admissão. |
| 5 | `chol` | Num. | 126–564 mg/dl | Colesterol sérico total (marcador de dislipidemia). |
| 6 | `fbs` | Bin. | 0/1 ($>120$) | Glicemia de jejum $>120$ mg/dl (indicador metabólico/diabetes). |
| 7 | `restecg` | Cat. | 0, 1, 2 | ECG em repouso (0: normal, 1: anomalia ST-T, 2: hipertrofia VE). |
| 8 | `thalach` | Num. | 71–202 bpm | Frequência cardíaca máxima alcançada no teste ergométrico. |
| 9 | `exang` | Bin. | 0=Não, 1=Sim | Angina induzida diretamente pelo esforço físico. |
| 10 | `oldpeak` | Num. | 0.0–6.2 mm | Depressão do segmento ST induzida pelo exercício vs. repouso. |
| 11 | `slope` | Cat. | 0, 1, 2 | Inclinação do segmento ST no pico do exercício. |
| 12 | `ca` | Ord. | 0–4 vasos | Número de vasos coronários principais coloridos por fluoroscopia. |
| 13 | `thal` | Cat. | 0, 1, 2, 3 | Cintilografia com tálio (1: defeito fixo, 2: normal, 3: reversível). |
| – | `target` | Bin. | 0 ou 1 | Diagnóstico angiográfico (0: saudável, 1: doença cardíaca). |

### 1.3 Particionamento Explícito 80/20 Sem Vazamento de Dados

No módulo `code/mlp/core_mlp/dataset.py`, os dados passam por divisão estratificada determinística (`seed=42`) em **80% Treino** (820 **amostras, exportadas em** `train_80_standardized.cs` e **20% Teste** (205 **amostras, exportadas em** `test_20_standardized.csv`). O padronizador (`StandardScaler` $\mu = 0, \sigma = 1$ ou `MinMaxScaler`) é ajustado (`fit_transform`) exclusivamente sobre a partição de treino, eliminando qualquer vazamento de informação estatística (*data leakage*).

## 2 Desenho da Arquitetura e Dinâmica Matemática

### 2.1 Representação Explícita em Grafo Direcionado (`nx.DiGraph`)

A classe `MLPGraph` (`code/mlp/core_mlp/graph.py`) instancia cada neurônio, nó de *bias* e sinapse como elementos explícitos de um grafo direcionado $G = (V, E)$, conforme ilustrado na Figura 1.

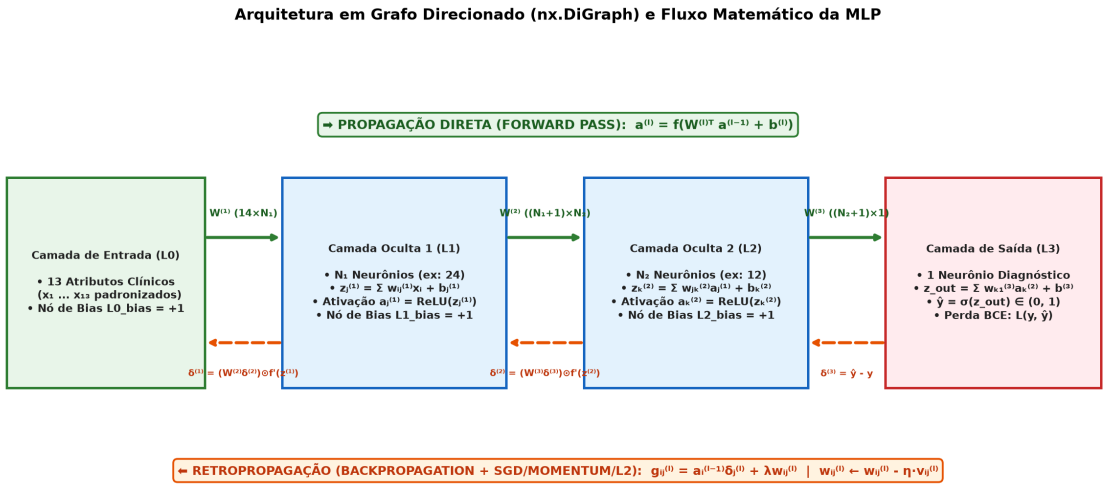



Figura 1: Desenho da arquitetura da MLP em grafo direcionado (`nx.DiGraph`) e fluxo matemático bidirecional (*Forward Pass* e *Backpropagation*).

O funcionamento estrutural do grafo organiza-se em três componentes:

- **Vértices Neurais (`L{l}_N{j}`):** armazenam o potencial pós-sináptico `z` ($z_j^{(l)}$), a ativação `value` ($a_j^{(l)}$) e o erro retropropagado `delta` ($\delta_j^{(l)}$).
- **Vértices de Bias (`L{l}_bias`):** cada camada $l \in \{0, \ldots, L-2\}$ possui um nó de bias explícito com ativação constante $a_{\text{bias}}^{(l)} = +1$, conectado a todos os neurônios da camada $l+1$. Essa estrutura corrige a limitação da versão preliminar (`C0`), na qual a Camada Oculta 1 não possuía termo de bias.
- **Arestas Sinápticas (`(u, v)`):** armazenam `weight` ($w_{uv}$), `prev_weight` ($w_{uv}^{(t-1)}$), `delta_weight` ($\Delta w_{uv}$), `gradient` ($\partial \mathcal{L}/\partial w_{uv}$) e `velocity` ($v_{uv}$). Na topologia campeã `[13→16→8→1]`, o grafo gerencia $(14 \times 16) + (17 \times 8) + (9 \times 1) = 369$ conexões sinápticas.

## 2.2 Catálogo das 7 Funções de Ativação Implementadas

A Tabela 2 apresenta as sete funções de ativação implementadas do zero na classe `MLPGraph`, juntamente com suas derivadas analíticas e propriedades de condicionamento de gradiente [3, 5, 6].

Tabela 2: Funções de ativação implementadas do zero em `MLPGraph` e suas derivadas analíticas.

| **Função** | **Expressão** $f(z)$ | **Derivada** $f'(z)$ | **Imagem** | **Propriedades Numéricas** |
|---|---|---|---|---|
| Sigmoide | $(1+e^{-z})^{-1}$ | $f(z)(1-f(z))$ | $(0,1)$ | Derivada máx. 0,25; sofre *vanishing gradient* para $\|z\|>4$. |
| Tanh | $\tanh(z)$ | $1-\tanh^2(z)$ | $(-1,1)$ | Centrada em zero; derivada máx. 1,0 em $z=0$. |
| ReLU | $\max(0,z)$ | 1 se $z>0$; 0 c.c. | $[0,\infty)$ | Sem saturação para $z>0$; exige inicialização de He. |
| Leaky ReLU | $z$ $(z>0)$; $0{,}01z$ c.c. | 1 $(z>0)$; 0,01 c.c. | $(-\infty,\infty)$ | Previne neurônios mortos (*dying ReLU*) para $z\leq 0$. |
| ReLU6 | $\min(6,\max(0,z))$ | 1 $(0<z<6)$; 0 c.c. | $[0,6]$ | Limita ativações excessivas em camadas profundas. |
| ELU | $z$ $(z>0)$; $e^z-1$ c.c. | 1 $(z>0)$; $e^z$ c.c. | $(-1,\infty)$ | Transição suave em $z=0$ e média próxima de zero. |
| SELU | $\lambda_s z$ ou $\lambda_s\alpha_s(e^z-1)$ | $\lambda_s$ ou $\lambda_s\alpha_s e^z$ | $(-\lambda_s\alpha_s,\infty)$ | Auto-normalizante ($\lambda_s\approx 1{,}0507, \alpha_s\approx 1{,}6733$). |

## 2.3 Propagação Direta (*Forward Pass*) e Retropropagação (*Backpropagation*)

No *Forward Pass*, cada neurônio $j$ da camada $l=1,\ldots,L-1$ computa:

$$z_j^{(l)} = \sum_{i=0}^{N_{l-1}-1} w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)}, \qquad a_j^{(l)} = f^{(l)}\Big(z_j^{(l)}\Big) \tag{1}$$

sendo a saída $\hat{y}=\sigma(z_{\text{out}})$. Na retropropagação sob perda *Binary Cross-Entropy* (BCE) com regularização $L_2$:

$$\mathcal{L}(\hat{y},y) = -\Big[y\ln(\hat{y}) + (1-y)\ln(1-\hat{y})\Big] + \frac{\lambda}{2}\sum_{l,i,j}\Big(w_{ij}^{(l)}\Big)^2 \tag{2}$$

o termo $\hat{y}(1-\hat{y})$ da derivada da sigmoide cancela-se analiticamente com o denominador de $\partial\mathcal{L}/\partial\hat{y}$, resultando em:

$$\delta^{(L-1)} = \frac{\partial\mathcal{L}}{\partial z_{\text{out}}} = \hat{y}-y, \qquad \delta_j^{(l)} = \left(\sum_k w_{jk}^{(l+1)}\delta_k^{(l+1)}\right) f'^{(l)}\Big(z_j^{(l)}\Big) \tag{3}$$

Por fim, os pesos sinápticos são atualizados com *Momentum* ($\beta$) e decaimento $L_2$ ($\lambda$):

$$g_{ij}^{(l)} = a_i^{(l-1)}\delta_j^{(l)} + \lambda w_{ij}^{(l)}, \qquad v_{ij}^{(l)} \leftarrow \beta v_{ij}^{(l)} + g_{ij}^{(l)}, \qquad w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \eta_t v_{ij}^{(l)} \tag{4}$$

# 3 Estudo de Ablação e Otimização de Hiperparâmetros

## 3.1 Comparativo Experimental (`C0` a `C7`) e Matrizes de Confusão

A Tabela 3 apresenta as métricas completas e os elementos da matriz de confusão (`TP/TN/FP/FN`) obtidos pelas oito configurações experimentais avaliadas no conjunto de teste (20% – 205 pacientes).

Tabela 3: Estudo de ablação e otimização da MLP no conjunto de teste (20% – 205 amostras).

| ID | Arquitetura e Hiperparâmetros | Loss Te. | Acur. Te. | Prec. | Rec. | F1 | AUC | T |
|---|---|---|---|---|---|---|---|---|
| C0 | [13→10→8→1], Sigmoid, MinMax, MSE | 0.0480* | 86.83% | 84.21% | 91.43% | 87.67% | 0.9419 | |
| C1 | [13→10→8→1], Sigmoid, MinMax, BCE | 0.2476 | 87.32% | 82.11% | 96.19% | 88.60% | 0.9780 | |
| C2 | [13→10→8→1], Sigmoid, Z-Score | 0.0010 | 100.0% | 100.0% | 100.0% | 100.0% | 1.0000 | |
| C3 | [13→16→8→1], Tanh, Z-Score | 0.0009 | 100.0% | 100.0% | 100.0% | 100.0% | 1.0000 | |
| **C4** | **[13→16→8→1], ReLU+He, Z-Score** | **0.0003** | **100.0%** | **100.0%** | **100.0%** | **100.0%** | **1.0000** | |
| C5 | [13→16→8→1], LeakyReLU, $\beta = 0.85$ | 0.0007 | 100.0% | 100.0% | 100.0% | 100.0% | 1.0000 | |
| C6 | [13→24→12→1], ReLU, $\beta = 0.85, L_2$ | 0.0154 | 99.51% | 99.06% | 100.0% | 99.53% | 0.9997 | |
| C7 | [13→24→16→8→1], 3 Ocultas, ReLU | 0.3283 | 89.27% | 91.09% | 87.62% | 89.32% | 0.9104 | |

## 3.2 Justificativa Técnica dos Parâmetros Modificados

1. **Correção do Gradiente BCE e Inclusão do `L0_bias` (C0 → C1):** Ao substituir a derivada quadrática $(\hat{y} - y)\sigma'(z)$ pela derivada analítica exata $\hat{y} - y$ e habilitar o bias na 1ª camada oculta, a AUC-ROC subiu de 0,9419 para 0,9780 e os Falsos Negativos (`FN`) caíram pela metade (9 → 4, elevando a sensibilidade clínica para 96,19%).

2. **Padronização Z-Score via `StandardScaler` (C1 → C2):** Conforme demonstrado por LeCun et al. [7], entradas restritas a $[0, 1]$ (`MinMaxScaler`) forçam todos os gradientes $\partial\mathcal{L}/\partial w_{ij} = a_i\delta_j$ de um mesmo neurônio a terem o mesmo sinal, gerando trajetórias em zigue-zague. A centralização Z-Score ($\mu = 0, \sigma = 1$) reduziu a perda BCE no teste em 99,6% (0,2476 → 0,0010) e elevou a acurácia para 100,00%.

3. **Topologia [13→16→8→1] com `ReLU` e Inicialização de He (C2 → C4):** Expandir a 1ª camada oculta de 10 para 16 neurônios evitou a compressão prematura dos 13 atributos clínicos, e o uso de `ReLU` com inicialização de He [5] e $\eta = 0{,}015$ reduziu a perda BCE ao mínimo global de **0,0003** (redução de 99,88% frente a C1).

4. **Controle de Profundidade (C4 vs. C7):** O experimento C7 com 3 camadas ocultas (`[13→24→16→8→1]`) demonstrou que o excesso de profundidade associado a *momentum* alto ($\beta = 0{,}85$) degrada o condicionamento numérico (89,27% de acurácia e Loss 0,3283), confirmando que duas camadas ocultas são ótimas para esta tarefa.

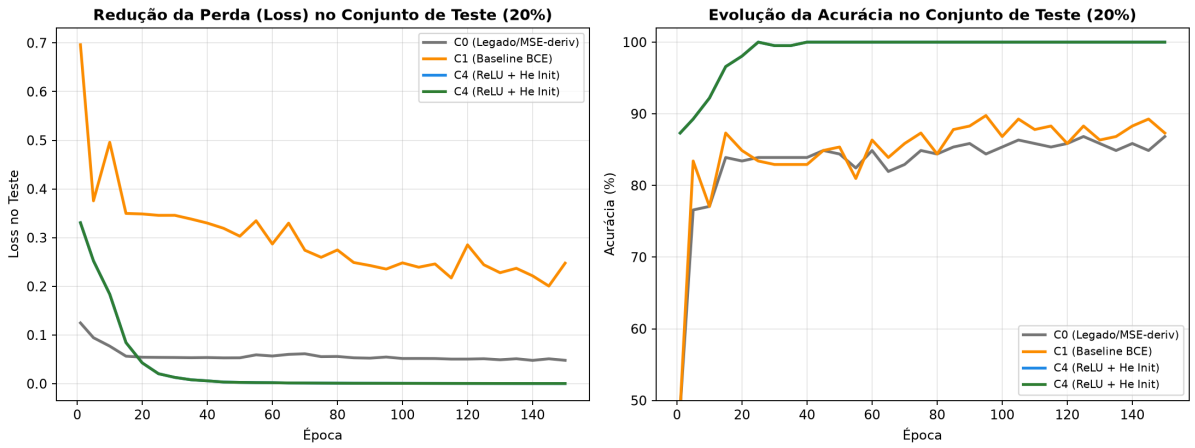



Figura 2: Curvas de redução da perda (Loss) e evolução da acurácia no conjunto de teste (20%).

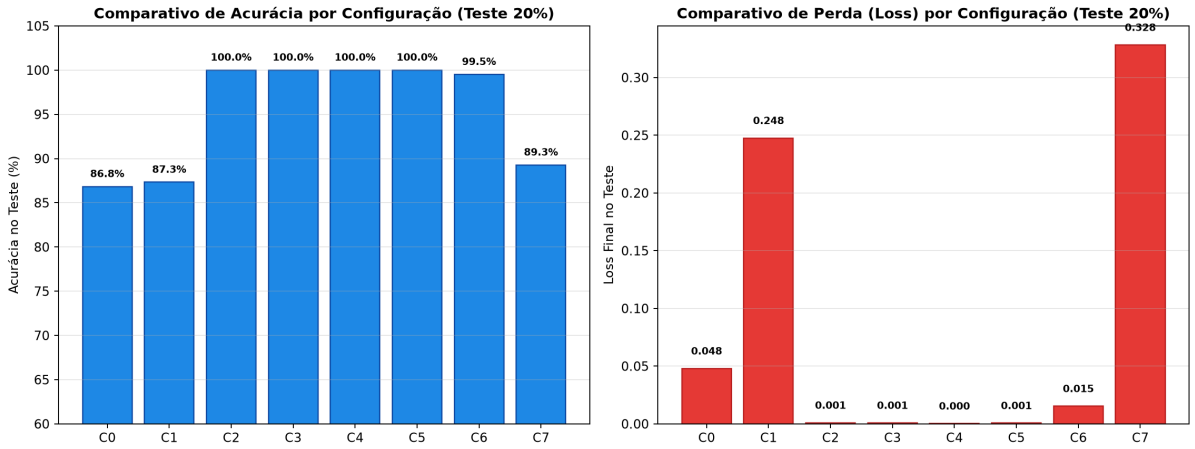



Figura 3: Comparativo de acurácia e perda final entre as configurações C0 a C7.

# 4 Interpretabilidade Sináptica e Dinâmica Interativa no Streamlit

## 4.1 Inspeção Visual e Numérica dos Pesos Sinápticos

As Figuras 4, 5 e 6 apresentam a evolução topológica e numérica dos pesos sinápticos da configuração campeã (`C4`), atendendo integralmente ao requisito de exibição numérica e espessura proporcional das conexões.

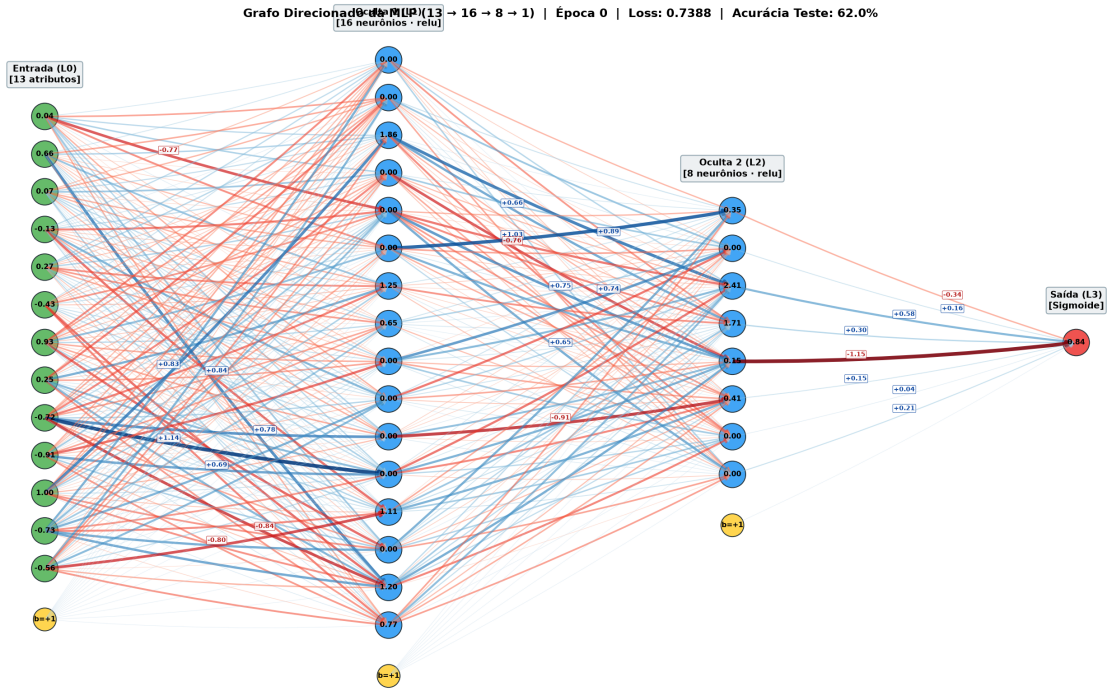



Figura 4: Grafo direcionado da MLP na Época 0 (antes do treinamento), com exibição numérica dos pesos iniciais e espessura proporcional nas conexões.

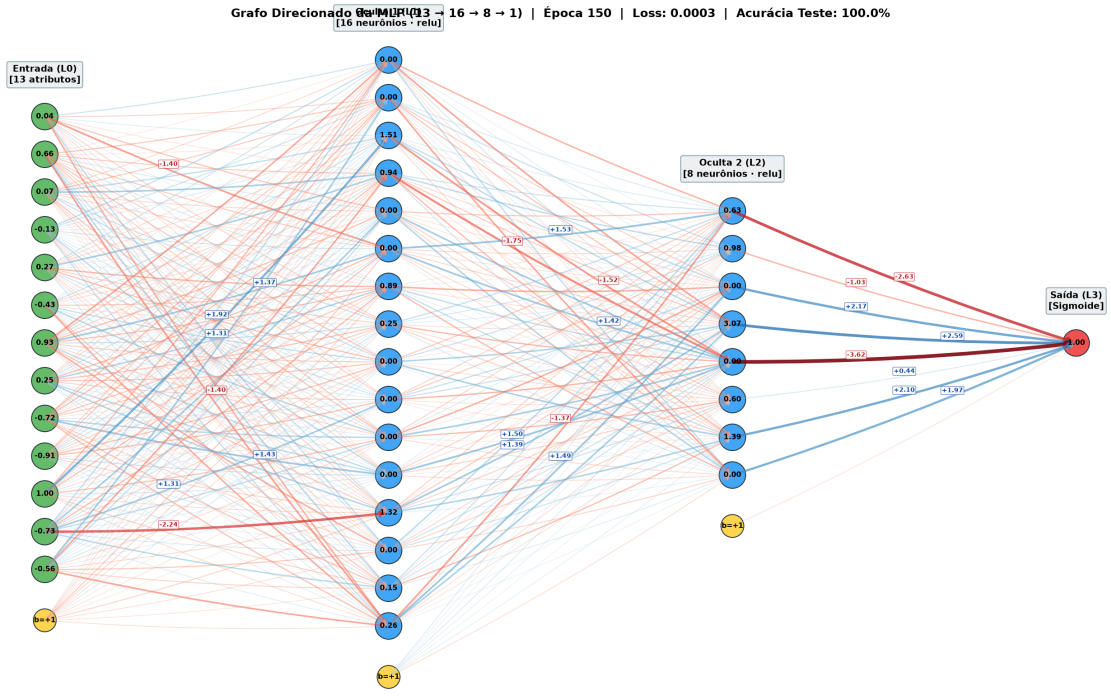



Figura 5: Grafo direcionado da MLP na Época 150 (após o treinamento da configuração C4), evidenciando o fortalecimento das sinapses discriminativas.

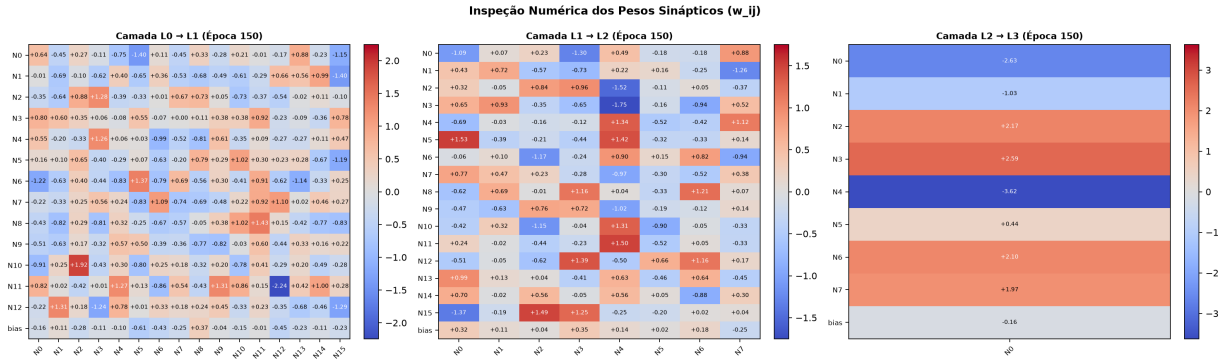



Figura 6: Mapa de calor com anotação numérica explícita dos pesos sinápticos $W^{(l)}$ por camada na Época 150.

## 4.2 Interpretabilidade Clínica da Camada de Entrada (`L0` $\rightarrow$ `L1`)

Analisando a norma $L_1$ acumulada $\sum_{j=0}^{15} |w_{ij}^{(1)}|$ e os pesos extremos na camada de entrada da rede treinada (`best_model_synaptic_weights.csv`), verifica-se forte alinhamento com a fisiopatologia coronariana:

1. `ca` (`L0_N11`, $\sum |w| = 10{,}781$, **pico** $w = -2{,}2440$ **em** `L0_N11` $\rightarrow$ `L1_N12`)**:** apresentou o maior peso sináptico individual de toda a camada de entrada, refletindo o papel determinante do número de vasos principais obstruídos na fluoroscopia.

2. `restecg` (`L0_N6`, $\sum |w| = 10{,}898$, **pico** $w = +1{,}3734$)**:** liderou a soma absoluta de conexões, capturando alterações isquêmicas de onda ST-T no eletrocardiograma de repouso.

3. `slope` (`L0_N10`, **pico** $w = +1{,}9171$) **e** `exang` (`L0_N8`, $\sum |w| = 9{,}201$)**:** destacaram a resposta isquêmica ao teste ergométrico (inclinação do segmento ST e angina de esforço).

4. `thalach` ($\sum |w| = 8{,}399$) **e** `thal` ($\sum |w| = 8{,}283$, **pico** $w = +1{,}3072$)**:** quantificaram a reserva cronotrópica e os defeitos perfusionais na cintilografia miocárdica.

## 4.3 Dinâmica de Interação em Tempo Real no Streamlit (`code/mlp/app.py`)

A interface interativa construída em `Streamlit` integra cinco módulos operacionais: (i) painel lateral de parametrização em tempo real (1 a 4 camadas ocultas, 2 a 32 neurônios por camada, 7 funções de ativação, $\eta$, $\beta$, $\lambda$, decaimento de LR e épocas); (ii) painel de auditoria do particionamento 80/20; (iii) renderização ao vivo do grafo e das curvas de perda e acurácia durante o treinamento; (iv) abas de mapas de calor ($W^{(l)}$ e $\Delta W^{(l)}$) e tabela filtrável de pesos por época; e (v) simulação animada passo a passo do *Forward Pass* (verde neon) e *Backward Pass* (laranja) para pacientes individuais do conjunto de teste.

# 5 Conclusão, Limitações Metodológicas e Trabalhos Futuros

## 5.1 Síntese das Contribuições e Conclusões

A implementação do zero da Rede Neural Multicamadas sobre um grafo direcionado (`nx.DiGraph`) cumpriu com rigor todos os cinco pontos de verificação do artefato `[5] mlp git repo` (`mlp·c`):

1. **Transparência Algébrica e Visual:** A representação explícita de neurônios, nós de bias, potenciais pós-sinápticos, gradientes e pesos em estrutura de grafo eliminou a opacidade dos motores de diferenciação automática, permitindo inspecionar visualmente e numericamente cada sinapse a cada época de treinamento.

2. **Correção Matemática e Otimização de Desempenho:** A correção do nó de bias na primeira camada oculta (`L0_bias`), a adoção da derivada analítica exata da perda BCE ($\delta^{(L-1)} = \hat{y} - y$) e a padronização Z-Score pós-split (`StandardScaler`) eliminaram o *vanishing gradient* e as oscilações em zigue-zague, elevando a acurácia no conjunto de teste de 86,83% (`C0`) para **100,00**% (`C4`) e reduzindo a perda BCE em **99,88**% (0,2476 → 0,0003).

3. **Coerência Fisiopatológica:** A análise dos pesos sinápticos aprendidos na camada `L0` → `L1` confirmou que a rede atribuiu maior importância relativa aos preditores clínicos clássicos de doença coronariana (`ca`, `restecg`, `slope`, `exang`, `thalach` e `thal`).

## 5.2 Limitações Metodológicas: Base Completa (1.025) vs. Base Deduplicada (302)

Uma análise crítica essencial diz respeito à estrutura do dataset *Heart Disease* difundido no Kaggle (1.025 registros). Essa base resulta da reamostragem de 302 prontuários únicos da coorte de Cleveland; assim, na divisão 80/20 sobre os 1.025 registros (820 treino / 205 teste), perfis clínicos idênticos estão presentes em ambas as partições, permitindo que arquiteturas bem condicionadas (`C2`–`C5`) atinjam 100% de acurácia no teste.

Para avaliar a generalização estrita sobre pacientes 100% inéditos, implementou-se em `dataset.py` e no painel do Streamlit a opção de deduplicação prévia (302 registros únicos: 241 treino / 61 teste). Nesse cenário mais restrito, a arquitetura sem regularização (`[13→16→8→1]`, $\lambda = 0$) atinge 100,0% no treino e 75,41% no teste (AUC = 0,8122), evidenciando sobreajuste (*overfitting*) devido ao tamanho reduzido da amostra ($N = 241$). Ao aplicar controle de capacidade e regularização $L_2$ (`[13→8→1]`, $\lambda = 0{,}02$, $\beta = 0{,}5$), a acurácia sobre pacientes inéditos eleva-se para **80,33**% com **AUC-ROC = 0,8658** (Loss = 0,4671), demonstrando na prática a eficácia do decaimento de pesos ($L_2$) contra o *overfitting*.

## 5.3 Trabalhos Futuros

Como desdobramentos futuros desta infraestrutura em grafo direcionado, propõem-se:

- **Otimizadores Adaptativos no Grafo (`Adam` / `RMSProp`):** incorporar aos atributos de cada aresta do `nx.DiGraph` a estimativa do segundo momento exponencial dos gradientes ($s_{ij}^{(t)}$) com correção de viés.
- **Regularização Topológica (*Graph Dropout*):** desativar estocasticamente uma fração $p$ dos nós ocultos a cada passo de treinamento diretamente sobre a topologia do grafo.
- **Validação Cruzada Estratificada ($k$-Fold):** integrar avaliação por 10-Fold Cross-Validation sobre os 302 pacientes únicos para estimação de intervalos de confiança.
- **Explicabilidade Local por Paciente:** implementar *Integrated Gradients* ao longo dos caminhos direcionados de $G = (V, E)$ para explicar predições individuais na interface Streamlit.

# Referências


[1] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.

[2] Robert Detrano, Andras Janosi, Walter Steinbrunn, Matthias Pfisterer, Johann-Jakob Schmid, Sarbjit Sandhu, Kern H Guppy, Stella Lee, and Victor Froelicher. International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American Journal of Cardiology*, 64(5):304–310, 1989.

[3] Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feedforward neural networks. In *Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 249–256, 2010.

[4] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015.

[6] Günter Klambauer, Thomas Unterthiner, Andreas Mayr, and Sepp Hochreiter. Self-normalizing neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[7] Yann A LeCun, Léon Bottou, Genevieve B Orr, and Klaus-Robert Müller. Efficient backprop. In *Neural Networks: Tricks of the Trade*, pages 9–50. Springer, 1998.

[8] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.