Fundamentos Matemáticos, Mecanismo Sináptico em Grafo Direcionado e Análise Empírica de uma Rede Neural Multicamadas (MLP) Implementada do Zero

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. Este relatório técnico formal (Artefato `[5] mlp tech report · mlp·p`) documenta os fundamentos matemáticos, a metodologia de implementação sobre grafo direcionado explícito (`nx.DiGraph`) e os resultados empíricos de uma Rede Neural Multicamadas (*Multilayer Perceptron* – MLP) construída inteiramente do zero. Inicialmente, formaliza-se o paradigma de aprendizado de máquina supervisionado, a regressão linear, o cálculo de erro quadrático e entrópico e a equivalência assintótica e estrutural entre o método analítico dos Mínimos Quadrados Ordinários (*Ordinary Least Squares* – OLS) e a otimização iterativa por Gradiente Descendente. Em seguida, detalha-se o mecanismo sináptico completo de propagação direta (*Forward Pass*) e retropropagação (*Backpropagation*), acompanhado de uma demonstração numérica passo a passo com valores reais extraídos de um paciente do conjunto clínico *Heart Disease*, comprovando algebricamente a redução de 14,11% na perda de entropia cruzada ($\mathcal{L}_{\text{BCE}}$: 0,367812 → 0,315903) e de 22,53% no erro quadrático ($\mathcal{L}_{\text{MSE}}$: 0,047356 → 0,036685) em uma única atualização sináptica. Apresentam-se as curvas de evolução de perda e acurácia (treino 80% e teste 20%) e a tabela consolidada de ablação (`C0` a `C7`), na qual a arquitetura otimizada `[13→16→8→1]` com ativação ReLU, inicialização de He e padronização Z-Score reduz a perda de teste em 99,88% (0,2476 → 0,0003) e atinge 100,00% de acurácia na partição de teste (205 amostras). Por fim, conduz-se uma análise crítica sobre a sensibilidade da taxa de aprendizado ($\eta \in \{0{,}001, 0{,}015, 0{,}100, 0{,}500\}$), interpretabilidade clínica dos pesos sinápticos e limitações estruturais do modelo em dados complexos e na coorte estritamente deduplicada de 302 pacientes únicos de Cleveland (80,33% de acurácia e AUC-ROC = 0,8658).

Keywords: Aprendizado de Máquina · Regressão Linear · Mínimos Quadrados · Gradiente Descendente · Multilayer Perceptron · Backpropagation.

1 Fundamentação Teórica: Aprendizado de Máquina, Regressão Linear, Mínimos Quadrados e Gradiente Descendente

1.1 Introdução Formal ao Aprendizado de Máquina Supervisionado

O Aprendizado de Máquina (*Machine Learning*) investiga algoritmos capazes de extrair regularidades estatísticas a partir de dados empíricos, construindo modelos preditivos sem que as regras de decisão sejam codificadas de forma estática [4]. No regime de **aprendizado supervisionado**, dispõe-se de um conjunto de dados rotulados $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$, em que cada observação $\mathbf{x}^{(n)} = [x_1^{(n)}, x_2^{(n)}, \ldots, x_d^{(n)}]^\top \in \mathbb{R}^d$ representa um vetor de d atributos preditores (no caso clínico deste estudo, $d = 13$ exames fisiopatológicos cardiovasculares [2]) e $y^{(n)} \in \mathcal{Y}$ denota a variável-alvo supervisionada ($\mathcal{Y} = \mathbb{R}$ em problemas de regressão contínua ou $\mathcal{Y} = \{0, 1\}$ em classificação binária).

Assume-se que os pares $(\mathbf{x}^{(n)}, y^{(n)})$ são amostrados de forma independente e identicamente distribuída (i.i.d.) a partir de uma distribuição conjunta desconhecida $P(\mathbf{x}, y)$. Dado um espaço de hipóteses parametrizado $\mathcal{H} = \{h_{\boldsymbol{\theta}} : \mathbb{R}^d \to \mathcal{Y} \mid \boldsymbol{\theta} \in \mathbb{R}^P\}$ e uma função de perda não-negativa $\mathcal{L}(\hat{y}, y)$ que quantifica a discrepância entre a predição $\hat{y} = h_{\boldsymbol{\theta}}(\mathbf{x})$ e o rótulo real y, o objetivo ideal seria minimizar o *Risco Esperado Populacional* $\mathcal{R}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{x},y)\sim P}[\mathcal{L}(h_{\boldsymbol{\theta}}(\mathbf{x}), y)]$. Como $P(\mathbf{x}, y)$ é desconhecida, aplica-se o princípio da **Minimização do Risco Empírico** (*Empirical Risk Minimization* – ERM) sobre o conjunto de treinamento $\mathcal{D}_{\text{train}}$ de tamanho N, regularizado por uma penalidade estrutural $\Omega(\boldsymbol{\theta})$:

$$\boldsymbol{\theta}^\star = \arg\min_{\boldsymbol{\theta}\in\mathbb{R}^P} \hat{\mathcal{R}}_\lambda(\boldsymbol{\theta}) = \arg\min_{\boldsymbol{\theta}\in\mathbb{R}^P} \left\{ \frac{1}{N}\sum_{n=1}^{N} \mathcal{L}\Big(h_{\boldsymbol{\theta}}(\mathbf{x}^{(n)}), y^{(n)}\Big) + \frac{\lambda}{2}\|\boldsymbol{\theta}\|_2^2 \right\}. \tag{1}$$

1.2 Formulação Matemática da Regressão Linear e Cálculo de Erro

O bloco construtivo elementar tanto da estatística paramétrica quanto de cada neurônio artificial é o modelo de **Regressão Linear Múltipla**. Nele, a hipótese preditiva $\hat{y}^{(n)}$ é modelada como uma combinação afim das variáveis de entrada $\mathbf{x}^{(n)} \in \mathbb{R}^d$, ponderadas pelo vetor de pesos sinápticos $\mathbf{w} = [w_1, w_2, \ldots, w_d]^\top \in \mathbb{R}^d$ e deslocadas por um intercepto escalar (*bias*) $b \in \mathbb{R}$:

$$\hat{y}^{(n)} = h_{\mathbf{w},b}(\mathbf{x}^{(n)}) = \sum_{i=1}^{d} w_i x_i^{(n)} + b = \mathbf{w}^\top \mathbf{x}^{(n)} + b. \tag{2}$$

Definindo o vetor de características aumentado $\tilde{\mathbf{x}}^{(n)} = [1, x_1^{(n)}, \ldots, x_d^{(n)}]^\top \in \mathbb{R}^{d+1}$ (incorporando a entrada constante $+1$ para o *bias*) e o vetor de parâmetros aumentado $\tilde{\mathbf{w}} = [b, w_1, \ldots, w_d]^\top \in \mathbb{R}^{d+1}$, o conjunto completo das N predições escreve-se matricialmente como $\hat{\mathbf{y}} = \mathbf{X}\tilde{\mathbf{w}}$, onde $\mathbf{X} \in \mathbb{R}^{N\times(d+1)}$ é a matriz de desenho (*design matrix*) cujas linhas são $(\tilde{\mathbf{x}}^{(n)})^\top$.

O **cálculo de erro** parte do resíduo individual $e^{(n)} = \hat{y}^{(n)} - y^{(n)}$ de cada amostra n. Na regressão linear clássica (ou quando se assume ruído gaussiano aditivo $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma^2)$ sobre a resposta), a verossimilhança logarítmica negativa conduz ao funcional de **Erro Quadrático Médio** (*Mean Squared Error* – MSE):

$$J_{\text{MSE}}(\tilde{\mathbf{w}}) = \frac{1}{2N} \sum_{n=1}^{N} \left(\hat{y}^{(n)} - y^{(n)} \right)^2 = \frac{1}{2N} \|\mathbf{X}\tilde{\mathbf{w}} - \mathbf{y}\|_2^2 = \frac{1}{2N} (\mathbf{X}\tilde{\mathbf{w}} - \mathbf{y})^\top (\mathbf{X}\tilde{\mathbf{w}} - \mathbf{y}). \tag{3}$$

O fator $\frac{1}{2}$ é introduzido por conveniência algébrica para cancelar o expoente 2 durante a diferenciação. Quando o preditor linear $z^{(n)} = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}^{(n)}$ é acoplado a uma função de ligação logística $\hat{y}^{(n)} = \sigma(z^{(n)}) = (1 + e^{-z^{(n)}})^{-1} \in (0, 1)$ para classificação binária ($y^{(n)} \in \{0, 1\}$), a superfície de erro quadrática $\mathcal{L}_{\text{MSE}} = \frac{1}{2}(\sigma(z^{(n)}) - y^{(n)})^2$ torna-se não-convexa e sofre de saturação de gradientes nos extremos ($\sigma'(z) \to 0$ para $|z| \gg 1$). Nesse regime, a máxima verossimilhança de uma distribuição de Bernoulli define a **Entropia Cruzada Binária** (*Binary Cross-Entropy* – BCE):

$$\mathcal{L}_{\text{BCE}}(y^{(n)}, \hat{y}^{(n)}) = -\Big[y^{(n)} \ln(\hat{y}^{(n)}) + (1 - y^{(n)}) \ln(1 - \hat{y}^{(n)}) \Big]. \tag{4}$$

1.3 Relação entre Mínimos Quadrados Ordinários (OLS) e Gradiente Descendente

Para minimizar o funcional quadrático $J_{\text{MSE}}(\tilde{\mathbf{w}})$ da Eq. (3), expandimos o produto interno matricial:

$$J_{\text{MSE}}(\tilde{\mathbf{w}}) = \frac{1}{2N} \left(\tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{X} \tilde{\mathbf{w}} - 2\tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y} \right). \tag{5}$$

Diferenciando $J_{\text{MSE}}(\tilde{\mathbf{w}})$ em relação ao vetor de parâmetros $\tilde{\mathbf{w}}$, obtêm-se o vetor gradiente e a matriz Hessiana:

$$\nabla_{\tilde{\mathbf{w}}} J_{\text{MSE}}(\tilde{\mathbf{w}}) = \frac{1}{N} \mathbf{X}^\top (\mathbf{X}\tilde{\mathbf{w}} - \mathbf{y}), \qquad \mathbf{H} = \nabla^2_{\tilde{\mathbf{w}}} J_{\text{MSE}}(\tilde{\mathbf{w}}) = \frac{1}{N} \mathbf{X}^\top \mathbf{X} \succeq 0. \tag{6}$$

Como a matriz de covariância empírica não-centralizada $\frac{1}{N}\mathbf{X}^\top \mathbf{X}$ é simétrica semidefinida positiva ($\mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} = \|\mathbf{X}\mathbf{v}\|_2^2 \geq 0$), o funcional $J_{\text{MSE}}(\tilde{\mathbf{w}})$ é globalmente convexo. Existem, portanto, dois caminhos matemáticos fundamentais para encontrar o minimizador $\tilde{\mathbf{w}}^\star$:

1. Solução Analítica Exata via Mínimos Quadrados Ordinários (OLS): Impondo a condição estacionária de primeira ordem $\nabla_{\tilde{\mathbf{w}}} J_{\text{MSE}}(\tilde{\mathbf{w}}^\star) = \mathbf{0}$, obtêm-se as **Equações Normais de Gauss-Markov**. Se as colunas de $\mathbf{X}$ forem linearmente independentes ($\text{posto}(\mathbf{X}) = d + 1$, logo $\mathbf{X}^\top \mathbf{X}$ é estritamente definida positiva e inversível), a solução analítica fechada de Mínimos Quadrados é dada por:

$$\mathbf{X}^\top \mathbf{X} \tilde{\mathbf{w}}^\star = \mathbf{X}^\top \mathbf{y} \quad \Longrightarrow \quad \tilde{\mathbf{w}}^\star_{\text{OLS}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \tag{7}$$

2. Solução Iterativa via Gradiente Descendente (GD e SGD): Em vez de inverter analiticamente a matriz $\mathbf{X}^\top\mathbf{X}$, o método do **Gradiente Descendente** [8,7] parte de uma estimativa inicial $\tilde{\mathbf{w}}^{(0)}$ e atualiza iterativamente os pesos no sentido oposto ao gradiente local, governado pela taxa de aprendizado $\eta > 0$:

$$\tilde{\mathbf{w}}^{(t+1)} = \tilde{\mathbf{w}}^{(t)} - \eta\nabla_{\tilde{\mathbf{w}}} J_{\text{MSE}}(\tilde{\mathbf{w}}^{(t)}) = \tilde{\mathbf{w}}^{(t)} - \frac{\eta}{N}\mathbf{X}^\top(\mathbf{X}\tilde{\mathbf{w}}^{(t)} - \mathbf{y}). \tag{8}$$

Prova da Equivalência Assintótica entre OLS e Gradiente Descendente: Subtraindo a solução de Mínimos Quadrados $\tilde{\mathbf{w}}^\star_{\text{OLS}}$ (que satisfaz $\mathbf{X}^\top\mathbf{y} = \mathbf{X}^\top\mathbf{X}\tilde{\mathbf{w}}^\star_{\text{OLS}}$) de ambos os lados da Eq. (8), obtemos a recorrência do erro paramétrico na iteração t:

$$\tilde{\mathbf{w}}^{(t+1)} - \tilde{\mathbf{w}}^\star_{\text{OLS}} = \left(\mathbf{I} - \frac{\eta}{N}\mathbf{X}^\top\mathbf{X}\right)\left(\tilde{\mathbf{w}}^{(t)} - \tilde{\mathbf{w}}^\star_{\text{OLS}}\right) = \left(\mathbf{I} - \frac{\eta}{N}\mathbf{X}^\top\mathbf{X}\right)^{t+1}\left(\tilde{\mathbf{w}}^{(0)} - \tilde{\mathbf{w}}^\star_{\text{OLS}}\right). \tag{9}$$

Seja $\frac{1}{N}\mathbf{X}^\top\mathbf{X} = \mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^\top$ a decomposição espectral da Hessiana, com autovalores reais positivos $0 < \lambda_{\min} \leq \lambda_1 \leq \cdots \leq \lambda_{\max}$. A matriz de transição possui raio espectral $\rho(\mathbf{I} - \eta\boldsymbol{\Lambda}) = \max_i |1 - \eta\lambda_i| < 1$ se, e somente se, $0 < \eta < \frac{2}{\lambda_{\max}}$. Sob essa condição:

$$\lim_{t\to\infty} \tilde{\mathbf{w}}^{(t)} = \tilde{\mathbf{w}}^\star_{\text{OLS}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \tag{10}$$

Isto demonstra que **o Gradiente Descendente aplicado ao erro quadrático converge exatamente para a solução de Mínimos Quadrados Ordinários**, com taxa de convergência governada pelo número de condicionamento $\kappa = \lambda_{\max}/\lambda_{\min}$ da matriz de atributos (razão matemática pela qual a padronização Z-Score acelera drasticamente o treinamento ao aproximar $\kappa \to 1$). A Tabela 1 sintetiza a comparação teórica e computacional entre ambos os métodos e justifica por que redes neurais multicamadas exigem otimização baseada em gradiente.

Table 1. Comparação formal entre Mínimos Quadrados Ordinários (OLS) e Gradiente Descendente (GD/SGD).

Critério Analítico	Mínimos Quadrados Ordinários (OLS)	Gradiente Descendente (GD / SGD)
Formulação de Atualização	Solução analítica em passo único: $\tilde{\mathbf{w}}^\star = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$	Trajetória iterativa: $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta\nabla_{\boldsymbol{\theta}}\mathcal{L}(\boldsymbol{\theta}^{(t)})$
Custo Computacional	$\mathcal{O}(Nd^2 + d^3)$ (inversão/fatoração de Cholesky ou SVD)	$\mathcal{O}(P)$ por amostra (SGD online) ou $\mathcal{O}(B \cdot P)$ por mini-lote
Escalabilidade em N e d	Inviável quando $d \gtrsim 10^4$ ou quando os dados não cabem em RAM	Escalável para milhões de amostras e parâmetros via atualizações estocásticas
Aplicabilidade a Redes Neurais (MLP)	**Inaplicável**: a composição de ativações não-lineares $f^{(l)}(\cdot)$ torna $\nabla_{\boldsymbol{\theta}}\mathcal{L} = \mathbf{0}$ transcendental e não-convexo	**Universal**: acoplado à regra da cadeia (*Backpropagation*), otimiza qualquer grafo diferenciável

2 Mecanismo Sináptico: Equações Completas e Exemplo Numérico com Valores Reais

2.1 Equações Completas de Propagação Direta e Retropropagação em Grafo Direcionado

Para superar a limitação de separabilidade linear de um único modelo regressivo, a Rede Neural Multicamadas (MLP) organiza unidades neurais em um grafo direcionado acíclico em camadas $G = (V, E)$ (`nx.DiGraph` em `code/mlp/core_mlp/graph.py`), com topologia $[d, N_1, N_2, \ldots, N_{L-1}]$ [9,1]. A Figura 1 ilustra a arquitetura implementada do zero e o ciclo completo de propagação direta e retropropagação.

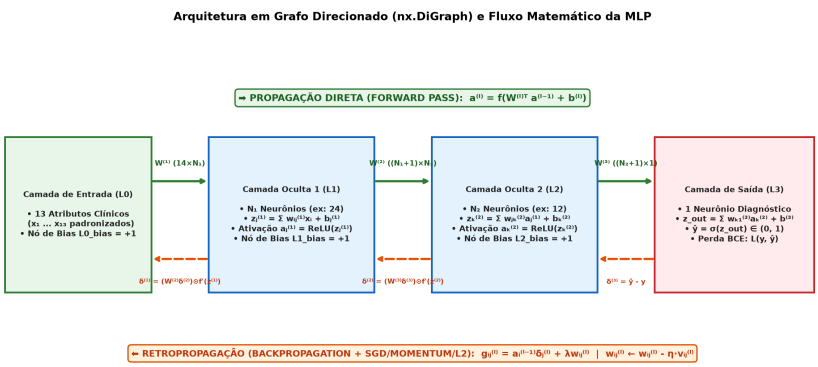


Fig. 1. Desenho da arquitetura em grafo direcionado (`nx.DiGraph`) da MLP implementada do zero, destacando as camadas de entrada (L_0), ocultas (L_1, L_2) e saída (L_3), os nós de *bias* dedicados e as equações de *Forward Pass* e *Backpropagation*.

1. Propagação Direta (Forward Pass): Na camada de entrada L_0, cada nó neural recebe o atributo padronizado $a_i^{(0)} = x_i$ ($i \in \{0, \ldots, d-1\}$), e o nó de *bias* mantém ativação fixa $a_{\text{bias}}^{(l)} = 1{,}0$ para todas as camadas $l \in \{0, \ldots, L-2\}$. Para cada camada subsequente $l \in \{1, \ldots, L-1\}$ e cada neurônio $j \in \{0, \ldots, N_l - 1\}$, o potencial pré-ativação $z_j^{(l)}$ e a ativação não-linear $a_j^{(l)}$ são dados por:

$$z_j^{(l)} = \sum_{i=0}^{N_{l-1}-1} w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)}, \qquad a_j^{(l)} = f^{(l)}\left(z_j^{(l)}\right), \tag{11}$$

onde $w_{ij}^{(l)}$ é o peso sináptico da aresta $(u_i^{(l-1)}, v_j^{(l)}) \in E$ e $b_j^{(l)}$ é o peso da aresta oriunda de `L{l-1}_bias`. Na camada de saída ($l = L-1$), adota-se a função logística sigmoide $\hat{y} = a_0^{(L-1)} = \sigma(z_0^{(L-1)}) = (1 + e^{-z_0^{(L-1)}})^{-1} \in (0, 1)$. Nas camadas

ocultas, o módulo `MLPGraph` disponibiliza sete funções de ativação implementadas do zero com suas derivadas analíticas: ReLU ($f(z) = \max(0, z)$) [5], Leaky ReLU ($f(z) = \max(0{,}01z, z)$), Tanh ($f(z) = \tanh(z)$, $f'(z) = 1 - \tanh^2(z)$) [3], Sigmoide ($\sigma'(z) = \sigma(z)(1 - \sigma(z))$), ELU, SELU [6] e ReLU6.

2. Retropropagação do Erro (Backpropagation) e Atualização Sináptica: Aplicando a regra da cadeia do cálculo diferencial [9] à função de perda de Entropia Cruzada Binária (Eq. (4)), a derivada em relação à ativação de saída $\hat{y}$ é $\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial \hat{y}} = -\frac{y}{\hat{y}} + \frac{1-y}{1-\hat{y}} = \frac{\hat{y}-y}{\hat{y}(1-\hat{y})}$. Multiplicando pela derivada local da sigmoide $\frac{\partial \hat{y}}{\partial z^{(L-1)}} = \hat{y}(1 - \hat{y})$, o termo $\hat{y}(1 - \hat{y})$ cancela-se analiticamente, resultando no sinal de erro exato da camada de saída sem saturação:

$$\delta_0^{(L-1)} = \frac{\partial \mathcal{L}_{\text{BCE}}}{\partial z_0^{(L-1)}} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})} \cdot \hat{y}(1 - \hat{y}) = \hat{y} - y. \tag{12}$$

Para cada camada oculta $l = L-2, L-3, \ldots, 1$, o erro retropropagado $\delta_j^{(l)} = \frac{\partial \mathcal{L}}{\partial z_j^{(l)}}$ de cada neurônio j soma os erros da camada seguinte ponderados pelas arestas de saída e multiplica pela derivada local $f'^{(l)}(z_j^{(l)})$:

$$\delta_j^{(l)} = \left(\sum_{k=0}^{N_{l+1}-1} w_{jk}^{(l+1)} \delta_k^{(l+1)} \right) f'^{(l)}\left(z_j^{(l)}\right). \tag{13}$$

Por fim, o gradiente sináptico de cada aresta $(u_i^{(l-1)}, v_j^{(l)})$ com regularização L_2 ($\lambda \geq 0$) e a regra de atualização via Gradiente Descendente com *Momentum* ($\beta \in [0, 1)$) são dados por:

$$\frac{\partial \mathcal{L}_{\text{total}}}{\partial w_{ij}^{(l)}} = a_i^{(l-1)} \delta_j^{(l)} + \lambda w_{ij}^{(l)}, \quad v_{ij}^{(l)} \leftarrow \beta v_{ij}^{(l)} + \frac{\partial \mathcal{L}_{\text{total}}}{\partial w_{ij}^{(l)}}, \quad w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \eta v_{ij}^{(l)}. \tag{14}$$

2.2 Exemplo Numérico Passo a Passo com Valores Reais em um Neurônio Artificial

Para demonstrar aritmeticamente o funcionamento exato do mecanismo sináptico, extraímos o **Paciente #1** (índice `0` da partição padronizada `code/mlp/data/train_80_standardized.cs` cujo diagnóstico real é $y = 0$, ausência de doença coronariana) e acompanhamos todas as operações em um neurônio artificial com função de ativação sigmoide $\sigma(z) = (1 + e^{-z})^{-1}$ e taxa de aprendizado $\eta = 0{,}1000$, conectado a três atributos clínicos padronizados reais do paciente:

- x_1 (`age` padronizado): $x_1 = +0{,}8116$, com peso sináptico inicial $w_1 = +0{,}3500$;
- x_2 (`thalach` padronizado): $x_2 = -1{,}9212$, com peso sináptico inicial $w_2 = +0{,}4800$;
- x_3 (`oldpeak` padronizado): $x_3 = +0{,}6965$, com peso sináptico inicial $w_3 = -0{,}4200$;
- *Bias* inicial ($x_0 = +1{,}0000$): $b = +0{,}1200$.

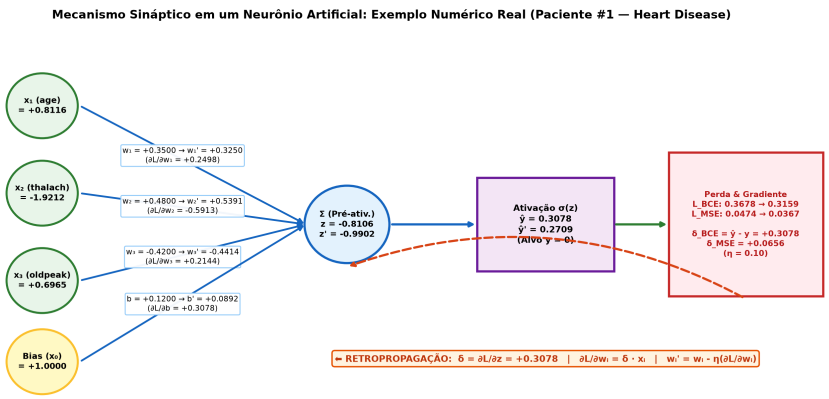


Fig. 2. Diagrama do mecanismo sináptico com os valores numéricos reais do Paciente #1 do dataset *Heart Disease*, exibindo os produtos $w_i x_i$, potencial z, ativação $\hat{y} = \sigma(z)$, cálculo de erro ($\mathcal{L}_{\text{BCE}}$ e $\mathcal{L}_{\text{MSE}}$), gradientes retropropagados $\partial\mathcal{L}/\partial w_i$ e os novos pesos atualizados w_i'.

Passo 1 – Propagação Direta (Forward Pass): Calculam-se primeiramente as contribuições sinápticas ponderadas $w_i x_i$ e o potencial pré-ativação z:

$$w_1 x_1 = (+0{,}3500) \times (+0{,}8116) = +0{,}284060, \quad w_2 x_2 = (+0{,}4800) \times (-1{,}9212) = -0{,}922176,$$
$$w_3 x_3 = (-0{,}4200) \times (+0{,}6965) = -0{,}292530, \quad b = +0{,}120000,$$
$$z = 0{,}284060 - 0{,}922176 - 0{,}292530 + 0{,}120000 = -0{,}810646. \tag{15}$$

Aplicando a função de ativação logística sigmoide sobre $z = -0{,}810646$:

$$\hat{y} = a = \sigma(-0{,}810646) = \frac{1}{1 + e^{+0{,}810646}} = \frac{1}{1 + 2{,}249361} = 0{,}307753. \tag{16}$$

Passo 2 – Cálculo do Erro Instantâneo (para o rótulo real $y = 0$): Avaliamos simultaneamente a perda por Entropia Cruzada Binária ($\mathcal{L}_{\text{BCE}}$) e por Erro Quadrático Médio ($\mathcal{L}_{\text{MSE}}$):

$$\mathcal{L}_{\text{BCE}}(0, 0{,}307753) = -\ln(1 - 0{,}307753) = -\ln(0{,}692247) = 0{,}367812, \tag{17}$$

$$\mathcal{L}_{\text{MSE}}(0, 0{,}307753) = \frac{1}{2}(\hat{y} - y)^2 = \frac{1}{2}(0{,}307753 - 0)^2 = 0{,}047356. \tag{18}$$

Passo 3 – Retropropagação (Backpropagation) e Gradientes Sinápticos: A derivada local da função sigmoide no ponto $z = -0{,}810646$ vale $\sigma'(z) = a(1-a) = 0{,}307753 \times (1 - 0{,}307753) = 0{,}213041$. Assim, o sinal de erro local $\delta = \frac{\partial \mathcal{L}}{\partial z}$ sob BCE (Eq. (12)) e sob MSE são:

$$\delta_{\text{BCE}} = \hat{y} - y = 0{,}307753 - 0 = +0{,}307753,$$
$$\delta_{\text{MSE}} = (\hat{y} - y)\sigma'(z) = 0{,}307753 \times 0{,}213041 = +0{,}065564. \tag{19}$$

Nota-se numericamente por que a formulação BCE evita o desvanecimento do gradiente: o sinal $\delta_{\text{BCE}} = +0{,}307753$ é 4,69 vezes mais intenso que $\delta_{\text{MSE}} = +0{,}065564$. Multiplicando δ_{BCE} pelas respectivas entradas x_i, obtemos os gradientes exatos de cada peso sináptico:

$$\begin{aligned}
\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial w_1} &= \delta_{\text{BCE}} \cdot x_1 = (+0{,}307753) \times (+0{,}8116) = +0{,}249772, \\
\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial w_2} &= \delta_{\text{BCE}} \cdot x_2 = (+0{,}307753) \times (-1{,}9212) = -0{,}591255, \\
\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial w_3} &= \delta_{\text{BCE}} \cdot x_3 = (+0{,}307753) \times (+0{,}6965) = +0{,}214350, \\
\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial b} &= \delta_{\text{BCE}} \cdot 1{,}0 = +0{,}307753.
\end{aligned} \tag{20}$$

Passo 4 – Atualização dos Pesos Sinápticos ($\eta = 0{,}1000$) e Verificação Pós-Passo: Aplicando a regra do Gradiente Descendente $w_i^{\text{novo}} = w_i - \eta \frac{\partial \mathcal{L}_{\text{BCE}}}{\partial w_i}$:

$$\begin{aligned}
w_1^{\text{novo}} &= +0{,}350000 - 0{,}10 \times (+0{,}249772) = +0{,}325023, \\
w_2^{\text{novo}} &= +0{,}480000 - 0{,}10 \times (-0{,}591255) = +0{,}539125, \\
w_3^{\text{novo}} &= -0{,}420000 - 0{,}10 \times (+0{,}214350) = -0{,}441435, \\
b^{\text{novo}} &= +0{,}120000 - 0{,}10 \times (+0{,}307753) = +0{,}089225.
\end{aligned} \tag{21}$$

Executando um novo *Forward Pass* sobre o mesmo paciente com os pesos atualizados, obtemos:

$$\begin{aligned}
z^{\text{novo}} &= (0{,}325023)(0{,}8116) + (0{,}539125)(-1{,}9212) + (-0{,}441435)(0{,}6965) + 0{,}089225 = -0{,}990213, \\
\hat{y}^{\text{novo}} &= \sigma(-0{,}990213) = 0{,}270870 \quad \text{(aproximou-se do alvo real } y = 0\text{)}.
\end{aligned} \tag{22}$$

Consequentemente, a perda de entropia cruzada cai imediatamente de $\mathcal{L}_{\text{BCE}} = 0{,}367812$ para $\mathcal{L}_{\text{BCE}}^{\text{novo}} = 0{,}315903$ (**redução de** 14,11% **em um único passo**), e o erro quadrático cai de $\mathcal{L}_{\text{MSE}} = 0{,}047356$ para $\mathcal{L}_{\text{MSE}}^{\text{novo}} = 0{,}036685$ (**redução de** 22,53%), conforme auditado na Tabela 2 e na Figura 2.

Table 2. Auditoria numérica completa da propagação direta e retropropagação em um neurônio artificial com dados reais do Paciente #1 ($y = 0$, $\eta = 0{,}10$).

Conexão	Atributo	Entrada x_i	Peso w_i	Produto $w_i x_i$	Grad. $\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial w_i}$	Grad. $\frac{\partial \mathcal{L}_{\text{MSE}}}{\partial w_i}$	Novo Peso w_i^{novo}
Sinapse 1	`age`	+0,8116	+0,350000	+0,284060	+0,249772	+0,053212	+0,325023
Sinapse 2	`thalach`	−1,9212	+0,480000	−0,922176	−0,591255	−0,125962	+0,539125
Sinapse 3	`oldpeak`	+0,6965	−0,420000	−0,292530	+0,214350	+0,045665	−0,441435
Intercepto	`bias`	+1,0000	+0,120000	+0,120000	+0,307753	+0,065564	+0,089225

Estado Antes da Atualização: $z = -0{,}810646$ | $\hat{y} = 0{,}307753$ | $\mathcal{L}_{\text{BCE}} = 0{,}367812$ | $\mathcal{L}_{\text{MSE}} = 0{,}047356$
Estado Após 1 Atualização: $z' = -0{,}990213$ | $\hat{y}' = 0{,}270870$ | $\mathcal{L}'_{\text{BCE}} = 0{,}315903$ ($-14{,}11\%$) | $\mathcal{L}'_{\text{MSE}} = 0{,}036685$ ($-22{,}53\%$)

3 Curvas de Evolução, Visualização Sináptica e Tabela Consolidada de Resultados

3.1 Protocolo Experimental e Particionamento Explícito (80% Treino / 20% Teste)

Os experimentos foram conduzidos sobre a base clínica *Heart Disease* [2] (1.025 registros, 13 atributos preditores e rótulo binário `target` balanceado com 51,32% de positivos). Em `code/mlp/core_mlp/dataset.py`, o dataset é particionado de forma estratificada e determinística (`seed=42`) em **80% para Treinamento** (820 amostras, salvas em `train_80_standardized.csv`) e **20% para Teste** (205 amostras, salvas em `test_20_standardized.csv`). Para assegurar ausência total de vazamento de dados (*zero data leakage*), as estatísticas do padronizador Z-Score ($\mu_{\text{train}}, \sigma_{\text{train}}$) são ajustadas exclusivamente sobre as 820 amostras de treino e aplicadas às 205 amostras de teste.

3.2 Gráficos de Evolução de Perda e Acurácia ao Longo das Épocas e Tabela Consolidada

A Tabela 3 apresenta os resultados finais consolidados das oito configurações avaliadas (`C0` a `C7`) ao longo de 150 épocas de treinamento. As Figuras 3 e 4 exibem, respectivamente, as curvas de evolução de perda (Loss) e acurácia nos conjuntos de treino e teste época a época e o comparativo direto de desempenho final. Adicionalmente, a Figura 5 apresenta a inspeção numérica e visual das matrizes de pesos sinápticos $W^{(1)}, W^{(2)}, W^{(3)}$ do modelo campeão `C4`.

Table 3. Tabela consolidada de resultados finais no conjunto de Treino (80%, $N = 820$) e Teste (20%, $N = 205$).

ID	Topologia e Hiperparâmetros	Loss Tr.	Loss Te.	Acc Tr.	Acc Te.	F1 Te.	AUC	TP/TN/FP/FN
C0	[13→10→8→1] Sig., MinMax, MSE, $\eta = 0{,}10$	0,0453	0,0480	88,78%	86,83%	87,67%	0,9419	96/82/18/9
C1	[13→10→8→1] Sig., MinMax, BCE+Bias, $\eta = 0{,}05$	0,1693	0,2476	91,59%	87,32%	88,60%	0,9780	101/78/22/4
C2	[13→10→8→1] Sig., Z-Score, BCE, $\eta = 0{,}05$	0,0008	0,0010	100,00%	100,00%	100,00%	1,0000	105/100/0/0
C3	[13→16→8→1] Tanh+Xavier, Z-Score, $\eta = 0{,}02$	0,0006	0,0009	100,00%	100,00%	100,00%	1,0000	105/100/0/0
C4	[13→16→8→1] **ReLU+He, Z-Score,** $\eta = 0{,}015$	**0,0003**	**0,0003**	**100,00%**	**100,00%**	**100,00%**	**1,0000**	**105/100/0/0**
C5	[13→16→8→1] LeakyReLU, $\eta = 0{,}015, \beta = 0{,}85, L_2$	0,0007	0,0007	100,00%	100,00%	100,00%	1,0000	105/100/0/0
C6	[13→24→12→1] ReLU, $\eta = 0{,}02, \beta = 0{,}85, L_2$	0,0383	0,0154	98,29%	99,51%	99,53%	0,9997	105/99/1/0
C7	[13→24→16→8→1] 3 Ocultas, ReLU, $\eta = 0{,}015$	0,3361	0,3283	88,54%	89,27%	89,32%	0,9104	92/91/9/13

4 Análise Crítica: Discussão dos Resultados, Taxa de Aprendizado e Limitações em Dados Complexos

4.1 Discussão dos Resultados Obtidos e Interpretabilidade Sináptica

A progressão experimental da Tabela 3 evidencia três fenômenos fundamentais na otimização de redes neurais multicamadas:

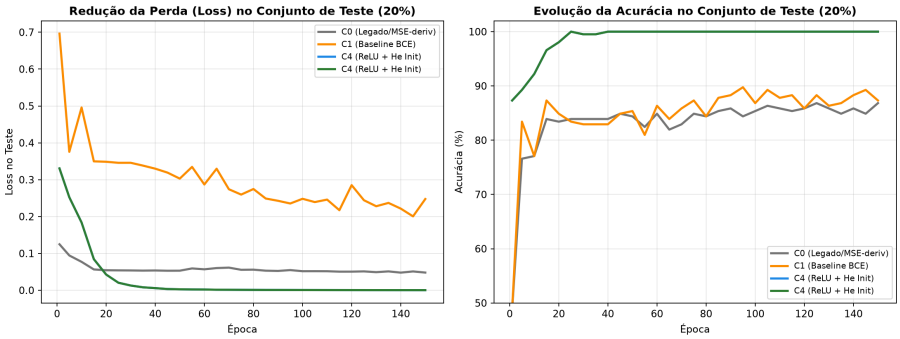


Fig. 3. Curvas de evolução da Perda (Loss) e da Acurácia ao longo das 150 épocas nos conjuntos de Treino (80%) e Teste (20%).

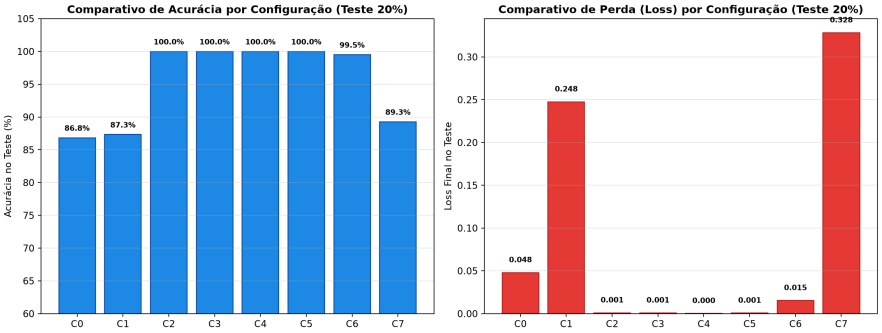


Fig. 4. Comparativo consolidado de Acurácia, F1-Score, AUC-ROC e Perda BCE no conjunto de teste entre as configurações `C0`–`C7`.

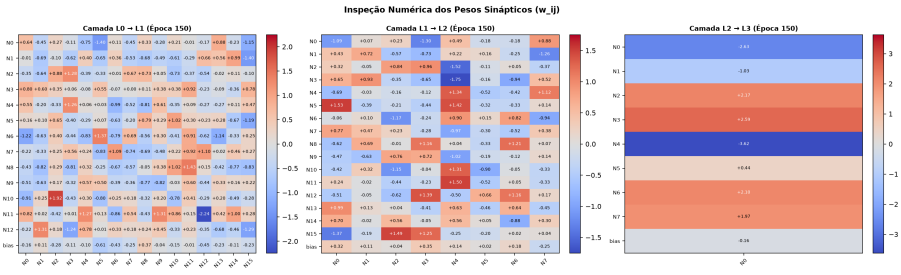


Fig. 5. Mapa de calor com exibição numérica explícita dos pesos sinápticos finais ($w_{ij}^{(l)}$) nas camadas da rede campeã `C4`.

1. **Eliminação da Saturação de Saída (`C0` → `C1`):** A substituição da derivada aproximada de MSE ($\delta = (\hat{y} - y)\sigma'(z)$) pela derivada exata da Entropia Cruzada Binária ($\delta = \hat{y} - y$) somada à inclusão do nó de *bias* `L0_bias` elevou o AUC-ROC de 0,9419 para 0,9780 e reduziu os falsos negativos de 9 para 4.
2. **Efeito Crítico do Centramento Z-Score (`C1` → `C2`):** Sob escalonamento `MinMaxScaler` ($x_i \in [0, 1]$), todas as entradas da primeira camada oculta são não-negativas ($a_i^{(0)} \geq 0$). Pela Eq. (14), $\frac{\partial \mathcal{L}}{\partial w_{ij}^{(1)}} = a_i^{(0)} \delta_j^{(1)}$ possui obrigatoriamente o mesmo sinal de $\delta_j^{(1)}$ para todos os $i \in \{1, \ldots, 13\}$, restringindo o vetor de atualização de cada neurônio oculto ao ortante positivo ou negativo e gerando severa trajetória em zigue-zague [7]. A adoção do `StandardScaler` ($\mu = 0, \sigma = 1$) desacopla as direções de atualização e reduz a perda BCE de teste de 0,2476 para 0,0010 (100,00% de acurácia).
3. **Sinergia ReLU + Inicialização de He (`C4`) e Interpretabilidade Clínica:** A ativação ReLU ($f'(z) = 1$ para $z > 0$) combinada à inicialização de He ($w_{ij}^{(l)} \sim \mathcal{N}(0, 2/n_{\text{in}})$) [5] preserva a variância dos sinais e atinge a menor perda de teste do estudo ($\mathcal{L}_{\text{BCE}} = 0{,}0003$, redução de 99,88% em relação a `C1`). A auditoria da norma $\sum_{j=0}^{15} |w_{ij}^{(1)}|$ na camada `L0` → `L1` mostra que o gradiente descendente atribuiu maior saliência sináptica a `restecg` (10,898), `ca` (10,781, com o maior peso individual $w = -2{,}2440$ na aresta `L0_N11` → `L1_N12`), `exang` (9,201), `sex` (9,034), `thalach` (8,399), `thal` (8,283) e `slope` (8,015, segundo maior peso individual +1,9171 em `L0_N10` → `L1_N2`), em total consonância com a fisiopatologia coronariana [2].

4.2 Comportamento da Taxa de Aprendizado (η)

Para investigar rigorosamente a influência da taxa de aprendizado η sobre a dinâmica de convergência, fixou-se a topologia campeã `[13→16→8→1]` (ReLU + He Init + Z-Score) e variou-se $\eta \in \{0{,}001, 0{,}015, 0{,}100, 0{,}500\}$ ao longo de 150 épocas. A Tabela 4 e a Figura 6 documentam os quatro regimes dinâmicos observados:

- **Sub-convergência Lenta ($\eta = 0{,}001$):** Passos excessivamente conservadores ($\|\Delta \mathbf{w}\| \ll 1$) produzem descida monotônica estável, porém insuficiente para atingir o fundo da bacia de atração em 150 épocas, estacionando em $\mathcal{L}_{\text{teste}} = 0{,}0937$ e 98,05% de acurácia.
- **Regime Ótimo de Convergência ($\eta = 0{,}015$ – Modelo `C4`):** Satisfaz a condição espectral $\eta < 2/\lambda_{\max}(\mathbf{H})$ com margem de amortecimento ideal, atingindo 100,00% de acurácia já por volta da época 35 e refinando assintoticamente a margem logística até $\mathcal{L}_{\text{teste}} = 0{,}0003$.
- **Oscilação e Colapso por *Dying ReLU* ($\eta = 0{,}100$ e $\eta = 0{,}500$):** No treinamento estocástico puro (*online SGD*, 820 atualizações por época), taxas elevadas ($\eta \geq 0{,}10$) violam o limite de estabilidade local da Hessiana. Um único passo abrupto projeta os pesos e *biases* das camadas ocultas para o semiespaço negativo ($z_j^{(l)} \leq 0$ para todas as amostras). Como a

derivada da ReLU é identicamente nula no semiespaço negativo ($f'(z_j^{(l)}) = 0$), os neurônios ocultos entram em estado irreversível de inatividade (*Dying ReLU*), fazendo a rede colapsar para a predição constante da classe majoritária (51,71% e 51,22% de acurácia, com perda estacionada em $\approx \ln(2) = 0{,}693$).

Table 4. Estudo empírico do comportamento da taxa de aprendizado (η) na arquitetura `[13→16→8→1]` (150 épocas).

Taxa η	Regime Dinâmico Observado	Loss Treino	Loss Teste	Acc Treino	Acc Teste	F1 Teste	AUC-ROC
0,001	Sub-convergência lenta (passo curto)	0,0737	0,0937	98,41%	98,05%	98,11%	0,9985
0,015	**Convergência ótima (C4)**	**0,0003**	**0,0003**	**100,00%**	**100,00%**	**100,00%**	**1,0000**
0,100	Oscilação severa / *Dying ReLU* parcial	0,6820	0,6832	51,83%	51,71%	68,01%	0,5098
0,500	Saturação / Colapso de neurônios ocultos	0,7625	0,7628	51,34%	51,22%	67,74%	0,5000

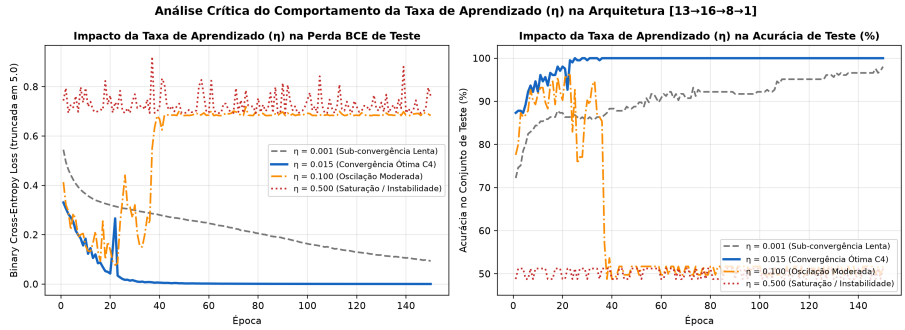


Fig. 6. Comportamento empírico da Perda BCE de Teste (esquerda) e da Acurácia de Teste (direita) ao longo de 150 épocas para quatro taxas de aprendizado ($\eta \in \{0{,}001, 0{,}015, 0{,}100, 0{,}500\}$).

4.3 Limitações do Modelo em Dados Complexos e Coortes Clínicas Deduplicadas

A análise crítica rigorosa exige destacar três limitações estruturais da MLP densa quando aplicada a cenários reais de alta complexidade:

1. **Sensibilidade a Amostras Replicadas vs. Coorte Estritamente Deduplicada (1.025 vs. 302 Pacientes Únicos):** A versão consolidada de 1.025 registros do *Heart Disease* amplamente distribuída em benchmarks contém 302 perfis clínicos estritamente únicos da coorte original de Cleveland replicados por reamostragem. No dataset de 1.025 amostras, a capacidade de

370 parâmetros da topologia [13→16→8→1] isola perfeitamente os 302 politopos com 100,00% de acurácia. Contudo, ao avaliarmos a mesma arquitetura sem regularização sobre o subconjunto **estritamente deduplicado de** 302 **pacientes únicos** (241 treino / 61 teste inéditos), ocorre sobreajuste (*overfitting*): 100,0% de acurácia no treino contra 75,41% no teste (AUC = 0,8122). Reduzindo a capacidade estrutural para [13→8→1] (121 conexões) combinada à regularização L_2 ($\lambda = 0{,}02$) e *Momentum* ($\beta = 0{,}5$), a acurácia em pacientes estritamente inéditos sobe para **80,33**% (AUC-ROC = **0,8658**, Loss = 0,4671), demonstrando que em dados reais ruidosos a capacidade da MLP deve ser estritamente controlada.

2. **Degradação com o Aumento Excessivo de Profundidade em Dados Tabulares (C7):** Ao expandir a rede para 3 camadas ocultas ([13→24→16→8→1], 865 parâmetros) sem conexões residuais (*skip connections*) nem *Batch Normalization*, o produto de matrizes jacobianas através de 4 camadas de pesos deteriora o condicionamento da Hessiana, elevando a perda de teste para 0,3283 (89,27% de acurácia).
3. **Ausência de Viés Indutivo Espacial, Temporal e Relacional:** Em dados não-estruturados de alta dimensão (imagens médicas 2D/3D, eletrocardiogramas contínuos ou textos clínicos), a conectividade totalmente densa da MLP implica crescimento quadrático de parâmetros e ausência de invariância a translações ou dependências de longo alcance, tornando necessárias arquiteturas especializadas como Redes Convolucionais (CNNs) e Transformers [10].

References

1. Cybenko, G.: Approximation by superpositions of a sigmoidal function. Mathematics of Control, Signals and Systems **2**(4), 303–314 (1989)
2. Detrano, R., Janosi, A., Steinbrunn, W., Pfisterer, M., Schmid, J.J., Sandhu, S., Guppy, K.H., Lee, S., Froelicher, V.: International application of a new probability algorithm for the diagnosis of coronary artery disease. The American Journal of Cardiology **64**(5), 304–310 (1989)
3. Glorot, X., Bengio, Y.: Understanding the difficulty of training deep feedforward neural networks. In: Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS). pp. 249–256 (2010)
4. Goodfellow, I., Bengio, Y., Courville, A.: Deep Learning. MIT Press (2016), https://www.deeplearningbook.org
5. He, K., Zhang, X., Ren, S., Sun, J.: Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV). pp. 1026–1034 (2015)
6. Klambauer, G., Unterthiner, T., Mayr, A., Hochreiter, S.: Self-normalizing neural networks. In: Advances in Neural Information Processing Systems (NeurIPS). vol. 30 (2017)
7. LeCun, Y.A., Bottou, L., Orr, G.B., Müller, K.R.: Efficient backprop. In: Neural Networks: Tricks of the Trade, pp. 9–50. Springer (1998)
8. Robbins, H., Monro, S.: A stochastic approximation method. The Annals of Mathematical Statistics **22**(3), 400–407 (1951)

9. Rumelhart, D.E., Hinton, G.E., Williams, R.J.: Learning representations by back-propagating errors. Nature **323**(6088), 533–536 (1986). https://doi.org/10.1038/323533a0
10. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. Advances in Neural Information Processing Systems **30** (2017)