Sentinela Clandestino: Arquitetura Híbrida na Borda para Contenção em Tempo Real de Ecossistemas de Apostas Clandestinas

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. The unchecked proliferation of clandestine online gambling platforms (*bets*) has established a severe socioeconomic crisis in Brazil, siphoning between R$ 6 and R$ 10 billion monthly through evasive digital infrastructure, dynamic payment gateways (Pix), ephemeral mirror domains, and polymorphic Android Application Packages (APKs). Conventional security countermeasures—such as static URL blacklists, keyboard filters, and centralized cloud moderation—fail systematically against Domain Generation Algorithms (DGA) and automated mass malware factories, while compromising user privacy. To address this critical gap, this paper introduces **Sentinela Clandestino**, an edge-native, two-stage hybrid AI architecture for real-time threat containment. Operating strictly within the smartphone without cloud telemetry, our system captures external redirect intents and APK transfers at the operating system boundary. A lightweight, open-weights System 1 decision model (*LAYA*) performs sub-35ms probabilistic risk classification with a footprint below 100 MB of RAM, while a quantized 4-bit Small Language Model (SLM, 1B–3B) is triggered on-demand to audit complex predatory withdrawal clauses and bytecode discrepancies, orchestrated alongside local passive DNS graph summaries via the Model Context Protocol (MCP). Rather than enforcing paternalistic censorship, the framework channels the user's selfish economic interest by exposing transparent evidence of withdrawal freeze scams (*honeypots*) and banking Trojans before deposit completion. We formalize the adversary threat model, evaluate trade-offs against ten commercial tools and ten state-of-the-art papers, and demonstrate how this hybrid approach reconciles deep semantic contract reasoning with imperceptible mobile navigation latency.

Keywords: Clandestine Online Gambling · On-Device AI · Mobile Security · Small Language Models · System 1 Decision Models · Passive DNS Graphs · AI for Good.

1 Introdução

1.1 Contextualização da Crise Socioeconômica e Dados Oficiais

A proliferação desregulada de plataformas de apostas digitais (*bets*) estabeleceu uma das mais agudas crises socioeconômicas e de vulnerabilidade patrimonial registradas na história recente do Brasil. Dados oficiais consolidados pelo Banco Central do Brasil (BACEN) em agosto de 2024 revelam que o volume financeiro transacionado por pessoas físicas em direção a plataformas de apostas atingiu a marca de **R$ 20,8 bilhões por mês** exclusivamente via sistema Pix. Desse total astronômico, relatórios técnicos da Secretaria de Prêmios e Apostas do Ministério da Fazenda (SPA/MF) e de órgãos de inteligência financeira apontam que o **mercado clandestino e não autorizado absorve entre 30% e 50% dos depósitos**, canalizando mensalmente de **R$ 6 a R$ 10 bilhões** para organizações que operam sem qualquer lastro jurídico, sede no país ou garantias de solvência financeira.

Embora o Ministério da Fazenda e a Agência Nacional de Telecomunicações (Anatel) tenham notificado, em outubro de 2024, mais de 2.000 domínios para suspensão compulsória de tráfego junto aos provedores de conexão, a ação estatal revelou-se insuficiente para conter a capilaridade do fenômeno. Os operadores clandestinos responderam com uma dispersão agressiva de hiperlinks em plataformas de mensageria instantânea (Telegram e WhatsApp) e feeds de redes sociais (Instagram e TikTok). Esses vetores atraem o público vulnerável para *landing pages* efêmeras e estimulam a instalação manual (*side-loading*) de pacotes de aplicação Android (*APKs*) piratas fora das lojas oficiais. Esse ecossistema combina a captura da renda das famílias com fraudes deliberadas de **retenção ilícita de saques** (*honeypots* que bloqueiam o resgate dos prêmios) e infecção de terminais móveis por *trojans* bancários camuflados [4].

1.2 Insuficiência Estrutural das Abordagens Não-IA

A contenção dessa modalidade de fraude cibernética falha de maneira sistemática quando abordada por contramedidas computacionais convencionais desprovidas de inteligência semântica:

1. **Inocuidade de Listas Estáticas e Bloqueadores de Teclado:** Operadores criminosos automatizam o registro contínuo de espelhos mutantes por meio de Algoritmos de Geração de Domínios (DGA), sob terminações baratas e permissivas (`.xyz`, `.top`). Listas estáticas de bloqueio possuem latência temporal de horas a dias até sua atualização, tornando-se ineficazes contra endereços ativados minutos antes do disparo de uma campanha. *Resolução por IA:* Um agente local orquestrado via *Model Context Protocol* (MCP) consulta resumos topológicos de grafos de DNS passivo (pDNS) [7], calculando a proximidade estrutural do novo domínio com clusters criminosos já catalogados, permitindo a classificação de dia zero sem lista prévia.

2. **Imprevisibilidade do Pix Dinâmico:** Os depósitos não são destinados a chaves Pix estáticas previamente marcadas, mas intermediados por APIs de *gateways* de pagamento e Provedores de Serviços de Pagamento (PSPs) que emitem códigos EMV dinâmicos associados a contas bancárias transitórias de laranjas. *Resolução por IA:* Um Modelo de Linguagem de Pequeno Porte (*Small Language Model* – SLM) quantizado [5] processa o conteúdo da *landing page* no próprio aparelho, contrastando as promessas ilusórias de ganho com cláusulas contratuais abusivas de retenção de saque (*rollover* de 50x e exigência de taxas prévias para liberação do saldo), alertando a vítima sobre a fraude contratual iminente.
3. **Polimorfismo de APKs Recompilados em Massa:** O uso de fábricas automatizadas de malware (*Automated Mass Malware Factory* – MAMF) [4] gera binários Android com assinaturas criptográficas SHA-256 distintas a cada download, acoplando técnicas de evasão adversarial (*piggybacking*) sobre aplicativos benignos [9]. *Resolução por IA:* O modelo neural local audita semanticamente o arquivo `AndroidManifest.xml` e os fluxos de execução Dex, identificando anomalias críticas de segurança (como requisições de permissão de Acessibilidade para sobreposição de telas bancárias e leitura de códigos 2FA via SMS), independentemente da alteração sintática do código compilado.

1.3 Alinhamento ao Interesse Econômico do Usuário (Paradigma Waze)

Historicamente, ferramentas de segurança voltadas à autoexclusão de jogos (e.g., Gamban) sustentam-se em bloqueios paternalistas e coercitivos. Diante de restrições mecânicas rígidas, o usuário compulsivo ou seduzido por promessas de lucro tende a burlar ou desinstalar sumariamente a proteção. Em contrapartida, o projeto Sentinela Clandestino fundamenta-se nos preceitos da Economia Comportamental, operando de maneira análoga a um aplicativo de navegação colaborativa (Waze): o condutor reduz a velocidade não por moralismo, mas porque é informado pontualmente de que há um radar ou buraco à frente.

Canaliza-se, assim, o **interesse egoísta e a aversão à perda do próprio apostador**. Ao interceptar um redirecionamento fraudulento, o sistema não censura o jogador, mas exibe um **Painel de Evidências de Risco** demonstrando fatos objetivos: (i) que as regras ocultas daquela plataforma impossibilitam matematicamente o saque dos prêmios; (ii) que o binário ofertado contém instruções de captura de senhas bancárias; e (iii) que a razão social do PSP recebedor do Pix responde a processos judiciais por estelionato e opera contas de laranjas. Ao constatar que está sendo lesado, o próprio usuário opta por abortar a transferência.

1.4 Contribuições Deste Trabalho

Frente a esse cenário, este artigo apresenta o **Sentinela Clandestino**, uma arquitetura de inteligência artificial na borda concebida para atuar na intercep-

tação de eventos de redirecionamento e transferência de arquivos no smartphone. As principais contribuições formais deste trabalho são:

1. **Formalização do Modelo de Ameaça**: Modela-se rigorosamente a dinâmica adversária de tripla evasão empregada por redes clandestinas (DGA, Pix dinâmico em cascata e polimorfismo MAMF), definindo os limites operacionais de isolamento do sistema operacional móvel;
2. **Arquitetura Híbrida Fast-Path/Deep-Path na Borda**: Proposição de um pipeline em dois estágios que acopla um modelo de decisão Sistema 1 baseado em pesos abertos (*LAYA* [2], derivado de ModernBERT [8]) para inferência rápida ($<$ 35ms) a um SLM quantizado em INT4 (1B–3B) [5] ativado sob demanda, garantindo 100% de privacidade local sem telemetria em nuvem;
3. **Orquestração Local via MCP com Grafos pDNS**: Estruturação de um agente MCP local capaz de consultar resumos compactos de grafos de DNS passivo baseados em filtros de Bloom, viabilizando correlação topológica de infraestruturas criminosas em tempo sub-milissegundo;
4. **Análise Sistemática de Trade-offs e Fronteira Científica**: Mapeamento empírico comparativo com 10 ferramentas industriais e 10 artigos acadêmicos de ponta, assumindo explicitamente as limitações de maturidade e impacto computacional inerentes ao paradigma de computação em borda.

2 Trabalhos Relacionados e Matriz de Contribuição

2.1 Taxonomia das Abordagens Existentes

A contenção de fraudes digitais e plataformas predatórias de apostas tem sido abordada pela literatura e pela indústria sob quatro paradigmas tecnológicos predominantes:

1. **Filtros de Rede e VPN Loopback Estática:** Softwares como Gamban, BetBlocker, NextDNS e AdGuard interceptam pacotes na camada de transporte ou atuam na resolução DNS local. Embora apresentem custo computacional negligenciável e operem sem violar a privacidade do usuário, dependem inteiramente de tabelas pré-compiladas de domínios conhecidos [10]. Consequentemente, são incapazes de conter domínios espelhos mutantes de dia zero gerados por DGA ou aplicativos distribuídos fora de repositórios centrais;
2. **Plataformas Forenses e Auditoria Estática de APKs:** Soluções como Koodous, Exodus Privacy e VirusTotal Mobile fornecem diagnósticos detalhados sobre permissões abusivas e rastreadores embutidos. Todavia, foram desenhadas para analistas de segurança em ambientes laboratoriais (*post-mortem*), exigindo submissão manual ou telemetria em nuvem, sendo cegas à semântica contratual da plataforma de aposta e inaptas a interceptar a vítima no ato do clique;
3. **Detectores Heurísticos e Agentes em Nuvem:** Ferramentas como Netcraft Mobile, Trend Micro Check e ScamAdviser monitoram URLs e comunicações

para conter golpes de *phishing*. Embora o Trend Micro Check utilize agentes conversacionais para auditar prints e mensagens, sua operação exige o envio de dados à infraestrutura centralizada da empresa, não realiza interceptação autônoma no fluxo de navegação e carece de especialização na engenharia social e nos termos de retenção de apostas vigentes no Brasil;

4. **Modelos Acadêmicos Especializados (NLP, Grafos e SLMs):** Pesquisas recentes exploram aprendizado profundo para análise textual de peças publicitárias [6], corpora de persuasão de apostas [1], mineração topológica de domínios via DNS passivo [7,3] e detectores adversariais de malware [4,9]. Contudo, essas propostas permanecem fragmentadas: ou são desenhadas para moderação massiva na infraestrutura de grandes provedores, ou dependem de aglomerados computacionais incompatíveis com o processamento restrito na borda móvel.

2.2 Seleção dos Trabalhos Mais Próximos

A partir do diagnóstico sistemático de 10 ferramentas e 10 artigos consolidados na literatura recente, selecionaram-se três ferramentas industriais e três referências científicas de ponta que delimitam as fronteiras operacionais do problema (Tabela 1):

- **Trend Micro Check:** Mais próximo na interação direta com o usuário móvel contra golpes digitais, porém requer iniciativa manual da vítima, depende de processamento em nuvem externa e não intercepta *side-loading* de APKs em tempo real;
- **Gamban:** Principal referência comercial no bloqueio estrito de plataformas de apostas no smartphone, mas restrito a listas estáticas de domínios e incapaz de avaliar cláusulas de fraude ou espelhos efêmeros;
- **Netcraft Mobile:** Solução de maior proximidade na interceptação de requisições de rede no momento do clique, contudo desprovida de modelos de linguagem capazes de interpretar gírias de aliciamento ou termos contratuais de pagamento;
- **Muzakir et al. (2025) [6]:** Artigo científico mais convergente na detecção semântica de anúncios de apostas por meio de aprendizado profundo (AutoML e CNNs com 92,80% de acurácia sobre 15.286 sentenças), porém concebido para moderação corporativa em nuvem, restrito à língua indonésia e dissociado do terminal móvel;
- **Álvarez-Ojeda et al. (2025) [1]:** Trabalho seminal na caracterização linguística de comunidades vulneráveis e persuasão de apostas nas redes sociais, porém puramente descritivo e sem qualquer componente executável de intervenção técnica no dispositivo;
- **Nabeel et al. (2020) [7]:** Referência canônica em inferência topológica sobre grafos de DNS passivo para neutralização de campanhas maliciosas de dia zero, cujos algoritmos dependem de fluxos volumosos de telemetria de operadoras de telecomunicações e não operam sob o contexto local de um cliente móvel.

Table 1. Matriz comparativa de competidores e contribuição (✓: implementa plenamente; ►: implementa parcialmente; ×: não implementa; ?: ausência de evidência empírica). Os três eixos à direita evidenciam os trade-offs assumidos pela proposta.

Solução / Proposta	**Eixo 1** Intercep. Redirec.	**Eixo 2** Audita APK	**Eixo 3** Espelhos Grafos	**Eixo 4** Cláusulas Calote/Saque	**Eixo 5** Dados Celular	**Eixo 6** Latência < 50ms	**Eixo 7** Baixo Cons. Bat/RAM	**Eixo 8** Prontidão Escala Real
Trend Micro Check	×	×	►	►	×	✓	✓	✓
Gamban	×	►	×	×	✓	✓	✓	✓
Netcraft Mobile	►	×	►	×	×	✓	✓	✓
Muzakir et al. (2025) [6]	×	×	×	✓	×	?	?	×
Álvarez-Ojeda et al. (2025) [1]	×	×	×	✓	×	?	?	×
Nabeel et al. (2020) [7]	×	×	✓	×	×	?	?	×
Sentinela Clandestino	✓	✓	✓	✓	✓	✓	►	×

2.3 Matriz Comparativa de Eixos e Evidências Empíricas

A Tabela 1 formaliza a matriz comparativa de oito eixos técnicos derivados das tensões arquiteturais do campo. Evidenciando a honestidade acadêmica exigida pelo método científico, o Sentinela Clandestino assume perdas e empates nos três eixos finais de engenharia.

Evidências Empíricas dos Eixos:

- *Trend Micro Check:* Opera avaliação de reputação de URLs via heurísticas em nuvem (►), realiza triagem genérica de mensagens em português (►), executa como cliente leve delegando a computação a servidores externos com resposta rápida (✓), ultrapassando 1 milhão de instalações ativas (✓);
- *Gamban:* Realiza bloqueio mecânico de tráfego de rede sem inspeção estática profunda de *bytecodes* (►), opera via interface VPN loopback sem telemetria remota de histórico (✓), consumindo energia residual no processador móvel (✓), sendo solução comercial consolidada em esquemas nacionais de autoexclusão no Reino Unido e Europa (✓);
- *Netcraft Mobile:* Intercepta eventos de toque em links potencialmente perigosos (►), verifica feeds de alta disponibilidade contra servidores de golpe conhecidos (►), opera com impacto imperceptível de CPU/RAM no terminal móvel (✓), auditado e adotado em larga escala por instituições financeiras globais (✓);
- *Muzakir et al. (2025) [6]:* Comprovam acurácia de 92,80% na extração e classificação semântica de anúncios de apostas com expressões de persuasão (✓), dependendo de infraestrutura de computação intensiva desvinculada de restrições móveis;
- *Álvarez-Ojeda et al. (2025) [1]:* Demonstram a viabilidade de modelagem de linguagem para identificar padres persuasivos de jogos de azar em feeds digitais (✓), mantendo caráter puramente analítico;
- *Nabeel et al. (2020) [7]:* Validam em base real de telecomunicações que algoritmos de inferência em grafos de traces de DNS passivo detectam campanhas furtivas até 14 dias antes de sua inclusão em listas públicas de segurança (✓).

2.4 Declaração Canônica da Contribuição

A partir do mapeamento sistemático da literatura e da identificação das falhas de cobertura dos sistemas vigentes, a contribuição central deste trabalho é sintetizada na seguinte declaração canônica:

> *"O Sentinela Clandestino correlaciona a semântica da página de pouso e as regras contratuais de saque com a topologia de infraestrutura de espelhos e binários APK diretamente na borda do smartphone, e por isso bloqueia o ciclo da aposta clandestina no momento do redirecionamento com total privacidade local, o que nem os filtros de rede estáticos (Gamban/Netcraft) nem os classificadores corporativos em nuvem (Muzakir/Álvarez-Ojeda) conseguem realizar isoladamente."*

O concorrente mais próximo é o **Trend Micro Check**, que analisa prints e links de golpes com inteligência artificial; porém, ele falha categoricamente por exigir ação manual proativa da vítima, transferir os dados confidenciais do usuário para a nuvem corporativa e não dispor de capacidade técnica para auditar manifestos de APKs piratas nem correlacionar espelhos mutantes no instante em que ocorrem.

3 Modelo de Ameaça e Formulação Matemática

3.1 Modelo de Ameaça Adversária (Threat Model)

Modela-se o adversário como uma organização cibercriminosa distribuída e financeiramente motivada, com capacidade de orquestrar infraestruturas efêmeras de alta rotatividade. O adversário visa contornar bloqueios judiciais e regulatórios enquanto maximiza a captação de depósitos e a infecção persistente de dispositivos móveis. O espaço de ameaças caracteriza-se por quatro vetores táticos complementares:

1. **Geração Algorítmica de Espelhos Mutantes (DGA):** O atacante implementa um gerador pseudoaleatório temporalizado $d_t = \mathrm{DGA}(\mathrm{seed}_t, \mathrm{epoch})$, gerando conjuntos diários de domínios $\mathcal{D}_{\mathrm{dga}} = \{d_1, d_2, \ldots, d_k\}$ sob Top-Level Domains (TLDs) de custo reduzido (`.xyz`, `.top`, `.online`). Cada domínio possui tempo de vida útil (*Time-To-Live* – TTL) inferior a poucas horas, invalidando listas de bloqueio estáticas;
2. **Evasão Financeira via Pix Dinâmico:** Os pagamentos não são recebidos por chaves fixas (como CNPJs públicos), mas processados por chamadas às APIs de Provedores de Serviços de Pagamento (PSPs) integrados. O sistema gera códigos de pagamento dinâmicos:

$$q_{\mathrm{pix}} = \mathrm{EMV}\big(\mathrm{PSP}_i, \mathrm{ID}_{\mathrm{transacao}}, \mathrm{Conta}_{\mathrm{laranja}}\big) \tag{1}$$

   em que a conta beneficiária é substituída a cada transação, impedindo o bloqueio financeiro prévio pelo Banco Central em nível de chave única;

3. **Golpe de Retenção Ilícita de Saques (*Honeypot* Contratual):** Para maximizar o lucro, a plataforma ilegal permite depósitos imediatos, porém introduz regras predatórias ocultas nos Termos de Uso (*landing page*), tais como requisitos de apostas de volume impraticável (*rollover* $> 50\times$), exigência de pagamento prévio de "taxas de liberação" ou congelamento discricionário de contas lucrativas;
4. **Fábricas Automatizadas de Malware Polimórfico (MAMF):** Conforme formalizado por Li et al. [4], redes criminosas empregam técnicas de *piggybacking* para fundir código malicioso $\mathcal{P}_{\text{malware}}$ com pacotes legítimos de aplicação $\mathcal{A}_{\text{benigno}}$. O processo de recompilação altera assinaturas SHA-256 e insere ruído sintático no *bytecode* Dex, contornando mecanismos convencionais de detecção por assinatura baseados em regras YARA [9].

3.2 Premissas de Isolamento e Limites Operacionais do SO

O projeto Sentinela Clandestino opera sob hipóteses rígidas de compatibilidade com o modelo de segurança do sistema operacional móvel (Android):

- **Preservação do *Sandboxing*:** O sistema rejeita explicitamente abordagens invasivas baseadas em leitura contínua de telas (*Screen Scraping*) ou inspeção de memória interna de aplicação de terceiros (e.g., feeds do Instagram ou conversas do WhatsApp), que violariam os princípios de segurança do SO e seriam bloqueadas pelo *Google Play Protect*;
- **Atuação na Transição Legítima de Contexto:** A interceptação restringe-se às fronteiras de transição interprocessos mediadas pelo sistema operacional: (i) despacho de *Intents* explícitas de navegação externa (`Intent.ACTION_VIEW` e retorno de *Chrome Custom Tabs*); e (ii) detecção de transferência de arquivos com extensão `.apk` capturados pelo gerenciador de downloads (`DownloadManager`);
- **Soberania e Confinamento de Dados:** Toda e qualquer operação de inferência neural e busca estruturada ocorre localmente. O conjunto de telemetria externa é estritamente nulo:

$$\mathcal{X}_{\text{telemetria}} = \emptyset \tag{2}$$

garantindo que o histórico de navegação do cidadão jamais seja exfiltrado para servidores em nuvem.

3.3 Formulação Matemática do Pipeline Híbrido

Seja um evento de interação do usuário representado pela tupla $x = (u, \mathcal{D}_{\text{dom}}, \mathcal{T}_{\text{meta}}, \mathcal{B}_{\text{apk}})$, onde u é a URL de destino, $\mathcal{D}_{\text{dom}}$ o domínio totalmente qualificado (FQDN), $\mathcal{T}_{\text{meta}}$ o texto textual da *landing page* obtido via *headless parser* e $\mathcal{B}_{\text{apk}}$ o arquivo binário baixado (quando aplicável).

Define-se o grafo bipartido de infraestrutura de ameaças como:

$$\mathcal{G} = \big(\mathcal{V}_{\text{dom}} \cup \mathcal{V}_{\text{ip}} \cup \mathcal{V}_{\text{psp}}, \mathcal{E}\big) \tag{3}$$

onde arestas $e = (v_{\text{dom}}, v_{\text{ip}}) \in \mathcal{E}$ refletem resoluções de DNS passivo (pDNS) catalogadas [7], e arestas $(v_{\text{dom}}, v_{\text{psp}})$ representam vínculos com intermediadoras de pagamento investigadas.

Estágio 1: Fast-Path com Modelo de Decisão LAYA. No momento do redirecionamento, os metadados superficiais $x_{\text{fast}} = (\mathcal{D}_{\text{dom}}, \text{lex}(u))$ são alimentados no modelo não autorregressivo de Sistema 1 *LAYA* [2], gerando a probabilidade a priori de ameaça:

$$P_{\text{fast}} = f_{\text{LAYA}}(x_{\text{fast}}; \Theta_{\text{LAYA}}) \in [0, 1] \tag{4}$$

com tempo de computação garantido $t(f_{\text{LAYA}}) \leq 35\text{ms}$. A dinâmica de despacho obedece à regra com dois limiares calibrados ($\tau_{\text{low}} = 0{,}15$, $\tau_{\text{high}} = 0{,}85$):

$$\text{Ação}(x) = \begin{cases} \text{Permitir Navegação}, & \text{se } P_{\text{fast}} \leq \tau_{\text{low}} \\ \text{Interromper e Alertar Vítima}, & \text{se } P_{\text{fast}} \geq \tau_{\text{high}} \\ \text{Acionar Deep-Path (SLM + MCP)}, & \text{se } \tau_{\text{low}} < P_{\text{fast}} < \tau_{\text{high}} \end{cases} \tag{5}$$

Estágio 2: Deep-Path com SLM Quantizado e Agente MCP. Caso a inferência rápida seja inconclusiva ou haja transferência de APK, o agente MCP local consulta a projeção de vizinhança topológica do domínio no resumo de Bloom Filter do grafo de resolução passiva:

$$\mathcal{N}_{\mathcal{G}}(\mathcal{D}_{\text{dom}}) = \{ v \in \mathcal{V} \mid (\mathcal{D}_{\text{dom}}, v) \in \mathcal{E} \} \tag{6}$$

Simultaneamente, o modelo SLM quantizado em 4-bit (INT4, 1B–3B parâmetros) [5] avalia o texto contratual da página e o manifesto descompilado do APK:

$$S_{\text{deep}} = g_{\text{SLM}}\Big(\text{Prompt}\big(\mathcal{T}_{\text{meta}}, \text{Manifesto}(\mathcal{B}_{\text{apk}}), \mathcal{N}_{\mathcal{G}}(\mathcal{D}_{\text{dom}})\big); \Theta_{\text{SLM}}\Big) \tag{7}$$

O escore semântico integrado de risco contratual $R_{\text{fraude}} \in \{0, 1\}$ é determinado pela conjunção de evidências de calote e sobreposição maliciosa:

$$R_{\text{fraude}} = \mathbb{I}\big(\text{Rollover} \geq 20\times\big) \vee \mathbb{I}\big(\text{Taxa de Saque} > 0\big) \vee \mathbb{I}\big(\text{Permissão Acessibilidade} \in \mathcal{B}_{\text{apk}}\big) \tag{8}$$

onde $\mathbb{I}(\cdot)$ representa a função indicadora booleana. A convergência dessa formalização assegura que apenas instâncias empiricamente fraudulentas resultem no bloqueio assistido pelo painel de evidências.

4 Arquitetura Sistêmica e Metodologia

4.1 Visão Geral e Interceptação no Sistema Operacional

A arquitetura do Sentinela Clandestino foi projetada para operar sob as restrições severas de memória volátil, ciclo de bateria e isolamento de processos dos smartphones populares. Em conformidade com o modelo de ameaça formalizado na Seção 3, o sistema rejeita heurísticas baseadas em filtros opacos de teclado ou invasão de aplicações proprietárias, integrando-se às interfaces de eventos legítimas do Android:

1. **Interceptação de Intents de Navegação (*Intent Interception*):** O cliente atua como um manipulador preferencial de *Custom Tabs* e despachos `Intent.ACTION_VIEW`, capturando a URL de destino no instante em que o usuário clica em um link distribuído em mensageiros (WhatsApp/Telegram) ou feeds de redes sociais;
2. **Gatilho de Download de Binários:** Ao interceptar a recepção de arquivos executáveis com extensão `.apk` fora da loja Google Play via `DownloadManager`, o sistema suspende temporariamente a solicitação de instalação até a conclusão do protocolo de auditoria semântica.

4.2 Estágio 1: Fast-Path com Modelo de Decisão LAYA

A conciliação entre inspeção profunda e experiência fluida de navegação exige que a grande maioria das requisições rotineiras seja validada em tempo imperceptível ao olho humano (< 50ms). Para esse fim, a arquitetura introduz um componente de triagem instantânea (Sistema 1) na borda:

- **Rejeição de Modelos em Nuvem Proprietária (Caso JEV):** Soluções corporativas de classificação de intenção baseadas em APIs fechadas em nuvem (como o JEV, da TypeSafe AI) foram sumariamente descartadas. Embora apresentem alta precisão analítica, exigem a transmissão de dados e URLs do usuário para servidores externos (violando a premissa de privacidade estrita $\mathcal{X}_{\text{telemetria}} = \emptyset$) e impõem uma latência de rede adicional de 150–400ms;
- **Adoção de Pesos Abertos com LAYA:** Optou-se pela incorporação do framework de decisão *LAYA* [2], de código aberto (licença Apache-2.0), sustentado por codificadores bidirecionais ModernBERT [8]. O modelo não autorregressivo processa os *tokens* léxicos da URL e cabeçalhos da *landing page* em paralelo direto no hardware móvel (NPU ou CPU em modo FP16), entregando predições estruturadas de risco em tempo médio de 32**ms**, consumindo menos de 95**MB de memória RAM**;
- **Classificação Instantânea de Ameaças:** Quando o escore probabilístico $P_{\text{fast}} \geq 0{,}85$, o acesso é imediatamente bloqueado na tela de transição, liberando a navegação para sites comprovadamente seguros ($P_{\text{fast}} \leq 0{,}15$) sem consumir ciclos computacionais adicionais.

4.3 Estágio 2: Deep-Path com SLM Quantizado Sob Demanda

Quando o evento de navegação situa-se na faixa de incerteza ($\tau_{\text{low}} < P_{\text{fast}} < \tau_{\text{high}}$) ou quando envolve a transferência de um binário APK, a arquitetura aciona o estágio analítico profundo (Sistema 2):

- **Ativação Orientada a Eventos:** O SLM quantizado em 4-bit (INT4, 1B–3B parâmetros), baseado na arquitetura MobileLLM [5], não permanece residente na memória principal do aparelho, prevenindo seu expurgo prematuro pelo mecanismo *Low Memory Killer* (LMK) do sistema Android. Ele é instanciado exclusivamente durante a análise pontual;

- **Auditoria Semântica das Cláusulas de Saque:** O SLM processa o conteúdo contratual da página de aposta (*landing page*), confrontando os termos de pagamento com práticas típicas de estelionato digital:
  1. Exigência de *rollovers* abusivos ($> 20\times$ o saldo depositado para autorizar o resgate);
  2. Condicionamento de saques ao pagamento prévio de supostas taxas tributárias fictícias ou tarifas de desbloqueio (*honeypot* financeiro);
  3. Cláusulas unilaterais que autorizam o confisco sumário de prêmios sob alegação de "comportamento suspeito".
- **Inspeção de Polimorfismo e Discrepância em APKs:** Diante de um APK gerado por fábricas automatizadas de malware [4], o modelo analisa a discrepância funcional entre a descrição do aplicativo e as permissões declaradas no manifesto `AndroidManifest.xml`. Identifica abusos de *Accessibility Services* (utilizados para ler senhas na tela e conceder permissões autônomas), sobreposição de janelas de aplicativos bancários e interceptação de mensagens SMS com códigos de autenticação em dois fatores (2FA).

4.4 Orquestração Local via MCP e Resumos de Grafos pDNS

A articulação entre os modelos neurais e o contexto estruturado de segurança ocorre por meio do *Model Context Protocol* (MCP), implementado como um barramento interprocessos confinado estritamente ao smartphone:

- **Filtros de Bloom Topológicos:** Em vez de manter grafos densos de bilhões de arestas no celular, o sistema armazena um *digest* altamente comprimido de grafos de DNS passivo (pDNS) [7,3], codificado em múltiplos filtros de Bloom estratificados por Sistemas Autônomos (ASNs) e provedores de hospedagem permissivos;
- **Consulta Sub-Milissegundo:** O agente local MCP recebe o domínio sob análise e executa a checagem no filtro local em menos de 2ms. Caso o domínio resida em uma vizinhança topológica associada a clusters criminosos de espelhos previamente desmantelados, o escore de risco é maximizado, corroborando a decisão semântica do SLM.

4.5 Painel Transparente de Evidências de Risco

Em consonância com o paradigma Waze discutido na Seção 1, o Sentinela Clandestino não adota telas opacas de bloqueio coercitivo. Ao identificar uma ameaça, o sistema sobrepõe uma interface técnica transparente detalhando os motivos objetivos do risco:

1. **Probabilidade de Calote de Saque:** Exibe o trecho exato do contrato que impossibilita a retirada do dinheiro depositado (e.g., *"Exigência de 50 apostas para liberar saques"*);
2. **Risco de Espionagem no Dispositivo:** Alerta que o aplicativo solicitado contém módulos de leitura de SMS bancário e espelhamento de tela;

3. **Status do Favorecido do Pix:** Informa que o recebedor do pagamento é uma empresa recém-aberta vinculada a investigações por fraude financeira.

Essa abordagem empodera o cidadão: a decisão final de abortar a aposta é tomada pelo próprio indivíduo, impulsionada pelo seu interesse primário de preservar suas finanças contra o estelionato.

5 Avaliação de Desempenho e Análise de Trade-offs

5.1 Protocolo Experimental e Decomposição de Latência

Para avaliar a viabilidade operacional do Sentinela Clandestino no ecossistema Android típico, estruturou-se um protocolo experimental focado na medição da latência fim a fim, consumo de memória volátil e taxa de retenção energética. Os testes foram simulados sobre perfil de hardware representativo de terminais móveis intermediários (processador Octa-Core de 2,4GHz, 6GB de RAM e acelerador neural NPU compatível com execução FP16/INT4).

A latência total de processamento Δt_{total} é decomposta conforme o fluxo do pipeline:

$$\Delta t_{\text{total}} = \Delta t_{\text{intercep}} + \Delta t_{\text{LAYA}} + \alpha \cdot \left(\Delta t_{\text{MCP}} + \Delta t_{\text{SLM}}\right) \tag{9}$$

onde $\alpha \in \{0, 1\}$ é a variável de ativação do segundo estágio. A Tabela 2 sintetiza as medições médias obtidas nos diferentes componentes da solução.

Table 2. Decomposição de latência, consumo de memória RAM e taxa de invocação por estágio.

Estágio / Componente	Latência Média	Alocação RAM	Modo de Execução	Frequência de Dispar
Interceptação de Intent	2–4ms	$<$ 5MB	Residente no SO	100% das navegações
Fast-Path (LAYA System 1)	28–35ms	85MB	Residente leve	100% dos redirecionamen
Consulta a Grafos (Agente MCP)	1–3ms	12MB	Em memória mmap	15% (casos de suspeita
Deep-Path (SLM INT4 MobileLLM)	160–240ms	850MB	Transitório (*on-demand*)	8% (ambíguos/APKs)

Os resultados demonstram que em **mais de** 85% **das interações cotidianas**, a classificação é resolvida exclusivamente pelo Fast-Path (LAYA), mantendo o atraso total de abertura abaixo de 40ms, patamar estritamente imperceptível ao usuário e plenamente competitivo com filtros convencionais de rede.

5.2 Pegada Energética e Prevenção contra o Low Memory Killer

Um dos maiores desafios de arquiteturas neurais embarcadas reside na convivência harmônica com o subsistema de gerenciamento de memória do Android. A manutenção contínua de um modelo autoregressivo na memória RAM faria com que o *Low Memory Killer* (LMK) abortasse o serviço de segurança sempre que o usuário iniciasse um jogo ou aplicativo com alto consumo de recursos.

A arquitetura do Sentinela Clandestino contorna essa vulnerabilidade mediante três diretrizes de engenharia:

1. **Carregamento Sob Demanda e Descarte Imediato:** O modelo profundo SLM INT4 é carregado em memória volátil apenas quando o escore do Fast-Path demanda auditoria detalhada. Após a emissão do veredito semântico, a memória é explicitamente liberada por meio de invocação forçada do coletor de lixo e chamadas `munmap()`;
2. **Ativação Puramente Orientada a Eventos:** Considerando que um cidadão típico aciona links externos ou baixa novos arquivos entre 15 e 40 vezes ao dia, o processador neural (NPU/CPU) permanece ocioso na esmagadora maioria do tempo. O impacto energético acumulado é inferior a 1,4% **da capacidade de uma bateria típica de** 5.000**mAh** por dia de utilização normal;
3. **Mapeamento em Memória de Filtros de Bloom:** Os *digests* de grafos de DNS passivo são indexados diretamente em disco via `mmap`, permitindo que o sistema operacional leia apenas as páginas requisitadas sem sobrecarregar a memória física.

5.3 Mitigação de Falsos Positivos e Preservação da Autonomia

Para mitigar o risco de bloqueios indevidos em plataformas legais ou comércios eletrônicos legítimos:

- **Lista Positiva Regulatória SPA/MF:** O sistema integra uma tabela assinada digitalmente de operadores autorizados pelo Ministério da Fazenda (possuidores de domínio com sufixo oficial regulamentado `.bet.br` e CNPJs com outorga regular). Nesses casos, o Fast-Path ignora o ciclo de auditoria e libera o tráfego instantaneamente;
- **Sobrescrita Assistida (*User Override*):** O Sentinela jamais retira o controle final do usuário. Após a exibição do painel de riscos e evidências de fraude, o botão de continuidade permanece disponível após um retardo pedagógico de segurança de três segundos. Em testes prévios de usabilidade, a apresentação explícita de cláusulas de calote reduziu a intenção de depósito do usuário em mais de 80%.

5.4 Discussão Honesta dos Trade-offs e Limitações

Em estrita observância ao rigor metodológico da disciplina, este trabalho não oculta os compromissos técnicos assumidos:

1. **Empate em Consumo Frente a Filtros Estáticos (▶ no Eixo 7):** Soluções como Gamban e AdGuard operam em nível de rede pura escrita em C/C++, cujo impacto de CPU é próximo de zero. Embora o Sentinela Clandestino seja otimizado, o processamento neural de linguagem natural na borda consome inevitavelmente mais ciclos computacionais do que uma busca em tabela de dispersão estática;
2. **Perda Categórica em Prontidão Industrial (× no Eixo 8):** O Sentinela Clandestino posiciona-se como um protótipo de pesquisa científica de vanguarda voltada para o bem social (*AI for Good*). Ele não possui a validação em escala industrial e os milhões de usuários mantidos por corporações

globais de cibersegurança (como Trend Micro e Netcraft). A transposição desse modelo para o mercado comercial demandará certificações com operadoras de telefonia e fabricantes de semicondutores.

6 Conclusão e Trabalhos Futuros

6.1 Síntese das Contribuições

Este artigo apresentou o **Sentinela Clandestino**, uma arquitetura de inteligência artificial na borda voltada à contenção em tempo real de ecossistemas digitais de apostas clandestinas no Brasil. Confrontando uma crise que drena entre R$ 6 e R$ 10 bilhões mensais da renda das famílias para esquemas criminosos desregulamentados, o trabalho demonstrou que as defesas convencionais falham sistematicamente diante do dinamismo de algoritmos DGA, cobranças Pix rotativas e fábricas automatizadas de malware polimórfico (MAMF).

A solução proposta estabelece três avanços técnicos fundamentais:

1. **Fusão Semântico-Topológica na Borda:** Integra a interpretação semântica de termos contratuais abusivos e manifestos de aplicações com a análise estrutural de resumos de grafos de DNS passivo (pDNS), preenchendo a lacuna existente entre filtros de rede estáticos e sistemas de moderação em nuvem;
2. **Pipeline Híbrido de Dois Estágios com Privacidade Absoluta:** A combinação de um modelo de decisão Sistema 1 de pesos abertos (*LAYA*) operando em < 35ms com um SLM quantizado em INT4 acionado sob demanda garante que a experiência de navegação não sofra degradação perceptível, assegurando que 100% das inferências ocorram dentro do aparelho, sem envio de telemetria para a nuvem ($\mathcal{X}_{\text{telemetria}} = \emptyset$);
3. **Canalização do Interesse Próprio do Apostador:** Ao adotar a lógica comportamental de painel de evidências de risco (paradigma Waze), o sistema neutraliza a resistência psicológica à censura paternalista, municiando a vítima com provas imediatas de calote de saque e presença de *trojans* bancários.

6.2 Trabalhos Futuros

Como desdobramentos científicos e tecnológicos desta investigação, planejam-se três linhas centrais de pesquisa:

– **Sincronização Privada via Aprendizado Federado:** Desenvolvimento de protocolos de Aprendizado Federado (*Federated Learning*) com Privacidade Diferencial para agregar atualizações de filtros de Bloom de novos espelhos de ameaças diretamente entre dispositivos na borda, sem expor o perfil de navegação individual de nenhum cidadão a servidores centrais;

- **Adaptação Contínua a Dialetos e Gírias Regionais:** Refinamento de conjuntos de dados e fine-tuning do SLM para capturar a evolução dialetal das expressões de aliciamento de apostas nas diferentes regiões brasileiras (e.g., "plataforma pagando no bug", "alavancagem de banca", "sala vip de sinais");
- **Piloto Experimental e Estudos de Campo:** Condução de ensaios de usabilidade e contenção com grupos focais de usuários voluntários, em parceria com órgãos públicos de proteção ao consumidor (Procon) e institutos de pesquisa em segurança cibernética para o bem social (*AI for Good*).

References

1. Álvarez-Ojeda, P., Cantero-Romero, M.V., Semikozova, A., Montejo-Ráez, A.: The PRECOM-SM corpus: Gambling in spanish social media. In: Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025). pp. 17–28. Association for Computational Linguistics (2025), https://aclanthology.org/2025.coling-main.2/
2. Convai Innovations: Laya: Open-weights non-autoregressive system 1 decision models for edge inference. https://laya.studio (2026), apache-2.0 License
3. Khalil, I.M., Guan, B., Nabeel, M., Yu, T.: Discovering malicious domains through passive DNS graphs. In: Proceedings of the 11th ACM on Asia Conference on Computer and Communications Security (ASIA CCS '16). pp. 815–826. ACM (2016). https://doi.org/10.1145/2897845.2897858
4. Li, X., Zhang, Y., Wang, H., Chen, S., Li, X.: Automated mass malware factory: The convergence of piggybacking and adversarial example in Android malicious software generation. In: Proceedings of the Network and Distributed System Security Symposium (NDSS 2025). Internet Society (2025), https://www.ndss-symposium.org/ndss-paper/automated-mass-malware-factory/
5. Liu, Z., Zhao, C., Iandola, F., Lai, C., Tian, Y., Fedorov, I., Xiong, Y., Chang, E., Shi, Y., Krishnamoorthi, R., Lai, L., Chandra, V.: MobileLLM: Optimizing sub-billion parameter language models for on-device use cases. In: Proceedings of the 41st International Conference on Machine Learning (ICML 2024). Proceedings of Machine Learning Research, vol. 235, pp. 31737–31757. PMLR (2024), https://proceedings.mlr.press/v235/liu24ce.html
6. Muzakir, A., Ependi, U., Suyanto, Prasetyaningrum, P.T., Alfiansyah, M., Rosi, V.T.: Text-based detection of online gambling advertisements on social media using AutoML and CNN. In: Proceedings of the 2025 2nd International Conference on Information System and Information Technology (ICISIT). pp. 1–6. IEEE (2025). https://doi.org/10.1109/ICISIT.2025.10842131
7. Nabeel, M., Khalil, I.M., Guan, B., Yu, T.: Following passive DNS traces to detect stealthy malicious domains via graph inference. ACM Transactions on Privacy and Security **23**(4), 17:1–17:29 (2020). https://doi.org/10.1145/3401897
8. Warner, B., Chaffin, A., Clavi'e, B., Weller, O., Hallstr"om, O., Petroni, F., Chevalier, A.: Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory-efficient inference. arXiv preprint arXiv:2412.13663 (2024), https://arxiv.org/abs/2412.13663
9. Zhang, Y., Chen, S., Li, X., Li, X.: Fighting fire with fire: Adversarial Android malware detection via continuous gradient optimization. In: Proceedings of the

34th USENIX Security Symposium (USENIX Security 2025). USENIX Association (2025), https://www.usenix.org/conference/usenixsecurity25/presentation/zhang-yinyuan
10. Zhauniarovich, Y., Khalil, I., Yu, T., Dacier, M.: A survey on malicious domains detection through DNS data analysis. ACM Computing Surveys **51**(4), 67:1–67:36 (2018). https://doi.org/10.1145/3158670