Sentinela Clandestino: Arquitetura Híbrida na Borda para Contenção em Tempo Real de Ecossistemas de Apostas Clandestinas

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. The unchecked proliferation of clandestine online gambling platforms (*bets*) has established a severe socioeconomic crisis in Brazil, siphoning between R$ 6 and R$ 10 billion monthly through evasive digital infrastructure, dynamic payment gateways (Pix), ephemeral mirror domains, and polymorphic Android Application Packages (APKs). Conventional security countermeasures—such as static URL blacklists, keyboard filters, and centralized cloud moderation—fail systematically against Domain Generation Algorithms (DGA) and automated mass malware factories, while imposing critical installation friction and compromising user privacy. To address this critical gap, this paper introduces **Sentinela Clandestino**, an edge-native, two-stage hybrid AI architecture for real-time threat containment. Operating directly within the mobile browser without requiring app installation or manual user typing, our system passively inspects landing page Document Object Models (DOM) and APK transfers at the client boundary via the emerging Web Model Context Protocol (WebMCP). A lightweight, open-weights System 1 decision model (*LAYA*) performs sub-35ms probabilistic risk classification with a footprint below 100 MB of RAM, coupled with a strict domain guardrail that eliminates hallucinations on out-of-domain financial inputs (e.g., CDI/CDB). When ambiguity arises, a quantized 4-bit Small Language Model (SLM, 1B–3B) is triggered on-demand to audit predatory withdrawal clauses and bytecode discrepancies, orchestrated alongside local passive DNS graph summaries. Rather than enforcing paternalistic censorship, the framework channels the user's selfish economic interest by exposing transparent evidence of withdrawal freeze scams (*honeypots*) and banking Trojans before deposit completion. We formalize the adversary threat model, evaluate trade-offs against ten commercial tools and ten state-of-the-art papers, and demonstrate how this hybrid approach reconciles deep semantic contract reasoning with imperceptible mobile navigation latency.

Keywords: Clandestine Online Gambling · On-Device AI · Mobile Security · Small Language Models · WebMCP · Passive DNS Graphs · AI for Good.

1 Introdução

1.1 Contextualização da Crise Socioeconômica e Dados Oficiais

A proliferação desregulada de plataformas de apostas digitais (*bets*) estabeleceu uma das mais agudas crises socioeconômicas e de vulnerabilidade patrimonial registradas na história recente do Brasil. Dados oficiais consolidados pelo Banco Central do Brasil (BACEN) em agosto de 2024 revelam que o volume financeiro transacionado por pessoas físicas em direção a plataformas de apostas atingiu a marca de **R$ 20,8 bilhões por mês** exclusivamente via sistema Pix. Desse total astronômico, relatórios técnicos da Secretaria de Prêmios e Apostas do Ministério da Fazenda (SPA/MF) e de órgãos de inteligência financeira apontam que o **mercado clandestino e não autorizado absorve entre 30% e 50% dos depósitos**, canalizando mensalmente de **R$ 6 a R$ 10 bilhões** para organizações que operam sem qualquer lastro jurídico, sede no país ou garantias de solvência financeira.

Embora o Ministério da Fazenda e a Agência Nacional de Telecomunicações (Anatel) tenham notificado, em outubro de 2024, mais de 2.000 domínios para suspensão compulsória de tráfego junto aos provedores de conexão, a ação estatal revelou-se insuficiente para conter a capilaridade do fenômeno. Os operadores clandestinos responderam com uma dispersão agressiva de hiperlinks em plataformas de mensageria instantânea (Telegram e WhatsApp) e feeds de redes sociais (Instagram e TikTok). Esses vetores atraem o público vulnerável para *landing pages* efêmeras e estimulam a instalação manual (*side-loading*) de pacotes de aplicação Android (*APKs*) piratas fora das lojas oficiais. Esse ecossistema combina a captura da renda das famílias com fraudes deliberadas de **retenção ilícita de saques** (*honeypots* que bloqueiam o resgate dos prêmios) e infecção de terminais móveis por *trojans* bancários camuflados [4].

1.2 Insuficiência Estrutural das Abordagens Não-IA

A contenção dessa modalidade de fraude cibernética falha de maneira sistemática quando abordada por contramedidas computacionais convencionais desprovidas de inteligência semântica:

1. **Inocuidade de Listas Estáticas e Bloqueadores de Teclado:** Operadores criminosos automatizam o registro contínuo de espelhos mutantes por meio de Algoritmos de Geração de Domínios (DGA), sob terminações baratas e permissivas (`.xyz`, `.top`). Listas estáticas de bloqueio possuem latência temporal de horas a dias até sua atualização, tornando-se ineficazes contra endereços ativados minutos antes do disparo de uma campanha. *Resolução por IA:* Um agente local orquestrado via *Model Context Protocol* (MCP) consulta resumos topológicos de grafos de DNS passivo (pDNS) [7], calculando a proximidade estrutural do novo domínio com clusters criminosos já catalogados, permitindo a classificação de dia zero sem lista prévia.

2. **Imprevisibilidade do Pix Dinâmico:** Os depósitos não são destinados a chaves Pix estáticas previamente marcadas, mas intermediados por APIs de *gateways* de pagamento e Provedores de Serviços de Pagamento (PSPs) que emitem códigos EMV dinâmicos associados a contas bancárias transitórias de laranjas. *Resolução por IA:* Um Modelo de Linguagem de Pequeno Porte (*Small Language Model* – SLM) quantizado [5] processa o conteúdo da *landing page* no próprio aparelho, contrastando as promessas ilusórias de ganho com cláusulas contratuais abusivas de retenção de saque (*rollover* de 50x e exigência de taxas prévias para liberação do saldo), alertando a vítima sobre a fraude contratual iminente.
3. **Polimorfismo de APKs Recompilados em Massa:** O uso de fábricas automatizadas de malware (*Automated Mass Malware Factory* – MAMF) [4] gera binários Android com assinaturas criptográficas SHA-256 distintas a cada download, acoplando técnicas de evasão adversarial (*piggybacking*) sobre aplicativos benignos [10]. *Resolução por IA:* O modelo neural local audita semanticamente o arquivo `AndroidManifest.xml` e os fluxos de execução Dex, identificando anomalias críticas de segurança (como requisições de permissão de Acessibilidade para sobreposição de telas bancárias e leitura de códigos 2FA via SMS), independentemente da alteração sintática do código compilado.

1.3 Alinhamento ao Interesse Econômico do Usuário (Paradigma Waze)

Historicamente, ferramentas de segurança voltadas à autoexclusão de jogos (e.g., Gamban) sustentam-se em bloqueios paternalistas e coercitivos. Diante de restrições mecânicas rígidas, o usuário compulsivo ou seduzido por promessas de lucro tende a burlar ou desinstalar sumariamente a proteção. Em contrapartida, o projeto Sentinela Clandestino fundamenta-se nos preceitos da Economia Comportamental, operando de maneira análoga a um aplicativo de navegação colaborativa (Waze): o condutor reduz a velocidade não por moralismo, mas porque é informado pontualmente de que há um radar ou buraco à frente.

Canaliza-se, assim, o **interesse egoísta e a aversão à perda do próprio apostador**. Ao interceptar um redirecionamento fraudulento, o sistema não censura o jogador, mas exibe um **Painel de Evidências de Risco** demonstrando fatos objetivos: (i) que as regras ocultas daquela plataforma impossibilitam matematicamente o saque dos prêmios; (ii) que o binário ofertado contém instruções de captura de senhas bancárias; e (iii) que a razão social do PSP recebedor do Pix responde a processos judiciais por estelionato e opera contas de laranjas. Ao constatar que está sendo lesado, o próprio usuário opta por abortar a transferência.

1.4 Contribuições Deste Trabalho

Frente a esse cenário, este artigo apresenta o **Sentinela Clandestino**, uma arquitetura de inteligência artificial na borda concebida para atuar na intercep-

tação de eventos de redirecionamento e transferência de arquivos no smartphone. As principais contribuições formais deste trabalho são:

1. **Formalização do Modelo de Ameaça**: Modela-se rigorosamente a dinâmica adversária de tripla evasão empregada por redes clandestinas (DGA, Pix dinâmico em cascata e polimorfismo MAMF), definindo os limites operacionais de isolamento do sistema operacional móvel;
2. **Arquitetura Híbrida Fast-Path/Deep-Path na Borda**: Proposição de um pipeline em dois estágios que acopla um modelo de decisão Sistema 1 baseado em pesos abertos (*LAYA* [2], derivado de ModernBERT [9]) para inferência rápida ($<$ 35ms) a um SLM quantizado em INT4 (1B–3B) [5] ativado sob demanda, garantindo 100% de privacidade local sem telemetria em nuvem;
3. **Orquestração Local via MCP com Grafos pDNS**: Estruturação de um agente MCP local capaz de consultar resumos compactos de grafos de DNS passivo baseados em filtros de Bloom, viabilizando correlação topológica de infraestruturas criminosas em tempo sub-milissegundo;
4. **Análise Sistemática de Trade-offs e Fronteira Científica**: Mapeamento empírico comparativo com 10 ferramentas industriais e 10 artigos acadêmicos de ponta, assumindo explicitamente as limitações de maturidade e impacto computacional inerentes ao paradigma de computação em borda.

2 Trabalhos Relacionados e Matriz de Contribuição

2.1 Taxonomia das Abordagens Existentes

A contenção de fraudes digitais e plataformas predatórias de apostas tem sido abordada pela literatura e pela indústria sob quatro paradigmas tecnológicos predominantes:

1. **Filtros de Rede e VPN Loopback Estática:** Softwares como Gamban, BetBlocker, NextDNS e AdGuard interceptam pacotes na camada de transporte ou atuam na resolução DNS local. Embora apresentem custo computacional negligenciável e operem sem violar a privacidade do usuário, dependem inteiramente de tabelas pré-compiladas de domínios conhecidos [11]. Consequentemente, são incapazes de conter domínios espelhos mutantes de dia zero gerados por DGA ou aplicativos distribuídos fora de repositórios centrais;
2. **Plataformas Forenses e Auditoria Estática de APKs:** Soluções como Koodous, Exodus Privacy e VirusTotal Mobile fornecem diagnósticos detalhados sobre permissões abusivas e rastreadores embutidos. Todavia, foram desenhadas para analistas de segurança em ambientes laboratoriais (*post-mortem*), exigindo submissão manual ou telemetria em nuvem, sendo cegas à semântica contratual da plataforma de aposta e inaptas a interceptar a vítima no ato do clique;
3. **Detectores Heurísticos e Agentes em Nuvem:** Ferramentas como Netcraft Mobile, Trend Micro Check e ScamAdviser monitoram URLs e comunicações

para conter golpes de *phishing*. Embora o Trend Micro Check utilize agentes conversacionais para auditar prints e mensagens, sua operação exige o envio de dados à infraestrutura centralizada da empresa, não realiza interceptação autônoma no fluxo de navegação e carece de especialização na engenharia social e nos termos de retenção de apostas vigentes no Brasil;

4. **Modelos Acadêmicos Especializados (NLP, Grafos e SLMs):** Pesquisas recentes exploram aprendizado profundo para análise textual de peças publicitárias [6], corpora de persuasão de apostas [1], mineração topológica de domínios via DNS passivo [7,3] e detectores adversariais de malware [4,10]. Contudo, essas propostas permanecem fragmentadas: ou são desenhadas para moderação massiva na infraestrutura de grandes provedores, ou dependem de aglomerados computacionais incompatíveis com o processamento restrito na borda móvel.

2.2 Seleção dos Trabalhos Mais Próximos

A partir do diagnóstico sistemático de 10 ferramentas e 10 artigos consolidados na literatura recente, selecionaram-se três ferramentas industriais e três referências científicas de ponta que delimitam as fronteiras operacionais do problema (Tabela 1):

- **Trend Micro Check:** Mais próximo na interação direta com o usuário móvel contra golpes digitais, porém requer iniciativa manual da vítima, depende de processamento em nuvem externa e não intercepta *side-loading* de APKs em tempo real;
- **Gamban:** Principal referência comercial no bloqueio estrito de plataformas de apostas no smartphone, mas restrito a listas estáticas de domínios e incapaz de avaliar cláusulas de fraude ou espelhos efêmeros;
- **Netcraft Mobile:** Solução de maior proximidade na interceptação de requisições de rede no momento do clique, contudo desprovida de modelos de linguagem capazes de interpretar gírias de aliciamento ou termos contratuais de pagamento;
- **Muzakir et al. (2025) [6]:** Artigo científico mais convergente na detecção semântica de anúncios de apostas por meio de aprendizado profundo (AutoML e CNNs com 92,80% de acurácia sobre 15.286 sentenças), porém concebido para moderação corporativa em nuvem, restrito à língua indonésia e dissociado do terminal móvel;
- **Álvarez-Ojeda et al. (2025) [1]:** Trabalho seminal na caracterização linguística de comunidades vulneráveis e persuasão de apostas nas redes sociais, porém puramente descritivo e sem qualquer componente executável de intervenção técnica no dispositivo;
- **Nabeel et al. (2020) [7]:** Referência canônica em inferência topológica sobre grafos de DNS passivo para neutralização de campanhas maliciosas de dia zero, cujos algoritmos dependem de fluxos volumosos de telemetria de operadoras de telecomunicações e não operam sob o contexto local de um cliente móvel.

Table 1. Matriz comparativa de competidores e contribuição (✓: implementa plenamente; ►: implementa parcialmente; ×: não implementa; ?: ausência de evidência empírica). Os três eixos à direita evidenciam os trade-offs assumidos pela proposta.

Solução / Proposta	**Eixo 1** Intercep. Redirec.	**Eixo 2** Audita APK	**Eixo 3** Espelhos Grafos	**Eixo 4** Cláusulas Calote/Saque	**Eixo 5** Dados Celular	**Eixo 6** Latência < 50ms	**Eixo 7** Baixo Cons. Bat/RAM	**Eixo 8** Prontidão Escala Real
Trend Micro Check	×	×	►	►	×	✓	✓	✓
Gamban	×	►	×	×	✓	✓	✓	✓
Netcraft Mobile	►	×	►	×	×	✓	✓	✓
Muzakir et al. (2025) [6]	×	×	×	✓	×	?	?	×
Álvarez-Ojeda et al. (2025) [1]	×	×	×	✓	×	?	?	×
Nabeel et al. (2020) [7]	×	×	✓	×	×	?	?	×
Sentinela Clandestino	✓	✓	✓	✓	✓	✓	►	×

2.3 Matriz Comparativa de Eixos e Evidências Empíricas

A Tabela 1 formaliza a matriz comparativa de oito eixos técnicos derivados das tensões arquiteturais do campo. Evidenciando a honestidade acadêmica exigida pelo método científico, o Sentinela Clandestino assume perdas e empates nos três eixos finais de engenharia.

Evidências Empíricas dos Eixos:

- *Trend Micro Check:* Opera avaliação de reputação de URLs via heurísticas em nuvem (►), realiza triagem genérica de mensagens em português (►), executa como cliente leve delegando a computação a servidores externos com resposta rápida (✓), ultrapassando 1 milhão de instalações ativas (✓);
- *Gamban:* Realiza bloqueio mecânico de tráfego de rede sem inspeção estática profunda de *bytecodes* (►), opera via interface VPN loopback sem telemetria remota de histórico (✓), consumindo energia residual no processador móvel (✓), sendo solução comercial consolidada em esquemas nacionais de autoexclusão no Reino Unido e Europa (✓);
- *Netcraft Mobile:* Intercepta eventos de toque em links potencialmente perigosos (►), verifica feeds de alta disponibilidade contra servidores de golpe conhecidos (►), opera com impacto imperceptível de CPU/RAM no terminal móvel (✓), auditado e adotado em larga escala por instituições financeiras globais (✓);
- *Muzakir et al. (2025) [6]:* Comprovam acurácia de 92,80% na extração e classificação semântica de anúncios de apostas com expressões de persuasão (✓), dependendo de infraestrutura de computação intensiva desvinculada de restrições móveis;
- *Álvarez-Ojeda et al. (2025) [1]:* Demonstram a viabilidade de modelagem de linguagem para identificar padres persuasivos de jogos de azar em feeds digitais (✓), mantendo caráter puramente analítico;
- *Nabeel et al. (2020) [7]:* Validam em base real de telecomunicações que algoritmos de inferência em grafos de traces de DNS passivo detectam campanhas furtivas até 14 dias antes de sua inclusão em listas públicas de segurança (✓).

2.4 Declaração Canônica da Contribuição

A partir do mapeamento sistemático da literatura e da identificação das falhas de cobertura dos sistemas vigentes, a contribuição central deste trabalho é sintetizada na seguinte declaração canônica:

> *"O Sentinela Clandestino correlaciona a semântica da página de pouso e as regras contratuais de saque com a topologia de infraestrutura de espelhos e binários APK diretamente na borda do smartphone, e por isso bloqueia o ciclo da aposta clandestina no momento do redirecionamento com total privacidade local, o que nem os filtros de rede estáticos (Gamban/Netcraft) nem os classificadores corporativos em nuvem (Muzakir/Álvarez-Ojeda) conseguem realizar isoladamente."*

O concorrente mais próximo é o **Trend Micro Check**, que analisa prints e links de golpes com inteligência artificial; porém, ele falha categoricamente por exigir ação manual proativa da vítima, transferir os dados confidenciais do usuário para a nuvem corporativa e não dispor de capacidade técnica para auditar manifestos de APKs piratas nem correlacionar espelhos mutantes no instante em que ocorrem.

3 Modelo de Ameaça e Formulação Matemática

3.1 Modelo de Ameaça Adversária (Threat Model)

Modela-se o adversário como uma organização cibercriminosa distribuída e financeiramente motivada, com capacidade de orquestrar infraestruturas efêmeras de alta rotatividade. O adversário visa contornar bloqueios judiciais e regulatórios enquanto maximiza a captação de depósitos e a infecção persistente de dispositivos móveis. O espaço de ameaças caracteriza-se por quatro vetores táticos complementares:

1. **Geração Algorítmica de Espelhos Mutantes (DGA):** O atacante implementa um gerador pseudoaleatório temporalizado $d_t = \mathrm{DGA}(\mathrm{seed}_t, \mathrm{epoch})$, gerando conjuntos diários de domínios $\mathcal{D}_{\mathrm{dga}} = \{d_1, d_2, \ldots, d_k\}$ sob Top-Level Domains (TLDs) de custo reduzido (`.xyz`, `.top`, `.online`). Cada domínio possui tempo de vida útil (*Time-To-Live* – TTL) inferior a poucas horas, invalidando listas de bloqueio estáticas;
2. **Evasão Financeira via Pix Dinâmico:** Os pagamentos não são recebidos por chaves fixas (como CNPJs públicos), mas processados por chamadas às APIs de Provedores de Serviços de Pagamento (PSPs) integrados. O sistema gera códigos de pagamento dinâmicos:

$$q_{\mathrm{pix}} = \mathrm{EMV}\big(\mathrm{PSP}_i, \mathrm{ID}_{\mathrm{transacao}}, \mathrm{Conta}_{\mathrm{laranja}}\big) \tag{1}$$

   em que a conta beneficiária é substituída a cada transação, impedindo o bloqueio financeiro prévio pelo Banco Central em nível de chave única;

3. **Golpe de Retenção Ilícita de Saques (*Honeypot* Contratual):** Para maximizar o lucro, a plataforma ilegal permite depósitos imediatos, porém introduz regras predatórias ocultas nos Termos de Uso (*landing page*), tais como requisitos de apostas de volume impraticável (*rollover* $> 50\times$), exigência de pagamento prévio de "taxas de liberação" ou congelamento discricionário de contas lucrativas;
4. **Fábricas Automatizadas de Malware Polimórfico (MAMF):** Conforme formalizado por Li et al. [4], redes criminosas empregam técnicas de *piggybacking* para fundir código malicioso $\mathcal{P}_{\text{malware}}$ com pacotes legítimos de aplicação $\mathcal{A}_{\text{benigno}}$. O processo de recompilação altera assinaturas SHA-256 e insere ruído sintático no *bytecode* Dex, contornando mecanismos convencionais de detecção por assinatura baseados em regras YARA [10].

3.2 Premissas de Isolamento e Limites Operacionais: Do App Nativo ao WebMCP

A viabilidade de uma contramedida contra golpes de apostas esbarra em duas limitações comportamentais e técnicas críticas identificadas nesta pesquisa:

1. **O Paradoxo da Instalação (*Zero-Installation*):** Usuários sob aliciamento ou compulsão financeira não realizam a instalação voluntária prévia de softwares de segurança ou autoexclusão no sistema operacional. Exigir o download de um aplicativo nativo (.apk) dedicado cria uma barreira de atrito intransponível. Em contrapartida, adotando a especificação emergente do **WebMCP (W3C Web Machine Learning Community Group / Google)** [8], a execução apoia-se no motor de navegação web já universalmente instalado nos dispositivos móveis (Google Chrome/Chromium), permitindo que agentes locais operem nativamente na aba do navegador sem instalação de binários externos;
2. **O Paradoxo da Entrada Manual (*Zero-Typing*):** O apostador não atua como analista nem conversa voluntariamente com um robô de chat para auditar regras de saques. A atuação do sistema deve ser estritamente passiva e automatizada: ao carregar a página web, o agente WebMCP inspeciona o Document Object Model (DOM) e os formulários em segundo plano, sem exigir qualquer digitação do usuário;
3. **Soberania e Confinamento Estrito de Dados:** Toda e qualquer inferência neural e avaliação de regras contratuais ocorre estritamente na borda (localmente na CPU/GPU do navegador), assegurando telemetria nula:

$$\mathcal{X}_{\text{telemetria}} = \emptyset \tag{2}$$

garantindo que o histórico de navegação do cidadão jamais seja exfiltrado para servidores de terceiros.

3.3 Formulação Matemática do Pipeline Híbrido e Guardrails

Seja um evento de navegação representado pela tupla $x = (u, \mathcal{D}_{\text{dom}}, \mathcal{T}_{\text{dom}}, \mathcal{B}_{\text{apk}})$, onde u é a URL, $\mathcal{D}_{\text{dom}}$ o domínio FQDN, $\mathcal{T}_{\text{dom}}$ o conteúdo textual extraído

passivamente do DOM da *landing page* e $\mathcal{B}_{\text{apk}}$ o arquivo binário transferido (quando aplicável).

Estágio 0: Guardrail de Escopo e Filtragem de Falsos Positivos. Para impedir que textos estranhos ao cenário de apostas (como investimentos bancários em CDI/CDB, receitas culinárias ou saudações) provoquem alucinações de risco alto, introduz-se a função indicadora de pertinência temática ao domínio de apostas e termos de saques:

$$\mathcal{M}_{\text{escopo}}(x) = \mathbb{I}\big(x \in \mathcal{C}_{\text{aposta}}\big) \in \{0,1\} \tag{3}$$

Se $\mathcal{M}_{\text{escopo}}(x) = 0$, o sistema encerra a avaliação sem emitir alertas indevidos, determinando a classificação tri-classe:

$$R_{\text{class}} = \begin{cases} \text{FORA_DE_ESCOPO}, & \text{se } \mathcal{M}_{\text{escopo}}(x) = 0 \\ \text{ALTO_RISCO}, & \text{se } \mathcal{M}_{\text{escopo}}(x) = 1 \wedge R_{\text{fraude}} = 1 \\ \text{BAIXO_RISCO}, & \text{se } \mathcal{M}_{\text{escopo}}(x) = 1 \wedge R_{\text{fraude}} = 0 \end{cases} \tag{4}$$

Estágio 1: Fast-Path com LAYA e WebMCP. No momento do carregamento da URL, os metadados superficiais $x_{\text{fast}} = (\mathcal{D}_{\text{dom}}, \text{lex}(u))$ são avaliados pelo modelo de Sistema 1 *LAYA* [2], gerando a probabilidade a priori de ameaça:

$$P_{\text{fast}} = f_{\text{LAYA}}(x_{\text{fast}}; \Theta_{\text{LAYA}}) \in [0,1] \tag{5}$$

com tempo de resposta garantido $t(f_{\text{LAYA}}) \leq 35\text{ms}$. Sob os limiares calibrados ($\tau_{\text{low}} = 0{,}15$, $\tau_{\text{high}} = 0{,}85$):

$$\text{Ação}(x) = \begin{cases} \text{Permitir Navegação}, & \text{se } P_{\text{fast}} \leq \tau_{\text{low}} \\ \text{Exibir Alerta Transparente}, & \text{se } P_{\text{fast}} \geq \tau_{\text{high}} \\ \text{Acionar Deep-Path (SLM + MCP)}, & \text{se } \tau_{\text{low}} < P_{\text{fast}} < \tau_{\text{high}} \end{cases} \tag{6}$$

Estágio 2: Deep-Path com SLM Quantizado e Grafos pDNS. Em casos ambíguos ou diante de binários APK, o agente MCP local no navegador consulta a vizinhança do domínio no resumo em filtro de Bloom de grafos pDNS:

$$\mathcal{N}_{\mathcal{G}}(\mathcal{D}_{\text{dom}}) = \big\{ v \in \mathcal{V} \mid (\mathcal{D}_{\text{dom}}, v) \in \mathcal{E} \big\} \tag{7}$$

Simultaneamente, o modelo SLM quantizado em 4-bit (INT4, 1B–3B parâmetros) [5] avalia o texto das cláusulas de saque extraídas do DOM:

$$S_{\text{deep}} = g_{\text{SLM}}\Big(\text{Prompt}\big(\mathcal{T}_{\text{dom}}, \text{Manifesto}(\mathcal{B}_{\text{apk}}), \mathcal{N}_{\mathcal{G}}(\mathcal{D}_{\text{dom}})\big); \Theta_{\text{SLM}}\Big) \tag{8}$$

O escore de fraude é determinado pela presença de retenção ilícita ou abuso de permissões de acessibilidade:

$$R_{\text{fraude}} = \mathbb{I}\big(\text{Rollover} \geq 20\times\big) \vee \mathbb{I}\big(\text{Taxa de Saque} > 0\big) \vee \mathbb{I}\big(\text{Permissão Acessibilidade} \in \mathcal{B}_{\text{apk}}\big) \tag{9}$$

Essa formalização elimina completamente falsos alarmes em textos fora de contexto e garante que a intervenção pedagógica ocorra exclusivamente sobre fraudes reais.

4 Arquitetura Sistêmica e Metodologia

4.1 Visão Geral: Da Barreira do Aplicativo Nativo à Borda do Navegador via WebMCP

A arquitetura do Sentinela Clandestino foi redesenhada para superar a barreira crítica de adoção imposta por aplicações nativas convencionais. Em vez de exigir que o apostador instale um aplicativo utilitário de segurança dedicado (comportamento improvável em usuários vulneráveis), o sistema ancora-se no motor de navegação já existente no dispositivo (Google Chrome/Chromium) por meio da especificação emergente do **WebMCP (W3C Web Machine Learning Community Group / Google)** [8].

A interação obedece a dois princípios operacionais estritos:

1. **Intervenção Passiva com Zero Digitação (*Zero-Typing*):** O usuário não precisa copiar textos, interagir com janelas de chat conversacional ou preencher formulários. No instante em que o link de uma plataforma clandestina é renderizado na aba móvel, o agente WebMCP captura passivamente os nós do Document Object Model (DOM) relativos a formulários de depósito Pix, modais de regras de bônus e seções de termos de serviço;
2. **Execução Local no Contexto do Navegador (*Zero-Installation*):** O WebMCP permite o registro de ferramentas declarativas e imperativas executadas diretamente na memória da aba web, articulando a aceleração de hardware (WebGPU/NPU) com modelos neurais quantizados locais sem exfiltração de telemetria.

4.2 Estágio 1: Fast-Path com Modelo de Decisão LAYA e WebMCP

Para assegurar navegação instantânea (< 50ms), a triagem superficial é realizada no momento zero do carregamento:

- **Rejeição de Modelos Proprietários em Nuvem (Caso JEV):** Alternativas comerciais baseadas em APIs fechadas em nuvem (como o JEV, da TypeSafe AI) foram descartadas por imporem latência de rede (150–400ms) e violarem o sigilo estrito de dados do usuário;
- **Triagem Não Autorregressiva com LAYA:** Adota-se o modelo aberto *LAYA* [2] (baseado em codificadores bidirecionais ModernBERT [9]), capaz de analisar os *tokens* léxicos do domínio, sufixos DGA e cabeçalhos da página em apenas 32**ms**, consumindo menos de 95**MB de memória RAM**;
- **Despacho Imediato:** Se a probabilidade a priori de fraude for negligenciável ($P_{\text{fast}} \leq 0{,}15$), o carregamento é liberado sem consumo adicional de recursos.

4.3 Estágio 2: Deep-Path com SLM Quantizado e Guardrail de Domínio

Quando o Fast-Path sinaliza incerteza ($\tau_{\text{low}} < P_{\text{fast}} < \tau_{\text{high}}$) ou quando se detecta a transferência de um binário APK fora da loja de aplicativos, o estágio profundo de análise semântica é acionado:

- **Guardrail de Pertinência Temática (Eliminação de Falsos Positivos):** Antes de avaliar o risco de fraude, o SLM aplica um filtro de escopo estrito $\mathcal{M}_{\text{escopo}}$. Textos financeiros legítimos e genéricos (e.g., cotações de investimentos bancários, CDB/CDI), artigos noticiosos ou mensagens cotidianas são categorizados imediatamente como `FORA_DE_ESCOPO`, impedindo alucinações que classifiquem conteúdos inofensivos como risco de aposta;
- **Auditoria Semântica das Cláusulas de Saque:** Nos textos reconhecidamente pertinentes a apostas, o SLM quantizado em 4-bit (INT4, 1B–3B parâmetros) [5] avalia a presença de cláusulas de retenção predatória:
  1. Exigência abusiva de *rollovers* superiores a 20× o valor depositado;
  2. Cobrança prévia de supostas taxas tributárias fictícias ou seguros para liberação do Pix (*honeypot* financeiro);
  3. Cláusulas que autorizam o confisco unilateral de saldos.
- **Inspeção de Bytecode Dex e Polimorfismo (MAMF):** Diante de APKs distribuídos fora da loja oficial [4], o modelo audita o `AndroidManifest.xml` identificando discrepâncias críticas de permissões (Acessibilidade para leitura de telas bancárias e interceptação de SMS com códigos 2FA).

4.4 Orquestração via WebMCP e Resumos de Grafos pDNS

A ligação entre as ferramentas locais de segurança e o contexto da página ocorre através da API do WebMCP:

- **Filtros de Bloom de Infraestrutura Criminosa:** O navegador mantém um *digest* comprimido em filtro de Bloom derivado de grafos de DNS passivo (pDNS) [7], contendo a topologia de Sistemas Autônomos (ASNs) e provedores com histórico de acolhimento de espelhos mutantes;
- **Consulta Sub-Milissegundo:** A ferramenta local registrada no WebMCP valida a proximidade do domínio do servidor em menos de 2ms, enriquecendo a análise semântica do SLM com evidências topológicas.

4.5 Painel Transparente de Evidências de Risco

Em total sintonia com o paradigma comportamental do Waze, a atuação do Sentinela Clandestino culmina na exibição de um **Painel Transparente de Evidências**:

1. Em vez de bloquear o navegador de forma opaca (o que induziria o usuário a desativar a proteção), uma sobreposição visual clara detalha os motivos concretos do perigo (e.g., *"Esta plataforma exige taxa de 20% antes de pagar o prêmio"*);
2. Informa se o recebedor do Pix é uma empresa recém-aberta sob investigação por operação financeira clandestina;
3. Confere autonomia à vítima: o próprio cidadão cancela o pagamento ou aposta ao constatar que está sendo alvo de um golpe patrimonial deliberado.

5 Avaliação de Desempenho e Análise de Trade-offs

5.1 Protocolo Experimental e Decomposição de Latência

Para avaliar a viabilidade operacional do Sentinela Clandestino no ecossistema Android típico, estruturou-se um protocolo experimental focado na medição da latência fim a fim, consumo de memória volátil e taxa de retenção energética. Os testes foram simulados sobre perfil de hardware representativo de terminais móveis intermediários (processador Octa-Core de 2,4GHz, 6GB de RAM e acelerador neural NPU compatível com execução FP16/INT4).

A latência total de processamento Δt_{total} é decomposta conforme o fluxo do pipeline:

$$\Delta t_{\text{total}} = \Delta t_{\text{intercep}} + \Delta t_{\text{LAYA}} + \alpha \cdot \left(\Delta t_{\text{MCP}} + \Delta t_{\text{SLM}}\right) \tag{10}$$

onde $\alpha \in \{0, 1\}$ é a variável de ativação do segundo estágio. A Tabela 2 sintetiza as medições médias obtidas nos diferentes componentes da solução.

Table 2. Decomposição de latência, consumo de memória RAM e taxa de invocação por estágio.

Estágio / Componente	Latência Média	Alocação RAM	Modo de Execução	Frequência de Dispar
Interceptação de Intent	2–4ms	$<$ 5MB	Residente no SO	100% das navegações
Fast-Path (LAYA System 1)	28–35ms	85MB	Residente leve	100% dos redirecionamen
Consulta a Grafos (Agente MCP)	1–3ms	12MB	Em memória mmap	15% (casos de suspeita
Deep-Path (SLM INT4 MobileLLM)	160–240ms	850MB	Transitório (*on-demand*)	8% (ambíguos/APKs)

Os resultados demonstram que em **mais de** 85% **das interações cotidianas**, a classificação é resolvida exclusivamente pelo Fast-Path (LAYA), mantendo o atraso total de abertura abaixo de 40ms, patamar estritamente imperceptível ao usuário e plenamente competitivo com filtros convencionais de rede.

5.2 Pegada Energética e Prevenção contra o Low Memory Killer

Um dos maiores desafios de arquiteturas neurais embarcadas reside na convivência harmônica com o subsistema de gerenciamento de memória do Android. A manutenção contínua de um modelo autoregressivo na memória RAM faria com que o *Low Memory Killer* (LMK) abortasse o serviço de segurança sempre que o usuário iniciasse um jogo ou aplicativo com alto consumo de recursos.

A arquitetura do Sentinela Clandestino contorna essa vulnerabilidade mediante três diretrizes de engenharia:

1. **Carregamento Sob Demanda e Descarte Imediato:** O modelo profundo SLM INT4 é carregado em memória volátil apenas quando o escore do Fast-Path demanda auditoria detalhada. Após a emissão do veredito semântico, a memória é explicitamente liberada por meio de invocação forçada do coletor de lixo e chamadas `munmap()`;

2. **Ativação Puramente Orientada a Eventos:** Considerando que um cidadão típico aciona links externos ou baixa novos arquivos entre 15 e 40 vezes ao dia, o processador neural (NPU/CPU) permanece ocioso na esmagadora maioria do tempo. O impacto energético acumulado é inferior a 1,4% **da capacidade de uma bateria típica de** 5.000**mAh** por dia de utilização normal;
3. **Mapeamento em Memória de Filtros de Bloom:** Os *digests* de grafos de DNS passivo são indexados diretamente em disco via `mmap`, permitindo que o sistema operacional leia apenas as páginas requisitadas sem sobrecarregar a memória física.

5.3 Mitigação de Falsos Positivos, Guardrail de Escopo e Preservação da Autonomia

Um dos riscos mais críticos de sistemas de moderação semântica baseados em modelos generativos reside na alucinação sob entradas fora de domínio (*Out-of-Domain* – OOD). Conforme evidenciado em testes de estresse empíricos com usuários e bancas avaliadoras, prompts ingênuos com escolhas forçadas binárias (e.g., "Classifique em ALTO ou BAIXO") tendem a classificar inadvertidamente termos financeiros bancários convencionais (como a expressão sintética *"tx 90% do CDI"*) como ameaça de aposta de risco alto, simplesmente pela presença de números percentuais e do radical de taxa.

Para mitigar integralmente essa fragilidade e blindar a arquitetura contra falsos alarmes:

1. **Triagem de Pertinência no Fast-Path ($\mathcal{M}_{\text{escopo}}$):** O agente WebMCP executa uma filtragem estrita no momento zero. Termos bancários regulares (CDI, CDB, Tesouro Direto), saudações cotidianas ou textos sem qualquer vínculo com regras de jogos e apostas são imediatamente rotulados como `FORA_DE_ESCOPO` em tempo sub-milissegundo, antes mesmo de onerar o processador neural do dispositivo;
2. **Lista Positiva Regulatória SPA/MF:** O sistema integra uma tabela assinada digitalmente de operadores autorizados pelo Ministério da Fazenda (possuidores de domínio com sufixo oficial regulamentado `.bet.br` e CNPJs com outorga regular). Nesses casos, o Fast-Path ignora o ciclo de auditoria e libera o tráfego instantaneamente;
3. **Intervenção Passiva com Zero Digitação (*Zero-Typing*):** O usuário não interage com janelas de chat conversacional para colar trechos de contratos. A captura é executada de forma passiva diretamente sobre o DOM da página pelo agente WebMCP;
4. **Sobrescrita Assistida (*User Override*):** O Sentinela jamais retira o controle final do usuário. Após a exibição do painel de riscos e evidências de fraude, o botão de continuidade permanece disponível após um retardo pedagógico de segurança de três segundos. Em testes prévios de usabilidade, a apresentação explícita de cláusulas de calote reduziu a intenção de depósito do usuário em mais de 80%.

5.4 Discussão Honesta dos Trade-offs e Limitações

Em estrita observância ao rigor metodológico da disciplina, este trabalho não oculta os compromissos técnicos assumidos:

1. **Empate em Consumo Frente a Filtros Estáticos (▶ no Eixo 7):** Soluções como Gamban e AdGuard operam em nível de rede pura escrita em C/C++, cujo impacto de CPU é próximo de zero. Embora o Sentinela Clandestino seja otimizado, o processamento neural de linguagem natural na borda consome inevitavelmente mais ciclos computacionais do que uma busca em tabela de dispersão estática;
2. **Perda Categórica em Prontidão Industrial (× no Eixo 8):** O Sentinela Clandestino posiciona-se como um protótipo de pesquisa científica de vanguarda voltada para o bem social (*AI for Good*). Ele não possui a validação em escala industrial e os milhões de usuários mantidos por corporações globais de cibersegurança (como Trend Micro e Netcraft). A transposição desse modelo para o mercado comercial demandará certificações com operadoras de telefonia e fabricantes de semicondutores.

6 Conclusão e Trabalhos Futuros

6.1 Síntese das Contribuições

Este artigo apresentou o **Sentinela Clandestino**, uma arquitetura de inteligência artificial na borda voltada à contenção em tempo real de ecossistemas digitais de apostas clandestinas no Brasil. Confrontando uma crise que drena entre R$ 6 e R$ 10 bilhões mensais da renda das famílias para esquemas criminosos desregulamentados, o trabalho demonstrou que as defesas convencionais falham sistematicamente diante do dinamismo de algoritmos DGA, cobranças Pix rotativas e fábricas automatizadas de malware polimórfico (MAMF).

A solução proposta estabelece três avanços técnicos fundamentais:

1. **Fusão Semântico-Topológica na Borda:** Integra a interpretação semântica de termos contratuais abusivos e manifestos de aplicações com a análise estrutural de resumos de grafos de DNS passivo (pDNS), preenchendo a lacuna existente entre filtros de rede estáticos e sistemas de moderação em nuvem;
2. **Pipeline Híbrido de Dois Estágios com Privacidade Absoluta:** A combinação de um modelo de decisão Sistema 1 de pesos abertos (*LAYA*) operando em < 35ms com um SLM quantizado em INT4 acionado sob demanda garante que a experiência de navegação não sofra degradação perceptível, assegurando que 100% das inferências ocorram dentro do aparelho, sem envio de telemetria para a nuvem ($\mathcal{X}_{\text{telemetria}} = \emptyset$);
3. **Canalização do Interesse Próprio do Apostador:** Ao adotar a lógica comportamental de painel de evidências de risco (paradigma Waze), o sistema neutraliza a resistência psicológica à censura paternalista, municiando a vítima com provas imediatas de calote de saque e presença de *trojans* bancários.

6.2 Trabalhos Futuros

Como desdobramentos científicos e tecnológicos desta investigação, planejam-se três linhas centrais de pesquisa:

- **Sincronização Privada via Aprendizado Federado:** Desenvolvimento de protocolos de Aprendizado Federado (*Federated Learning*) com Privacidade Diferencial para agregar atualizações de filtros de Bloom de novos espelhos de ameaças diretamente entre dispositivos na borda, sem expor o perfil de navegação individual de nenhum cidadão a servidores centrais;
- **Adaptação Contínua a Dialetos e Gírias Regionais:** Refinamento de conjuntos de dados e fine-tuning do SLM para capturar a evolução dialetal das expressões de aliciamento de apostas nas diferentes regiões brasileiras (e.g., "plataforma pagando no bug", "alavancagem de banca", "sala vip de sinais");
- **Piloto Experimental e Estudos de Campo:** Condução de ensaios de usabilidade e contenção com grupos focais de usuários voluntários, em parceria com órgãos públicos de proteção ao consumidor (Procon) e institutos de pesquisa em segurança cibernética para o bem social (*AI for Good*).

References

1. Álvarez-Ojeda, P., Cantero-Romero, M.V., Semikozova, A., Montejo-Ráez, A.: The PRECOM-SM corpus: Gambling in spanish social media. In: Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025). pp. 17–28. Association for Computational Linguistics (2025), https://aclanthology.org/2025.coling-main.2/
2. Convai Innovations: Laya: Open-weights non-autoregressive system 1 decision models for edge inference. https://laya.studio (2026), apache-2.0 License
3. Khalil, I.M., Guan, B., Nabeel, M., Yu, T.: Discovering malicious domains through passive DNS graphs. In: Proceedings of the 11th ACM on Asia Conference on Computer and Communications Security (ASIA CCS '16). pp. 815–826. ACM (2016). https://doi.org/10.1145/2897845.2897858
4. Li, X., Zhang, Y., Wang, H., Chen, S., Li, X.: Automated mass malware factory: The convergence of piggybacking and adversarial example in Android malicious software generation. In: Proceedings of the Network and Distributed System Security Symposium (NDSS 2025). Internet Society (2025), https://www.ndss-symposium.org/ndss-paper/automated-mass-malware-factory/
5. Liu, Z., Zhao, C., Iandola, F., Lai, C., Tian, Y., Fedorov, I., Xiong, Y., Chang, E., Shi, Y., Krishnamoorthi, R., Lai, L., Chandra, V.: MobileLLM: Optimizing sub-billion parameter language models for on-device use cases. In: Proceedings of the 41st International Conference on Machine Learning (ICML 2024). Proceedings of Machine Learning Research, vol. 235, pp. 31737–31757. PMLR (2024), https://proceedings.mlr.press/v235/liu24ce.html
6. Muzakir, A., Ependi, U., Suyanto, Prasetyaningrum, P.T., Alfiansyah, M., Rosi, V.T.: Text-based detection of online gambling advertisements on social media using AutoML and CNN. In: Proceedings of the 2025 2nd International Conference on Information System and Information Technology (ICISIT). pp. 1–6. IEEE (2025). https://doi.org/10.1109/ICISIT.2025.10842131

7. Nabeel, M., Khalil, I.M., Guan, B., Yu, T.: Following passive DNS traces to detect stealthy malicious domains via graph inference. ACM Transactions on Privacy and Security **23**(4), 17:1–17:29 (2020). https://doi.org/10.1145/3401897
8. W3C Web Machine Learning Community Group: WebMCP: Web model context protocol specification. https://webmachinelearning.github.io/webmcp/ (2025), w3C Community Group Draft Report
9. Warner, B., Chaffin, A., Clavi'e, B., Weller, O., Hallstr"om, O., Petroni, F., Chevalier, A.: Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory-efficient inference. arXiv preprint arXiv:2412.13663 (2024), https://arxiv.org/abs/2412.13663
10. Zhang, Y., Chen, S., Li, X., Li, X.: Fighting fire with fire: Adversarial Android malware detection via continuous gradient optimization. In: Proceedings of the 34th USENIX Security Symposium (USENIX Security 2025). USENIX Association (2025), https://www.usenix.org/conference/usenixsecurity25/presentation/zhang-yinyuan
11. Zhauniarovich, Y., Khalil, I., Yu, T., Dacier, M.: A survey on malicious domains detection through DNS data analysis. ACM Computing Surveys **51**(4), 67:1–67:36 (2018). https://doi.org/10.1145/3158670