Sentinela Clandestino: Detecção de Aliciamento de Apostas Ilegais e Mitigação de Espelhos Mutantes na Borda via SLMs e Grafos de Ameaças

José Albérico Rocha da Silva[1]

Universidade Federal Rural de Pernambuco (UFRPE)
Departamento de Computação – Tópicos Avançados em Inteligência Artificial (2026.2)
Recife - PE, Brasil
jose.alberico@ufrpe.br
https://github.com/albericolx/Topicos_Avancados_IA

Abstract. Este relatório técnico formaliza a concepção, fundamentação bibliográfica e análise comparativa do projeto **Sentinela Clandestino (Vigilante de Espelhos e APKs)**, correspondente às etapas de Brainwriting Híbrido (`brw`) e Competidores e Contribuição (`cmp`) da Segunda Verificação de Aprendizagem (VA2) na disciplina Tópicos Avançados em Inteligência Artificial (UFRPE 2026.2). Diante da crise crônica de endividamento financeiro e proliferação de plataformas de apostas ilegais que burlam bloqueios governamentais via domínios espelhos mutantes e distribuição clandestina de APKs nas redes sociais, propõe-se uma arquitetura de proteção reativa na borda (*on-device*). O sistema intercepta tentativas de redirecionamento para URLs externas e transferências de executáveis no momento do clique, empregando um Modelo de Linguagem de Pequeno Porte (SLM) quantizado localmente para análise semântica da página de pouso e inspeção de manifestos de aplicação, orquestrado por agentes locais via *Model Context Protocol* (MCP) que consultam resumos de grafos de DNS passivo. A contribuição é rigorosamente delimitada frente a dez ferramentas comerciais e dez artigos científicos de ponta, assumindo honestamente perdas operacionais categóricas em latência de redirecionamento (100–300ms), consumo contínuo de memória e escala de produção frente a filtros estáticos leves.

Keywords: Apostas Clandestinas · Engenharia Social · Small Language Models · On-Device AI · Grafos de DNS Passivo · Segurança Mobile · AI for Good.

1 Introdução

A proliferação desregulada de plataformas clandestinas de apostas digitais (*bets* ilegais) estabeleceu uma das mais severas crises socioeconômicas e de saúde financeira pública no Brasil contemporâneo. Estima-se que dezenas de bilhões de

reais sejam drenados anualmente do orçamento de famílias vulneráveis para redes criminosas de apostas que operam à margem do arcabouço fiscal e jurídico instituído pelos órgãos reguladores nacionais (Ministério da Fazenda e Anatel). A subsequente repressão governamental mediante ordens de bloqueio judicial e suspensão de operadoras não licenciadas não extinguiu a atividade; pelo contrário, empurrou o ecossistema predatório para o submundo da camuflagem digital contínua.

Nesse cenário de clandestinidade, operadores ilegais orquestram campanhas massivas de aliciamento em redes sociais e mensageria instantânea (Instagram, TikTok, Telegram e WhatsApp), promovendo supostas "brechas de algoritmo" e "salas de sinais" lucrativas. Para contornar os bloqueios de DNS de nível governamental impostos às operadoras de telecomunicações, os aliciadores distribuem hiperlinks dinâmicos que redirecionam o usuário para domínios espelhos mutantes de registro efêmero (domínios gerados por DGA sob TLDs permissivos como `.xyz` ou `.top`) e induzem a instalação de pacotes de aplicação fora da loja oficial (*side-loading* de binários APK piratas). Essa prática expõe o cidadão a um duplo vetor de risco: o endividamento compulsivo imediato e a contaminação do terminal móvel por *trojans* bancários e *spywares* camuflados [2].

As defesas computacionais convencionais enfrentam limitações estruturais críticas frente a esse ataque:

1. **Cegueira Semântica de Filtros Estáticos:** Soluções clássicas de autoexclusão e bloqueio (como Gamban e BetBlocker) baseiam-se em tabelas e listas de domínios previamente catalogados. Tais mecanismos falham sistematicamente contra espelhos de dia zero que entram em operação minutos antes de uma campanha de aliciamento;
2. **Comprometimento da Privacidade por Triagem em Nuvem:** Ferramentas heurísticas baseadas em IA comercial (ex.: Trend Micro Check) dependem do envio de capturas de tela e URLs para servidores remotos, exigindo a ação manual da vítima e expondo dados sensíveis de navegação a infraestruturas corporativas centralizadas;
3. **Inviabilidade de Escrutínio de Feeds Fechados:** A arquitetura de segurança do sistema operacional Android impõe *sandboxing* rígido e conexões criptografadas (*TLS pinning*) entre aplicativos de redes sociais, inviabilizando que aplicações clientes terceiras realizem a leitura passiva de fluxos internos de conteúdo sem a violação de permissões do sistema.

Para superar essas barreiras sem violar o modelo de segurança do sistema operacional e sem violar a privacidade do usuário, propõe-se o **Sentinela Clandestino (Vigilante de Espelhos e APKs)**, concebido no âmbito das atividades de ideação e investigação da disciplina de Tópicos Avançados em Inteligência Artificial (VA2). O sistema intervém na camada de redirecionamento de rede do dispositivo móvel: ao detectar tentativas de acesso a URLs externas ou *downloads* de arquivos binários com origem em redes sociais, dispara um Modelo de Linguagem de Pequeno Porte (*Small Language Model* – SLM) executado integralmente no hardware do smartphone (*on-device*) [3]. O modelo avalia a semântica persuasiva da página de pouso (*landing page*) e o manifesto do APK,

orquestrado por agentes locais via *Model Context Protocol* (MCP) que consultam grafos de infraestrutura de DNS passivo [5]. Desta forma, estanca-se o ciclo da aposta clandestina no momento do clique, conferindo proteção ativa e total soberania de dados ao usuário.

2 Trabalhos Relacionados e Matriz de Contribuição

A delimitação da fronteira tecnológica do Sentinela Clandestino fundamenta-se na análise comparativa de dez ferramentas de mercado e dez artigos científicos recentes, avaliados segundo as dimensões de Cenário, Usuário, Problema e Tecnologia (CUPT). A partir desse levantamento, selecionaram-se os três competidores de mercado e as três referências bibliográficas mais próximas.

2.1 Competidores de Mercado e Literatura Mais Próximos

- **Trend Micro Check:** Constitui o concorrente mais direto na interação móvel, utilizando IA para analisar prints e mensagens suspeitas. Entretanto, depende de ação voluntária e manual do usuário, processa dados na nuvem corporativa e não intercepta ativamente espelhos mutantes no ato do redirecionamento;
- **Gamban:** Referência global em autoexclusão de apostas digitais com bloqueio rígido em nível de rede local (via VPN loopback). Contudo, opera estritamente sobre listas estáticas de domínios consolidados, sendo totalmente ineficaz contra domínios efêmeros e APKs clandestinos;
- **Netcraft Mobile:** Solução líder em proteção contra ataques de *phishing* e *smishing* com inspeção no momento do toque, mas sem compreensão de engenharia social focada na linguagem informal de aliciamento de apostas no Brasil;
- **Muzakir et al. (2025) [4]:** Empregam CNNs e AutoML sobre 15.286 sentenças extraídas de anúncios de apostas em redes sociais (92,80% de acurácia). Contudo, o sistema foi desenhado para moderação centralizada na nuvem voltada à língua indonésia, não atuando no terminal móvel;
- **The PRECOM-SM Corpus (Álvarez-Ojeda et al., 2025) [1]:** Primeiro corpus de referência no COLING 2025 para identificar marcadores de dependência de apostas em redes sociais hispânicas, limitando-se à análise descritiva de comunidades sem mecanismo ativo de contenção de rede ou APKs;
- **Nabeel et al. (2020) [5]:** Propõem algoritmos de inferência em grafos de DNS passivo (pDNS) no *ACM TOPS* para rastrear infraestruturas de domínios maliciosos antes de ativação massiva. O método depende de telemetria corporativa de provedores de internet, não operando no smartphone do cidadão.

Table 1. Matriz comparativa de competidores e contribuição (✓: faz integralmente; ►: faz em parte; ×: não faz; ?: não reportado). Os três últimos eixos evidenciam onde a nossa proposta perde categoricamente (×).

Trabalho / Solução	**Eixo 1** Intercep. Redirec.	**Eixo 2** Audita APK	**Eixo 3** Espelhos Grafos	**Eixo 4** Semântica Landing	**Eixo 5** Dados Celular	**Eixo 6** Latência < 50ms	**Eixo 7** Baixo Cons. Bat/RAM	**Eixo 8** Prontidão Produção
Trend Micro Check	×	×	►	►	×	✓	✓	✓
Gamban	×	►	×	×	✓	✓	✓	✓
Netcraft Mobile	►	×	►	×	×	✓	✓	✓
Muzakir et al. (2025) [4]	×	×	×	✓	×	?	?	×
Álvarez-Ojeda et al. (2025) [1]	×	×	×	✓	×	?	?	×
Nabeel et al. (2020) [5]	×	×	✓	×	×	?	?	×
Sentinela Clandestino	✓	✓	✓	✓	✓	×	×	×

2.2 Matriz Comparativa de Eixos e Evidências Empíricas

A Tabela 1 formaliza a matriz comparativa de 8 eixos operacionais, confrontando a proposta do Sentinela Clandestino com os seis trabalhos mais próximos. Seguindo o princípio de rigor metodológico da disciplina, o modelo proposto assume honestamente a perda em três eixos críticos de engenharia.

2.3 Declaração Canônica da Contribuição

Com base na combinação única de quadrantes em que a solução atua de forma diferenciada, a contribuição científico-tecnológica é expressa formalmente como:

> *"O Sentinela Clandestino correlaciona a semântica da página de pouso de apostas com a topologia de infraestrutura de espelhos e APKs diretamente na borda do smartphone, e por isso bloqueia o ciclo da aposta clandestina no momento do redirecionamento com total privacidade local, o que nem os filtros de rede estáticos (Gamban/Netcraft) nem os classificadores em nuvem (Muzakir/Álvarez-Ojeda) conseguem realizar isoladamente."*

O trabalho mais próximo é o **Trend Micro Check**, que analisa links e capturas de tela com modelos de IA na nuvem; todavia, ele falha porque depende da proatividade manual da vítima em enviar o conteúdo e não audita manifestos de APKs piratas nem correlaciona grafos de espelhos no momento do clique.

3 Arquitetura Sistêmica e Metodologia

A arquitetura do Sentinela Clandestino foi desenhada para operar sob as restrições rígidas de segurança, memória e consumo de energia típicas de dispositivos móveis populares, articulando-se em três componentes cooperativos na borda.

3.1 Camada de Interceptação e Triagem de Eventos

Em vez de violar o isolamento de processos de redes sociais proprietárias, o sistema atua na transição de contexto do sistema operacional:

1. **Interceptação de Redirecionamento (*Intent Interception*):** Captura requisições de abertura de links externos despachadas a partir de navegadores embutidos (*Custom Tabs*) ou aplicativos de mensageria;
2. **Gatilho de Download de Binários:** Detecta o início de transferências de arquivos executáveis com extensão `.apk` provenientes de fontes desconhecidas fora da loja Google Play.

3.2 Inferência Semântica On-Device via SLM Quantizado

Ao interceptar a página de destino (*landing page*), o texto textual renderizado é submetido a um modelo de linguagem de pequeno porte quantizado em 4-bit (INT4) baseado na arquitetura MobileLLM [3]. O modelo avalia a presença de padrões de linguagem persuasiva, promessas de ganhos fáceis (e.g., termos como "banca", "alavancagem", "bug do tigrinho") e identifica chaves Pix ou intermediadoras financeiras informais descritas no HTML, alcançando alta capacidade discriminativa com pegada de memória inferior a 500 MB de RAM.

3.3 Inspeção Estática de APKs e Corredação em Grafos

Quando o evento envolve um pacote de aplicação Android:

1. **Análise Estática do Manifesto:** Um módulo local de análise rápida inspeciona permissões críticas (acesso a SMS, sobreposição de tela, leitura de *clipboard*), identificando táticas de camuflagem (*piggybacking*) documentadas na literatura recente de segurança [2,6];
2. **Agente MCP e Consulta a Grafos de Ameaças:** Por meio de um agente orquestrado via *Model Context Protocol* (MCP), o sistema consulta um *digest* comprimido (baseado em filtros de Bloom e grafos de resolução passiva de DNS [5]) para correlacionar o domínio do servidor com clusters históricos de operadores clandestinos e laranjas financeiros.

Caso a probabilidade conjunta de ameaça ultrapasse o limiar operacional, o redirecionamento é bloqueado preventivamente com exibição de alerta educativo ao cidadão.

4 Considerações Finais e Trade-offs de Engenharia

A viabilização do Sentinela Clandestino impõe a aceitação explícita de compromissos técnicos de engenharia de software e sistemas operacionais, evitando concessões complacentes:

1. **Latência de Redirecionamento (100–300ms vs. $<$ 50ms):** Filtros estáticos de DNS ou VPN (como Gamban e Netcraft) operam com descarte quase instantâneo de pacotes ($<$ 10ms). A execução de uma passagem direta (*forward pass*) de um SLM quantizado e a consulta ao grafo local introduzem uma latência perceptível de até 300 milissegundos durante o clique externo, configurando um custo deliberado em prol da análise contextual profunda;
2. **Consumo Energético e Alocação de Memória:** Manter um modelo de linguagem residente na memória de smartphones de entrada causaria o encerramento do processo pelo *Low Memory Killer* (LMK) do Android. Portanto, a arquitetura adota ativação estritamente orientada a eventos, permanecendo inativa durante a navegação cotidiana e ativando o processador neural (NPU/CPU) apenas em eventos de clique externo ou download;
3. **Maturidade de Validação em Escala:** Enquanto produtos comerciais possuem bases de milhões de usuários e certificação regulatória, o Sentinela Clandestino posiciona-se como uma investigação tecnológica de vanguarda voltada para o bem social (*AI for Good*).

Em síntese, enquanto as soluções existentes tentam conter o avanço das fraudes mediante tabelas fixas de endereços ou delegando a privacidade a servidores corporativos na nuvem, o Sentinela Clandestino articula a triagem semântica no aparelho com a inteligência de grafos de infraestrutura criminosa, oferecendo proteção em tempo real sem comprometer a soberania dos dados do cidadão.

References

1. Álvarez-Ojeda, P., Cantero-Romero, M.V., Semikozova, A., Montejo-Ráez, A.: The PRECOM-SM corpus: Gambling in spanish social media. In: Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025). pp. 17–28. Association for Computational Linguistics (2025), https://aclanthology.org/2025.coling-main.2/
2. Li, X., Zhang, Y., Wang, H., Chen, S., Li, X.: Automated mass malware factory: The convergence of piggybacking and adversarial example in Android malicious software generation. In: Proceedings of the Network and Distributed System Security Symposium (NDSS 2025). Internet Society (2025), https://www.ndss-symposium.org/ndss-paper/automated-mass-malware-factory/
3. Liu, Z., Zhao, C., Iandola, F., Lai, C., Tian, Y., Fedorov, I., Xiong, Y., Chang, E., Shi, Y., Krishnamoorthi, R., Lai, L., Chandra, V.: MobileLLM: Optimizing sub-billion parameter language models for on-device use cases. In: Proceedings of the 41st International Conference on Machine Learning (ICML 2024). Proceedings of Machine Learning Research, vol. 235, pp. 31737–31757. PMLR (2024), https://proceedings.mlr.press/v235/liu24ce.html
4. Muzakir, A., Ependi, U., Suyanto, Prasetyaningrum, P.T., Alfiansyah, M., Rosi, V.T.: Text-based detection of online gambling advertisements on social media using AutoML and CNN. In: Proceedings of the 2025 2nd International Conference on Information System and Information Technology (ICISIT). pp. 1–6. IEEE (2025). https://doi.org/10.1109/ICISIT.2025.10842131

5. Nabeel, M., Khalil, I.M., Guan, B., Yu, T.: Following passive DNS traces to detect stealthy malicious domains via graph inference. ACM Transactions on Privacy and Security **23**(4), 17:1–17:29 (2020). https://doi.org/10.1145/3401897
6. Zhang, Y., Chen, S., Li, X., Li, X.: Fighting fire with fire: Adversarial Android malware detection via continuous gradient optimization. In: Proceedings of the 34th USENIX Security Symposium (USENIX Security 2025). USENIX Association (2025), https://www.usenix.org/conference/usenixsecurity25/presentation/zhang-yinyuan